

Методы оптимизации

Семинар 1

Оптимизация как основа машинного обучения

Конспект теории

НИУ ВШЭ, факультет компьютерных наук

2026–2027 учебный год

Лектор курса: Андрей Игнатов

Евгений Баулин

Telegram: @tarakan_tuc

Содержание

1	Обозначения	4
2	Задачи оптимизации	5
2.1	Что мы минимизируем и зачем	5
2.2	Допустимое множество	5
2.3	Локальные и глобальные минимумы	6
3	Разминка: одна переменная	7
3.1	Производная — это скорость	7
3.2	Ноль производной необходим, но не достаточен	7
3.3	Формула Тейлора	8
4	Функции нескольких переменных	8
4.1	Множества уровня: карта высот	8
4.2	Частные производные	9
4.3	Градиент	9
4.4	Гессиан	10
4.5	Ловушка смешанного слагаемого	11
5	Формула Тейлора для многих переменных	11
5.1	Формула	11
5.2	Как считать квадратичное слагаемое	12
5.3	Численная проверка	12

6	Квадратичные формы и знакоопределённость	13
6.1	Пять случаев	13
6.2	Ответ дают собственные значения	13
6.3	Критерий Сильвестра	14
6.4	Чего не умеет критерий Сильвестра	15
7	Условия оптимальности	16
7.1	Допустимые направления	16
7.2	Производная по направлению	16
7.3	Необходимое условие первого порядка	17
7.4	Необходимое условие второго порядка	18
7.5	Достаточное условие второго порядка	19
7.6	Сводная таблица и порядок действий	19
7.7	Зазор между полуопределённостью и определённостью	19
7.8	Почему у обезьяньего седла шесть секторов	20
8	Выпуклость	21
8.1	Выпуклые множества	21
8.2	Выпуклые функции	22
8.3	Всякий локальный минимум глобален	22
8.4	Почему это важно в машинном обучении	23
9	От доски к клавиатуре	23
9.1	Проверка градиента: центральные разности	23
9.2	Классификация гессиана с допуском	24
10	Вопросы, которые задают студенты	25
11	Задачи семинара	25
11.1	A. Градиенты и гессианы	26
11.2	B. Классификация стационарных точек	27
11.3	C. Выпуклость	29
11.4	D. Допустимые направления	30
12	Домашняя практика	32
13	Типичные ошибки	33
13.1	Градиенты и гессианы	33
13.2	Классификация стационарных точек	34
13.3	Выпуклость	34
13.4	Допустимые направления	35

14 Глоссарий	35
15 Литература	37

Этот конспект собирает теорию к семинару 1: что такое задача оптимизации, производные функций одной и нескольких переменных, формула Тейлора, знакоопределённость матриц, условия оптимальности и выпуклость. Он написан для чтения с нуля: достаточно производной из первого курса математического анализа, а векторы, определители, градиенты, гессианы и собственные значения вводятся по ходу дела. К каждому утверждению есть пример с числами; главные доказательства начинаются с идеи в одной фразе; врезки двух видов отмечают ловушки, в которые попадают почти все, и короткие вопросы для самопроверки. В разделе «Задачи семинара» разобраны все одиннадцать задач с полными решениями; за ним следуют домашняя практика, типичные ошибки и глоссарий.

Обозначения и соглашения.

Векторы — это столбцы: $x = (x_1; \dots; x_n)^\top \in \mathbb{R}^n$, а $x^\top y = x_1 y_1 + \dots + x_n y_n$ — число. Евклидова длина вектора — $\|x\| = \sqrt{x^\top x}$. Каждая задача — задача минимизации $\min_{x \in \Omega} f(x)$: максимум f — это минимум $-f$. Градиент $\nabla f(x)$ — вектор-столбец, $H(x)$ — гессиан; у всех функций этого конспекта H симметричен. Через x^* обозначается точка-кандидат или точка минимума. Записи $A \succ 0$ и $A \succeq 0$ означают, что симметричная матрица A положительно определена и положительно полуопределена. Шаг вдоль направления s — это $x + \alpha s$ с параметром шага $\alpha \geq 0$; α равно длине шага только при $\|s\| = 1$. Буква λ обозначает вес из $[0, 1]$ или собственное значение, и из контекста всегда ясно, что именно.

1 Обозначения

Формулы легче читать, когда их можно произнести вслух. В таблице собраны символы: как они читаются и что означают.

Символ	Как читается	Что означает
$\mathbb{R}^n$	«эр в степени эн»	упорядоченные наборы из n вещественных чисел, например $x = (1; -2; 0,5) \in \mathbb{R}^3$
$\ x\ $	«норма икс»	длина вектора $\sqrt{x_1^2 + \dots + x_n^2}$
$x^\top y$	«икс транспонированное игрек», «скалярное произведение»	$x^\top$ — столбец x , записанный строкой; $x^\top y = x_1 y_1 + \dots + x_n y_n$ — одно число
∇f	«набла эф», «градиент эф»	столбец первых частных производных
$\partial f / \partial x_1$	«дэ эф по дэ икс один»	частная производная по x_1
H	«гессиан», «аш от икс»	матрица вторых частных производных
Ω	«омега»	допустимое множество, в котором ищется минимум
x^*	«икс со звёздочкой»	точка-кандидат или точка минимума
$A \succ 0, A \succeq 0$	«А положительно определена», «положительно полуопределена»	$h^\top A h > 0$ для всех $h \neq 0$ (все собственные значения положительны); $h^\top A h \geq 0$ для всех h (все собственные значения неотрицательны)
$o(\alpha)$	«о малое от альфа»	величина, для которой $o(\alpha)/\alpha \rightarrow 0$ при $\alpha \rightarrow 0$

Скалярное произведение — это число

Для $x = (1; -1)$ и $y = (2; 4)$ произведение $x^\top y = 1 \cdot 2 + (-1) \cdot 4 = -2$ — число, а не вектор. В разделе об условиях оптимальности это число станет скоростью изменения функции

вдоль направления.

2 Задачи оптимизации

Весь семинар рассказывает одну историю. Нужно найти точки, в которых функция принимает наименьшее значение. Проверить все точки невозможно, поэтому минимум приходится распознавать по локальным признакам, то есть по производным в самой точке: первая производная даёт кандидатов, вторая их сортирует, а в редких случаях помогает только прямое рассуждение.

2.1 Что мы минимизируем и зачем

Задача оптимизации записывается так:

$$\min_{x \in \Omega} f(x).$$

Здесь f — **целевая функция**, $x \in \mathbb{R}^n$ — **переменные**, а Ω — **допустимое множество**, то есть точки, среди которых ищется минимум. При двух переменных кандидат — точка плоскости, при трёх — точка пространства. При многих переменных картинки нет, но формулы те же.

В машинном обучении переменные — это параметры модели, а функция — её ошибка на данных. Линейная модель с 50 весами — точка $\mathbb{R}^{50}$, у нейронной сети около 10^9 параметров. Для обучающих данных $(a_i; y_i)$, $i = 1, \dots, m$, где a_i — вектор признаков, а y_i — целевое значение, **обучение** означает минимизацию **эмпирического риска**

$$L(w) = \frac{1}{m} \sum_{i=1}^m \ell(y_i, w^\top a_i),$$

где функция потерь ℓ измеряет ошибку на одном объекте, например $\ell(y, \hat{y}) = (y - \hat{y})^2$.

Пример. Подберите прямую $y = w_1 + w_2 t$ по точкам $(t_i; y_i)$, где $t = (0; 1; 2)$ и $y = (1; 2; 4)$. С квадратичной функцией потерь обучение — это задача

$$\min_{w \in \mathbb{R}^2} L(w), \quad L(w) = \frac{1}{3} ((w_1 - 1)^2 + (w_1 + w_2 - 2)^2 + (w_1 + 2w_2 - 4)^2).$$

Ответ $w^* = (\frac{5}{6}; \frac{3}{2})$ со значением $L(w^*) = \frac{1}{18}$ выводится в разделе о выпуклости, когда в распоряжении будут градиенты и выпуклость.

Почему. Перебор безнадёжен: сетка всего с 10 значениями по каждой координате содержит 10^{50} точек в $\mathbb{R}^{50}$. Поэтому вместо поиска по всему пространству смотрят на одну точку и спрашивают, что говорят производные в ней.

2.2 Допустимое множество

Допустимое множество $\Omega \subseteq \mathbb{R}^n$ состоит из разрешённых точек. Если $\Omega = \mathbb{R}^n$, то это задача **без ограничений**. Типичные допустимые множества — квадрант $\{x_1 \geq 0, x_2 \geq 0\}$, круг $\|x\| \leq 2$ и вообще множество, заданное системой неравенств.

Определение: внутренние и граничные точки. Точка $x \in \Omega$ называется **внутренней**, если некоторый шар $\{y : \|y - x\| < \varepsilon\}$ с $\varepsilon > 0$ целиком лежит в Ω ; иначе это **граничная** точка.

Пример. В квадранте $\Omega = \{x_1 \geq 0, x_2 \geq 0\}$ точка $(3; 5)$ внутренняя. Точка $(0; 2)$ граничная: шаг влево, сколь угодно малый, выводит из Ω . Угловая точка $(0; 0)$ тоже граничная. Это различие станет решающим в разделе об условиях оптимальности.

2.3 Локальные и глобальные минимумы

Определение: локальный минимум. Точка $x^* \in \Omega$ называется точкой **локального минимума** функции f на Ω , если существует $\varepsilon > 0$ такое, что

$$f(x) \geq f(x^*) \quad \text{для всех } x \in \Omega \text{ таких, что } \|x - x^*\| < \varepsilon.$$

Прочитайте определение по частям. «Существует $\varepsilon > 0$ »: найдётся некоторый радиус, возможно, очень маленький. «Для всех $x \in \Omega$ таких, что $\|x - x^*\| < \varepsilon$ »: x^* сравнивается только с допустимыми точками, которые ближе этого радиуса. « $f(x) \geq f(x^*)$ »: ни одна из них не ниже, а равные значения допускаются. Короче говоря, x^* — самая низкая допустимая точка в некоторой своей окрестности.

Определение: глобальный минимум. Точка $x^* \in \Omega$ называется точкой **глобального минимума** функции f на Ω , если $f(x) \geq f(x^*)$ для всех $x \in \Omega$, без ограничения на расстояние.

Определение: строгий минимум. Минимум называется **строгим**, если $f(x) > f(x^*)$ для всех допустимых $x \neq x^*$: в случае **строгого локального минимума** — для всех $x \in \Omega$, удовлетворяющих $0 < \|x - x^*\| < \varepsilon$, а в случае **строгого глобального минимума** — для всех $x \in \Omega$, отличных от x^* .

Пример. Функция $f(x) = x_1^2$ на $\mathbb{R}^2$ всюду удовлетворяет неравенству $f \geq 0$, а на всей прямой $x_1 = 0$ выполнено $f = 0$. Каждая точка этой прямой — точка глобального минимума, но ни один из этих минимумов не строгий: у соседних точек прямой то же значение. Такая прямая — плоское дно.

Локальный и глобальный

Глобальный минимум — это локальный минимум, у которого окрестностью служит всё Ω . Производные — локальный инструмент; для глобального утверждения нужна выпуклость, прямая оценка или, если известно, что глобальный минимум существует (например, когда $f(x) \rightarrow +\infty$ при $\|x\| \rightarrow \infty$ или когда Ω замкнуто и ограничено), сравнение всех локальных минимумов.

Проверьте себя. Функция на прямой стремится к $+\infty$ при $|x| \rightarrow \infty$ и имеет две ямы разной глубины. Сколько у неё локальных и сколько глобальных минимумов?

Ответ. Два локальных минимума и один глобальный — на дне более глубокой ямы; глобальный минимум существует, потому что f растёт на бесконечности. Если ямы одинаковой глубины, обе точки дна — точки глобального минимума; каждая из них по-

прежнему точка строгого локального минимума, но ни одна не является точкой строгого глобального минимума.

3 Разминка: одна переменная

Раздел начинается с производной из первого курса математического анализа: на неё полезно взглянуть глазами оптимизации.

3.1 Производная — это скорость

Производная функции $f: \mathbb{R} \rightarrow \mathbb{R}$ в точке x — это предел

$$f'(x) = \lim_{\alpha \rightarrow 0} \frac{f(x + \alpha) - f(x)}{\alpha}.$$

Сделайте маленький шаг α и разделите изменение f на шаг: получится скорость — изменение f на единицу шага. Геометрически $f'(x)$ — угловой коэффициент касательной к графику в точке x . Односторонний вариант, с $\alpha \rightarrow 0^+$, появится вместе с производной по направлению.

Если $f'(x) \neq 0$ во внутренней точке области определения, то по одну сторону от x функция f убывает, поэтому x не является точкой минимума.

3.2 Ноль производной необходим, но не достаточен

Пример. У $f(x) = x^3$ производная $f'(x) = 3x^2$ и $f'(0) = 0$, но $f < 0$ слева от 0 и $f > 0$ справа: экстремума в 0 нет.




Рисунок. Слева: у x^3 производная $f'(0) = 0$, но экстремума нет. В центре: у x^2 строгий минимум в 0. Справа: у $f(x) = 3x^4 - 4x^3 - 12x^2$ с $f'(x) = 12x(x+1)(x-2)$ локальные минимумы в $x = -1$ и $x = 2$ и локальный максимум в $x = 0$; глобальный минимум только на дне более глубокой ямы, $f(2) = -32$.

Необходимое и достаточное

Условие называется **необходимым**, если оно выполняется в каждом минимуме, и **достаточным**, если оно гарантирует минимум. Во внутренних точках равенство $f'(x) = 0$ необходимо, но не достаточно: решение уравнения $f' = 0$ даёт кандидатов, а не ответы.

Вторая производная различает x^2 и x^3 : у x^2 значение $f''(0) = 2 > 0$, а у x^3 значение $f''(0) = 0$ не даёт никакой информации.

3.3 Формула Тейлора

Формула Тейлора заменяет функцию вблизи точки многочленом. Для дважды дифференцируемой функции f выполнено

$$f(x + \alpha) = \underbrace{f(x)}_{\text{значение}} + \underbrace{f'(x)\alpha}_{\text{линейная часть}} + \underbrace{\frac{1}{2}f''(x)\alpha^2}_{\text{кривизна}} + o(\alpha^2).$$

Остаток $o(\alpha^2)$ («о малое») удовлетворяет условию $o(\alpha^2)/\alpha^2 \rightarrow 0$ при $\alpha \rightarrow 0$: при малых шагах им можно пренебречь по сравнению с остальными слагаемыми.

Как этим пользоваться

Если $f'(x) \neq 0$, всё решает линейное слагаемое: малый шаг с $f'(x)\alpha < 0$ уменьшает f , поэтому x не точка минимума. Если $f'(x) = 0$, решает знак $f''(x)$: при $f''(x) > 0$ это строгий локальный минимум, при $f''(x) < 0$ — строгий локальный максимум. Если же и $f''(x) = 0$, формула молчит. В разделе о формуле Тейлора для многих переменных та же логика повторяется для функций многих переменных.

Пример. У $f(x) = 3x^4 - 4x^3 - 12x^2$ производные равны $f'(x) = 12x(x+1)(x-2)$ и $f''(x) = 36x^2 - 24x - 24$. В стационарных точках: $f''(-1) = 36 > 0$ — локальный минимум; $f''(0) = -24 < 0$ — локальный максимум; $f''(2) = 72 > 0$ — локальный минимум. Какой из двух минимумов глобальный, производные не говорят. Так как $f(x) \rightarrow +\infty$ при $|x| \rightarrow \infty$, глобальный минимум существует и совпадает с одним из локальных, поэтому сравните значения $f(-1) = -5$ и $f(2) = -32$.

Проверьте себя. Пусть $f(x) = x^4$. Найдите $f'(0)$ и $f''(0)$. Является ли 0 точкой минимума?

Ответ. Обе производные равны нулю, и тест молчит. Но $x^4 \geq 0$ при всех x , причём равенство достигается только в 0, поэтому 0 — точка строгого глобального минимума. Та же ситуация вернётся в двух переменных в задаче В4.

4 Функции нескольких переменных

Функция n переменных сопоставляет число каждой точке $\mathbb{R}^n$. В примерах этого раздела используется функция из лекции $f = 3x_1^3 + 2x_1x_2^2 + 4x_2^2$ в точке $(1; 1)$; в задаче А2 та же функция исследуется в другой точке.

4.1 Множества уровня: карта высот

Функцию двух переменных удобно представлять как рельеф: $f(x_1, x_2)$ — высота над точкой $(x_1; x_2)$. **Множество уровня** $\{x : f(x) = c\}$ состоит из точек одинаковой высоты c , в точности как горизонталь на топографической карте; на картинках в плоскости это **линия уровня**. Несколько линий уровня с подписанными значениями дают карту высот функции f . Две разные линии уровня никогда не пересекаются: у точки только одна высота.




Рисунок. Линии уровня с подписанными значениями. Слева: $x_1^2 + x_2^2$ (задача B1), окружности вокруг минимума. В центре: $x_1^2 + x_2^2 - x_1x_2$ (задача A1), наклонные эллипсы вокруг минимума. Справа: $x_1^2 - x_2^2$ (задача B2), гиперболы вокруг седла; штриховые прямые — уровень 0.

Замкнутые вложенные линии уровня окружают яму или холм, и только значения уровней говорят, что именно: без них яма и холм выглядят одинаково. Незамкнутые линии уровня, расходящиеся друг от друга, — признак седла: в одном направлении функция растёт, в другом убывает. Там, где линии уровня с равномерно расставленными значениями сгущаются, функция меняется быстро.

4.2 Частные производные

Определение: частная производная. Частная производная функции f по переменной x_i — это обычная производная по x_i при зафиксированных остальных переменных, то есть скорость изменения f , когда меняется только x_i :

$$\frac{\partial f}{\partial x_i}(x) = \lim_{\alpha \rightarrow 0} \frac{f(x_1, \dots, x_i + \alpha, \dots, x_n) - f(x)}{\alpha}.$$

На практике это значит: считайте все буквы, кроме x_i , числами и дифференцируйте по обычным правилам. Результат снова зависит от всех n переменных.

Пример. Продифференцируйте $f = 3x_1^3 + 2x_1x_2^2 + 4x_2^2$ по слагаемым. По x_1 : $3x_1^3$ даёт $9x_1^2$; в слагаемом $2x_1x_2^2$ множитель x_2^2 — «число», поэтому оно даёт $2x_2^2$; слагаемое $4x_2^2$ не содержит x_1 и даёт 0. Итого $\partial f / \partial x_1 = 9x_1^2 + 2x_2^2$. Точно так же по x_2 первое слагаемое даёт 0, а два других дают $4x_1x_2$ и $8x_2$, так что $\partial f / \partial x_2 = 4x_1x_2 + 8x_2$.

Проверьте себя. Найдите обе частные производные функции $f = x_1^2x_2 + 5x_2^3$.

Ответ. $\partial f / \partial x_1 = 2x_1x_2$ и $\partial f / \partial x_2 = x_1^2 + 15x_2^2$.

4.3 Градиент

Определение: градиент. Градиент функции f в точке x собирает все частные производные в один вектор-столбец:

$$\nabla f(x) = (\partial f / \partial x_1; \dots; \partial f / \partial x_n)^\top \in \mathbb{R}^n.$$

- Градиент указывает направление наискорейшего роста, а $-\nabla f$ — направление наискорейшего убывания. Его длина $\|\nabla f\|$ — скорость изменения в этом направлении на

единицу длины (если $\nabla f(x) \neq 0$). Поэтому градиентный спуск шагает против градиента; в разделе об условиях оптимальности это доказывается с помощью производной по направлению.

- **Градиент перпендикулярен множествам уровня.** Вдоль множества уровня f не меняется, поэтому скорость изменения f в этом направлении равна нулю и у градиента нет составляющей вдоль этого множества.




Рисунок. Линии уровня $f = x_1^2 + 2x_2^2$ и точка $P = (1; 1)$ на уровне $f = 3$. Градиент $\nabla f(P) = (2; 4)$ перпендикулярен этой линии уровня и указывает в сторону подъёма; $-\nabla f(P)$ указывает в сторону спуска; вдоль касательного направления τ скорость изменения равна нулю. Направление $s = (1; -1)$ из задачи D2 образует с $\nabla f(P)$ тупой угол, поэтому вдоль него f убывает.

Пример. Частные производные функции из лекции в этой точке дают $\nabla f(1; 1) = (9 + 2; 4 + 8)^\top = (11; 12)$. Малый шаг α вдоль $(11; 12)$ меняет f примерно на $\alpha(121 + 144) = 265\alpha$; противоположный шаг в первом порядке уменьшает f на столько же. Множитель при α равен $\|\nabla f\|^2$ — скалярному произведению градиента на себя.

4.4 Гессиан

Если частную производную продифференцировать ещё раз, по той же или по другой переменной, получится вторая частная производная. Для n переменных таких производных n^2 , и их записывают в квадратную таблицу.

Определение: гессиан. Гессиан функции f в точке x — матрица $n \times n$ из вторых частных производных; в строке i и столбце j стоит $\partial^2 f / \partial x_i \partial x_j$:

$$H(x) = [\partial^2 f / \partial x_i \partial x_j]_{i,j=1}^n.$$

Теорема: Шварца. Если вторые частные производные функции f непрерывны, они не зависят от порядка дифференцирования: $\partial^2 f / \partial x_i \partial x_j = \partial^2 f / \partial x_j \partial x_i$. Следовательно, гессиан симметричен.

Все функции семинара — многочлены, их вторые производные всюду непрерывны, поэтому их гессианы симметричны. Это важно: всё дальнейшее, в том числе собственные значения и критерий Сильвестра, относится к симметричным матрицам.

Пример. Гессиан функции из лекции по шагам. Производная от $\partial f/\partial x_1 = 9x_1^2 + 2x_2^2$ по x_1 равна $18x_1$, а по x_2 равна $4x_2$; производная от $\partial f/\partial x_2 = 4x_1x_2 + 8x_2$ по x_2 равна $4x_1 + 8$. Поэтому

$$H(x) = \begin{pmatrix} 18x_1 & 4x_2 \\ 4x_2 & 4x_1 + 8 \end{pmatrix}, \quad H(1; 1) = \begin{pmatrix} 18 & 4 \\ 4 & 12 \end{pmatrix},$$

и $\det H(1; 1) = 216 - 16 = 200$. Проверьте симметрию: производная от $\partial f/\partial x_2$ по x_1 даёт то же самое $4x_2$. В отличие от гессиана квадратичной функции, этот гессиан зависит от точки, поэтому в задаче A2 в её точке получается другая матрица.

4.5 Ловушка смешанного слагаемого

Ловушка. Слагаемое cx_1x_2 даёт $H_{12} = H_{21} = c$: продифференцируйте напрямую, $\partial(cx_1x_2)/\partial x_1 = cx_2$, затем $\partial(cx_2)/\partial x_2 = c$ — никакого деления пополам. Значение $c/2$ — это элемент матрицы A в записи $f = x^\top Ax$: произведение $x^\top Ax$ содержит x_1x_2 дважды, как $A_{12}x_1x_2 + A_{21}x_2x_1$, и для симметричной A выполнено $H = A + A^\top$. В записи $f = \frac{1}{2}x^\top Hx$ делить пополам не нужно. На практике встречаются два неверных значения: $c/2$ (соглашение $x^\top Ax$) и $2c$ (удвоение, как будто слагаемое — квадрат).

Соглашение	Внедиагональный элемент	Для $f = x_1^2 + x_2^2 - x_1x_2$
Гессиан H	c	$H_{12} = -1$
$f = x^\top Ax$	$c/2$	$A_{12} = -0,5$
$f = \frac{1}{2}x^\top Hx$	c	сам гессиан

Отсюда правило, позволяющее выписать H многочлена второй степени без дифференцирования: на диагонали стоят удвоенные коэффициенты при квадратах; каждое смешанное слагаемое ставит свой коэффициент в обе симметричные позиции; переменным, которые нигде не встречаются вместе, соответствует 0.

Проверьте себя. Выпишите гессиан функции $f = 3x_1^2 + x_2^2 + 2x_3^2 - 4x_1x_2 + 6x_2x_3$, не дифференцируя по слагаемым.

Ответ. На диагонали стоят удвоенные коэффициенты при квадратах, вне диагонали — коэффициенты смешанных слагаемых в обеих симметричных позициях; x_1 и x_3 вместе не встречаются:

$$H = \begin{pmatrix} 6 & -4 & 0 \\ -4 & 2 & 6 \\ 0 & 6 & 4 \end{pmatrix}.$$

5 Формула Тейлора для многих переменных

Формула Тейлора — главный инструмент курса: вблизи точки гладкая функция заменяется многочленом с малой ошибкой, и все условия оптимальности выводятся из этой формулы.

5.1 Формула

Для дважды непрерывно дифференцируемой функции f и малого вектора h значение вблизи x равно значению в x плюс линейное и квадратичное слагаемые с точностью до малого остатка:

$$f(x+h) = f(x) + \nabla f(x)^\top h + \frac{1}{2}h^\top H(x)h + o(\|h\|^2).$$

Остаток удовлетворяет условию $o(\|h\|^2)/\|h\|^2 \rightarrow 0$ при $h \rightarrow 0$.

- $f(x)$ — значение там, где вы стоите, то есть исходная высота.
- $\nabla f(x)^\top h$ — **линейная часть**, одно число: скалярное произведение градиента на смещение. Она меняет знак вместе с h : у шагов h и $-h$ линейные части равны по величине и противоположны по знаку.
- $\frac{1}{2}h^\top Hh$ — **квадратичная часть**, кривизна. При замене h на $-h$ она не меняется, потому что h входит в неё дважды.

Почему. Если $\nabla f(x) \neq 0$, при малых шагах главной оказывается линейная часть, и один из шагов h и $-h$ уменьшает f , поэтому x не точка минимума. Если $\nabla f(x) = 0$, линейная часть исчезает и всё решает знак $h^\top Hh$ по всем направлениям h ; какими бывают эти знаки, разобрано в разделе о квадратичных формах и знакоопределённости.

5.2 Как считать квадратичное слагаемое

Число $h^\top Hh$ составлено из элементов H и компонент h . При $n = 2$ раскрытие произведения даёт

$$h^\top Hh = H_{11}h_1^2 + 2H_{12}h_1h_2 + H_{22}h_2^2.$$

Такая сумма квадратов и попарных произведений компонент с постоянными коэффициентами называется **квадратичной формой**. Смешанное слагаемое входит дважды, как $H_{12}h_1h_2$ и $H_{21}h_2h_1$, отсюда множитель 2 — то же удвоение, что и в ловушке смешанного слагаемого.

Пример. Для гессиана из лекции $H = \begin{pmatrix} 18 & 4 \\ 4 & 12 \end{pmatrix}$ и шага $h = (1; 1)$: $h^\top Hh = 38$ и $\frac{1}{2}h^\top Hh = 19$.

5.3 Численная проверка

Числа показывают, что формула действительно работает. Возьмите функцию из лекции в точке $(1; 1)$, где $f = 9$, $\nabla f = (11; 12)$ и $H = \begin{pmatrix} 18 & 4 \\ 4 & 12 \end{pmatrix}$. Вдоль $h = t(1; 1)$ сравните три числа: точное значение, линейную модель $9 + 23t$ и квадратичную модель $9 + 23t + 19t^2$.

t	точное f	линейная	квадратичная	ошибка линейной	ошибка квадратичной
0,5	25,875	20,5	25,25	5,375	0,625
0,1	11,495	11,3	11,49	0,195	0,005
0,01	9,231905	9,23	9,2319	0,001905	0,000005

Деление t на 10, как при переходе от второй строки к третьей, делит ошибку линейной модели примерно на 100 (как t^2), а ошибку квадратичной — на 1000 (как t^3). Вдоль этой прямой f равна $5(1+t)^3 + 4(1+t)^2$, поэтому ошибка квадратичной модели в точности равна $5t^3$. Именно это и означает запись $o(\|h\|^2)$: остаток исчезает быстрее выписанных слагаемых.

Квадратичные функции: формула точна

У многочлена второй степени все третьи производные равны нулю, поэтому остатка нет и формула Тейлора точна. Проверьте это на $q = x_1^2 + x_1x_2 + 2x_2^2$ в точке $(1; 2)$: $q = 11$,

$\nabla q = (4; 9)$, $H = \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}$. Для $h = (0,3; -0,2)$ линейная часть равна $-0,6$; произведения h_1^2 , h_1h_2 и h_2^2 , равные $(0,09; -0,06; 0,04)$, дают $h^\top H h = 0,22$ и квадратичную часть $0,11$. Сумма равна $10,51$ и совпадает с $q(1,3; 1,8)$. Линейная регрессия с квадратичной функцией потерь квадратична по весам, поэтому решается формулой, без итераций.

6 Квадратичные формы и знакоопределённость

Формула Тейлора показывает: в точке, где $\nabla f(x) = 0$, линейное слагаемое исчезает и главным становится квадратичное, $\frac{1}{2} h^\top H(x) h$. Поэтому поведение f вблизи x — поднимается она или опускается — зависит от знаков, которые принимает $h^\top H h$ при всевозможных направлениях h . В этом разделе разбирается, какие знаки может принимать квадратичная форма и как их определить.

6.1 Пять случаев

Определение: знакоопределённость. Симметричная матрица A размера $n \times n$ называется **положительно определённой**, $A \succ 0$, если $h^\top A h > 0$ для всех $h \neq 0$, и **положительно полуопределённой**, $A \succeq 0$, если $h^\top A h \geq 0$ для всех h . Она называется **отрицательно определённой**, $A \prec 0$, если $h^\top A h < 0$ для всех $h \neq 0$, и **отрицательно полуопределённой**, $A \preceq 0$, если $h^\top A h \leq 0$ для всех h . Наконец, A называется **знако-неопределённой**, если $h^\top A h$ принимает значения обоих знаков: $h^\top A h > 0$ для некоторого h и $g^\top A g < 0$ для некоторого g .

На языке рельефа график $h^\top A h$ — это чаша при $A \succ 0$, купол при $A \prec 0$, седло при знако-неопределённой A и жёлоб с плоским дном при вырожденной $A \succeq 0$: вдоль направлений, где $h^\top A h = 0$, график остаётся на высоте 0.




Рисунок. Линии уровня $h^\top A h$: чаша при $A = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$, купол при $A = \begin{pmatrix} -2 & 1 \\ 1 & -2 \end{pmatrix}$, седло при $A = \begin{pmatrix} 2 & -4 \\ -4 & 2 \end{pmatrix}$ и жёлоб при $A = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}$; нулевое собственное значение этой матрицы даёт плоское дно, показанное красным.

6.2 Ответ дают собственные значения

У симметричной матрицы A размера $n \times n$ есть n взаимно перпендикулярных единичных **собственных векторов** $v_1, \dots, v_n$: вдоль каждого из них A действует как растяжение, $Av_i = \lambda_i v_i$, а коэффициенты растяжения $\lambda_1, \dots, \lambda_n$ — это **собственные значения**, все они вещественны. Разложите h по осям собственных векторов: $h = u_1 v_1 + \dots + u_n v_n$. Тогда смешанные

слагаемые исчезают и квадратичная форма становится взвешенной суммой квадратов:

$$h^T A h = \lambda_1 u_1^2 + \dots + \lambda_n u_n^2.$$

Теперь любой вопрос о знаках $h^T A h$ решают знаки чисел λ_i .

Собственные значения	Тип	Линии уровня
все > 0	положительно определённая	эллипсы вокруг минимума
все < 0	отрицательно определённая	эллипсы вокруг максимума
обоих знаков	знаконеопределённая	гиперболы, седло
все ≥ 0 , есть нулевые	положительно полуопределённая	параллельные прямые, жёлоб
все ≤ 0 , есть нулевые	отрицательно полуопределённая	то же, но перевёрнутое

Для матрицы 2×2 собственные значения — корни квадратного уравнения $\det(A - \lambda I) = 0$, то есть

$$\lambda^2 - (A_{11} + A_{22})\lambda + \det A = 0.$$

Пример. $A = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$: уравнение $\lambda^2 - 4\lambda + 3 = 0$ имеет корни (1; 3), оба положительны, значит, A положительно определённая. $A = \begin{pmatrix} 2 & -4 \\ -4 & 2 \end{pmatrix}$: уравнение $\lambda^2 - 4\lambda - 12 = 0$ имеет корни (-2; 6) разных знаков, значит, A знаконеопределённая. Это гессианы из задач A1 и C2.

Эти две матрицы отличаются только величиной внедиагонального элемента. Значит, смешанное слагаемое может разрушить знакоопределённость, и решает здесь его величина, а не знак: если сменить знак внедиагональных элементов матрицы 2×2 , её собственные значения не изменятся. Всё семейство таких матриц исследуется в задаче C2.

Забегаая вперёд: число обусловленности

Для $A \succ 0$ отношение $\kappa = \lambda_{\max}/\lambda_{\min}$ называется **числом обусловленности**; оно показывает, насколько вытянуты линии уровня. У $x_1^2 + x_2^2$ собственные значения гессиана равны (2; 2), поэтому $\kappa = 1$ и линии уровня — окружности: один шаг градиентного спуска с величиной шага $\frac{1}{2}$ попадает точно в минимум, $x - \frac{1}{2} \cdot 2x = 0$. Для матрицы из задачи A1 число $\kappa = 3$, и линии уровня — эллипсы. Чем больше κ , тем уже овраг и тем медленнее работают градиентные методы: к этому курс ещё вернётся в следующих темах.

6.3 Критерий Сильвестра

Для матрицы 3×3 собственные значения — корни кубического уравнения, и решать его вручную неудобно. Строгую знакоопределённость можно проверить без него, с помощью определителей. Для матрицы 2×2 $\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc$, определитель большего размера раскладывается по строке, как в примере ниже; определитель равен произведению собственных значений, поэтому из $\det A < 0$ уже следует знаконеопределённость A .

Определение: угловой минор. Угловой (ведущий главный) минор Δ_k матрицы A размера $n \times n$ — это определитель подматрицы из первых k строк и первых k столбцов A , $k = 1, \dots, n$. Обычно их называют просто **угловыми минорами**.

Пример. $A = \begin{pmatrix} 2 & 2 & 0 \\ 2 & 4 & -1 \\ 0 & -1 & 6 \end{pmatrix}$: $\Delta_1 = 2$, $\Delta_2 = 8 - 4 = 4$ и $\Delta_3 = \det A = 2 \cdot 23 - 2 \cdot 12 + 0 = 46 - 24 = 22$ (разложение по первой строке). Все три минора положительны, поэтому по критерию ниже $A \succ 0$.

Теорема: критерий Сильвестра. Пусть A — симметричная матрица размера $n \times n$. Тогда

$$A \succ 0 \iff \Delta_k > 0 \text{ для всех } k, \quad A \prec 0 \iff (-1)^k \Delta_k > 0 \text{ для всех } k.$$

Второй шаблон означает чередование знаков, начиная с минуса: $\Delta_1 < 0$, $\Delta_2 > 0$, $\Delta_3 < 0$ и так далее.

Почему это работает, для 2×2 и $A_{11} \neq 0$: выделите полный квадрат,

$$A_{11}h_1^2 + 2A_{12}h_1h_2 + A_{22}h_2^2 = A_{11}\left(h_1 + \frac{A_{12}}{A_{11}}h_2\right)^2 + \frac{\Delta_2}{A_{11}}h_2^2.$$

При $\Delta_1 = A_{11} > 0$ и $\Delta_2 > 0$ оба коэффициента положительны, и сумма обращается в нуль, только когда $h_2 = 0$, а тогда и $h_1 = 0$. При $\Delta_1 < 0$ и $\Delta_2 > 0$ оба коэффициента отрицательны. В общем случае то же делает метод Гаусса: он выделяет квадраты по одной переменной, а угловые миноры управляют знаками получающихся коэффициентов.

6.4 Чего не умеет критерий Сильвестра

Ловушка. Критерий Сильвестра говорит только о строгой знакоопределённости. Если ни один шаблон не выполнен, нельзя заключать, что матрица знаконеопределённая: она может оказаться полуопределённой. У $A = \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix}$ и $B = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}$ одинаковые угловые миноры, $(\Delta_1; \Delta_2) = (0; 0)$, но $A \preceq 0$, а $B \succeq 0$. Одни и те же миноры дают противоположные ответы, поэтому по угловым минорам полуопределённость не распознать в принципе.

Правильная проверка полуопределённости использует **все** главные миноры: $A \succeq 0$ ровно тогда, когда неотрицательны определители всех подматриц, стоящих на пересечении какого-либо набора строк и того же набора столбцов. У матрицы 3×3 угловых миноров 3, а главных 7; для матрицы A из примера выше это $(2; 4; 6; 4; 12; 23; 22)$. У $\text{diag}(0, -1)$ главные миноры равны $(0; -1; 0)$, и отрицательный минор показывает, что эта матрица не $\succeq 0$.

Практическое правило

На бумаге применяйте критерий Сильвестра только для вопроса о строгой знакоопределённости. Если какой-то $\Delta_k = 0$, переходите к собственным значениям; для матрицы 2×2 это одно квадратное уравнение. В коде всегда вычисляйте собственные значения и сравнивайте их с нулём с допуском, потому что в арифметике с плавающей точкой точный нуль получается редко (об этом — в разделе «От доски к клавиатуре»).

Проверьте себя. Проверьте $A = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$ по критерию Сильвестра. Что можно заключить?

Ответ. $(\Delta_1; \Delta_2) = (2; -4)$. Шаблон для $A \succ 0$ требует, чтобы все $\Delta_k > 0$, и нарушается на Δ_2 ; шаблон для $A \prec 0$ требует $\Delta_1 < 0$ и нарушается сразу. Ни один шаблон не вы-

полнен, поэтому критерий говорит лишь, что A не является строго знакоопределённой. Собственные значения $(-2; 2)$ разных знаков и показывают, что матрица знаконеопределённая.

7 Условия оптимальности

Формула Тейлора, знакоопределённость и различие между внутренними и граничными точками теперь складываются в четыре утверждения: лемму о производной по направлению и три условия оптимальности. Вместе они составляют ядро первой лекции курса.

7.1 Допустимые направления

Из внутренней точки Ω можно немного сдвинуться в любом направлении и остаться в Ω . Из граничной точки так нельзя: некоторые направления сразу выводят из Ω .

Определение: допустимое направление. Вектор $s \in \mathbb{R}^n$, $s \neq 0$, называется **допустимым направлением** в точке $x \in \Omega$, если существует $\alpha_0 > 0$, при котором $x + \alpha s \in \Omega$ для всех $\alpha \in [0, \alpha_0]$.

Словами: достаточно малый шаг по направлению s оставляет точку в Ω . Число α_0 может быть крошечным, но обязано быть положительным.




Рисунок. Допустимые направления в квадранте $\Omega = \{x_1 \geq 0, x_2 \geq 0\}$. В граничной точке $P = (0; 2)$ они образуют полуплоскость $s_1 \geq 0$ (задача D1), в угловой точке $Q = (0; 0)$ — четверть плоскости $s_1 \geq 0, s_2 \geq 0$ (домашняя практика НЗ), а во внутренней точке $R = (3; 5)$ допустимо любое направление. Красные пунктирные направления сразу выводят из Ω .

Если направление s допустимо, то допустимо и ts при любом $t > 0$: допустимые направления образуют **конус**. Для выпуклого Ω они вместе с 0 образуют выпуклый конус, а для невыпуклого Ω это не обязательно так. В начале координат для множества $\{x_1 \leq 0\} \cup \{x_2 \leq 0\}$ допустимые направления — это $\{s \neq 0 : s_1 \leq 0 \text{ или } s_2 \leq 0\}$, и это множество не выпукло, даже если добавить к нему 0 .

7.2 Производная по направлению

Определение: производная по направлению. Пусть $x \in \Omega$ и s — направление. **Производная по направлению s функции f в точке x** — это односторонний предел

$$\frac{\partial f}{\partial s}(x) = \lim_{\alpha \rightarrow 0^+} \frac{f(x + \alpha s) - f(x)}{\alpha}.$$

Это обычная производная из первого курса математического анализа, только шаг делается не вдоль оси, а вдоль вектора s . Предел односторонний, потому что в граничной точке могут быть разрешены только шаги с $\alpha \geq 0$. Во внутренней точке для дифференцируемой f оба односторонних предела существуют и совпадают, так что двусторонний предел там не ошибка.

Лемма: производная по направлению через градиент. Если f дифференцируема в точке x , то $\frac{\partial f}{\partial s}(x) = s^\top \nabla f(x)$ для любого направления s .

Доказательство. Подстановка $h = \alpha s$ в формулу Тейлора даёт

$$f(x + \alpha s) = f(x) + \alpha s^\top \nabla f(x) + o(\alpha).$$

После вычитания $f(x)$, деления на $\alpha > 0$ и перехода к пределу при $\alpha \rightarrow 0^+$ слагаемое $o(\alpha)/\alpha$ стремится к 0, и остаётся $s^\top \nabla f(x)$.

Зачем нужна эта лемма

Предел, который приходится вычислять, превращается в скалярное произведение, которое считается в одну строку. Кроме того, лемма объясняет, почему градиент указывает направление наискорейшего роста: среди направлений длины 1 скорость $s^\top \nabla f$ максимальна при $s = \nabla f / \|\nabla f\|$ (если $\nabla f \neq 0$) и равна тогда $\|\nabla f\|$, потому что $s^\top \nabla f \leq \|s\| \|\nabla f\|$ по неравенству Коши — Буняковского — Шварца.

Пример. $f = x_1^2 + 2x_2^2$, $x = (1; 1)$, $s = (1; -1)$. Градиент равен $\nabla f = (2x_1; 4x_2)^\top$, в точке x это $(2; 4)$, поэтому $s^\top \nabla f(x) = -2$: вдоль s функция f убывает. Быстрее всего в расчёте на единицу длины она убывает вдоль $-\nabla f(x) / \|\nabla f(x)\|$, со скоростью $-\|\nabla f(x)\| = -2\sqrt{5} \approx -4,4721$, примерно в 3,1623 раза больше по модулю, чем вдоль $s/\|s\|$ (см. ловушку ниже). Поэтому градиентный спуск и делает шаг против градиента.

Ловушка. Число -2 — это скорость на единицу параметра α , а не на единицу длины. Здесь $\|s\| = \sqrt{2} \approx 1,4142$, поэтому на единицу длины приходится $-2/\|s\| = -\sqrt{2} \approx -1,4142$. Сравнивайте направления только после нормировки, иначе самым крутым окажется просто самый длинный вектор.

7.3 Необходимое условие первого порядка

Теорема: необходимое условие первого порядка. Пусть $f \in C^1$ на Ω и x^* — локальный минимум f на Ω . Тогда

$$s^\top \nabla f(x^*) \geq 0$$

для любого допустимого направления s в точке x^* . Если вдобавок x^* — внутренняя точка Ω , то $\nabla f(x^*) = 0$.

Почему. Если бы f убывала вдоль направления, по которому разрешено двигаться, маленький шаг по нему дал бы допустимую точку с меньшим значением, и x^* не был бы минимумом.

Доказательство. Пусть s допустимо и $s^\top \nabla f(x^*) = -\delta < 0$. По формуле Тейлора

$$f(x^* + \alpha s) = f(x^*) - \alpha \delta + o(\alpha),$$

причём $|o(\alpha)| < \frac{1}{2}\alpha\delta$ при всех малых $\alpha > 0$. Для таких α

$$f(x^* + \alpha s) < f(x^*) - \alpha\delta + \frac{1}{2}\alpha\delta = f(x^*) - \frac{1}{2}\alpha\delta < f(x^*).$$

При малых α точка $x^* + \alpha s$ лежит в Ω , так как s допустимо, и сколь угодно близка к x^* : это противоречит тому, что x^* — локальный минимум. Значит, $s^\top \nabla f(x^*) \geq 0$. Во внутренней точке для любого $s \neq 0$ допустимы и s , и $-s$, поэтому $s^\top \nabla f(x^*) \geq 0$ и $-s^\top \nabla f(x^*) \geq 0$, то есть $s^\top \nabla f(x^*) = 0$ для всех s . Единственный вектор, ортогональный всем векторам, — нулевой, значит, $\nabla f(x^*) = 0$.

Если сказать проще

Из минимума нельзя пойти вниз ни по одному направлению, по которому вообще разрешено двигаться. Привычное условие $\nabla f = 0$ — не отдельная теорема, а частный случай внутренней точки: там вдоль любой прямой можно идти в обе стороны, а «не вниз в обе стороны» означает «ровно». На семинаре 2 это неравенство превратится в условия ККТ.

Определение: стационарная точка. Точка x , в которой $\nabla f(x) = 0$, называется **стационарной точкой** функции f . Стационарные точки — кандидаты в точки безусловного минимума: по теореме выше локальный минимум во внутренней точке всегда стационарен.

7.4 Необходимое условие второго порядка

Теорема: необходимое условие второго порядка. Пусть $f \in C^2$ на Ω , x^* — локальный минимум f на Ω и s — допустимое направление в точке x^* , для которого $s^\top \nabla f(x^*) = 0$. Тогда $s^\top H(x^*) s \geq 0$. В частности, во внутренней точке $\nabla f(x^*) = 0$ и $H(x^*) \succeq 0$.

Почему. Когда линейное слагаемое формулы Тейлора вдоль s обнуляется, главным становится квадратичное, и всё решает кривизна вдоль s . Отрицательная кривизна вдоль s означала бы, что f убывает вдоль s .

Доказательство. Подстановка $h = \alpha s$ в формулу Тейлора с учётом $s^\top \nabla f(x^*) = 0$ даёт

$$f(x^* + \alpha s) = f(x^*) + \frac{1}{2}\alpha^2 s^\top H s + o(\alpha^2), \quad H = H(x^*).$$

Если $s^\top H s = -\delta < 0$, то $|o(\alpha^2)| < \frac{1}{4}\alpha^2\delta$ при всех малых $\alpha > 0$, и для таких α

$$f(x^* + \alpha s) < f(x^*) - \frac{1}{2}\alpha^2\delta + \frac{1}{4}\alpha^2\delta = f(x^*) - \frac{1}{4}\alpha^2\delta < f(x^*).$$

Как и в предыдущем доказательстве, точка $x^* + \alpha s \in \Omega$ сколь угодно близка к x^* , а это противоречит тому, что x^* — локальный минимум.

7.5 Достаточное условие второго порядка

Теорема: достаточное условие второго порядка. Пусть $f \in C^2$, x^* — внутренняя точка Ω , $\nabla f(x^*) = 0$ и $H(x^*) \succ 0$. Тогда x^* — строгий локальный минимум.

Почему. Положительно определённый гессиан означает положительную кривизну во всех направлениях сразу, причём с запасом $\mu = \lambda_{\min} > 0$, и этого запаса хватает, чтобы перебить остаток формулы Тейлора.

Доказательство. Пусть $H = H(x^*)$ и $\mu = \lambda_{\min}(H) > 0$. В осях собственных векторов $h^T H h = \lambda_1 u_1^2 + \dots + \lambda_n u_n^2 \geq \mu \|h\|^2$. Так как $\nabla f(x^*) = 0$, формула Тейлора даёт

$$f(x^* + h) - f(x^*) = \frac{1}{2} h^T H h + o(\|h\|^2) \geq \frac{1}{2} \mu \|h\|^2 + o(\|h\|^2).$$

Найдётся $\varepsilon > 0$, при котором шар $\|h\| < \varepsilon$ вокруг x^* лежит в Ω и $|o(\|h\|^2)| < \frac{1}{4} \mu \|h\|^2$ для $0 < \|h\| < \varepsilon$. Для таких h

$$f(x^* + h) - f(x^*) > \frac{1}{4} \mu \|h\|^2 > 0.$$

Значит, во всех остальных точках этой окрестности значение строго больше: x^* — строгий локальный минимум.

7.6 Сводная таблица и порядок действий

Порядок	Необходимое	Достаточное
первого порядка	$\nabla f(x^*) = 0$ во внутренней точке; $s^T \nabla f(x^*) \geq 0$ для любого допустимого s в граничной точке	нет
второго порядка	$\nabla f(x^*) = 0$ и $H(x^*) \succeq 0$ во внутренней точке	$\nabla f(x^*) = 0$ и $H(x^*) \succ 0$ во внутренней точке

Достаточного условия первого порядка нет. Градиент измеряет только наклон, а наклон равен нулю и в минимуме, и в максимуме, и в седле: у $x_1^2 + x_2^2$, $-x_1^2 - x_2^2$ и $x_1^2 - x_2^2$ одинаково $\nabla f(0) = 0$. Чтобы различить эти случаи, нужна информация о кривизне.

Порядок действий

Сначала найдите кандидатов — точки, где $\nabla f = 0$, — и вычислите гессиан H в каждом из них. Если $H \succ 0$, кандидат — строгий локальный минимум; если $H \prec 0$ — строгий локальный максимум; если H знаконеопределённый — седло. Если H вырожденный и полуопределённый, тест второго порядка ничего не решает, и нужно исследовать саму функцию f вблизи точки. Наконец, называйте минимум глобальным только при наличии дополнительного аргумента: выпуклости или оценки снизу.

7.7 Зазор между полуопределённостью и определённостью

Между необходимым и достаточным условиями второго порядка остаётся зазор: $H \succeq 0$, но не $H \succ 0$, то есть полуопределённый гессиан с нулевым собственным значением. Может показаться, что теория здесь просто слабовата и более тонкий тест закроет зазор. Это не так: никакой критерий, использующий только ∇f и H в точке, его не закроет, и следующий пример это доказывает.

Одинаковые данные, разные ответы

У $f_1 = x_1^4 + x_2^4$ и $f_2 = x_1^3 - 3x_1x_2^2$ одинаково $\nabla f(0) = 0$ и $H(0) = 0$. Но у f_1 в начале координат строгий глобальный минимум, а у f_2 экстремума там нет (задачи В4 и В3). Данные первого и второго порядка совпадают, а правильные ответы разные, поэтому никакой тест, который видит только $\nabla f(0)$ и $H(0)$, не отличит эти функции друг от друга.

В такой ситуации вернитесь к определению минимума и работайте с самой функцией f . Обычно помогает один из двух приёмов:

- **Оцените функцию снизу.** $f_1 = x_1^4 + x_2^4 \geq 0 = f_1(0)$, и равенство достигается только в начале координат, поэтому там строгий глобальный минимум. Одна строка, никаких производных.
- **Найдите направление спуска.** Сузьте f_2 на прямую $x_2 = 0$: $f_2(x_1, 0) = x_1^3$ меняет знак в нуле. Значит, сколь угодно близко к началу координат f_2 принимает и положительные, и отрицательные значения, и экстремума там нет.




Рисунок. Слева: знак $f_2 = x_1^3 - 3x_1x_2^2$ вокруг начала координат; чередуются 6 секторов по 60° , где $f_2 > 0$ (синие) и $f_2 < 0$ (красные). Справа: $f_1 = x_1^4 + x_2^4$ положительна всюду, кроме начала координат. У обеих функций $\nabla f(0) = 0$ и $H(0) = 0$.

Проверьте себя. Пусть $g(x_1, x_2) = x_1^2$ на $\mathbb{R}^2$. Найдите стационарные точки и гессиан. Что говорит об этих точках теория?

Ответ. $\nabla g = (2x_1; 0)^\top$ обращается в нуль на всей прямой $x_1 = 0$, а $H = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} \succeq 0$, но не $\succ 0$, поэтому достаточное условие неприменимо. Однако $g \geq 0$ и $g = 0$ на этой прямой, так что каждая её точка — нестрогий глобальный минимум: плоское дно жёлоба.

7.8 Почему у обезьяньего седла шесть секторов

График $f_2 = x_1^3 - 3x_1x_2^2$ — это «обезьянье седло», и его картинку можно объяснить до конца. В полярных координатах $x_1 = r \cos \varphi$, $x_2 = r \sin \varphi$ функция принимает вид $f_2 = r^3 \cos^3 \varphi - 3r^3 \cos \varphi \sin^2 \varphi$. Замена $\sin^2 \varphi$ на $1 - \cos^2 \varphi$ и формула косинуса тройного угла $\cos 3\varphi = 4 \cos^3 \varphi - 3 \cos \varphi$ дают

$$f_2 = r^3 (\cos^3 \varphi - 3 \cos \varphi (1 - \cos^2 \varphi)) = r^3 (4 \cos^3 \varphi - 3 \cos \varphi) = r^3 \cos 3\varphi.$$

Множитель r^3 положителен при $r > 0$, поэтому знак f_2 зависит только от угла φ : при обходе окружности косинус в этой записи меняет знак 6 раз. Получается 6 секторов по 60° : в 3 из них функция поднимается, в 3 опускается.

Почему. У обычного седла два сектора спуска, по одному для каждой ноги всадника. У этого их три: место для двух ног и хвоста сидящей обезьяны, отсюда и название.

Проверьте себя. Сколько секторов знака у $f = x_1^4 - 6x_1^2x_2^2 + x_2^4$ вокруг начала координат и что говорит там тест второго порядка?

Ответ. В полярных координатах $f = r^4 \cos 4\varphi$, поэтому при обходе окружности знак меняется 8 раз: получается 8 секторов. Начало координат — единственная стационарная точка, и $H(0) = 0$, поэтому тест ничего не решает; смены знака показывают, что экстремума в начале координат нет.

8 Выпуклость

Выпуклость — единственное широко распространённое свойство, которое превращает локальные утверждения в глобальные, поэтому за неё так держатся и теория, и машинное обучение.

8.1 Выпуклые множества

Определение: выпуклое множество. Множество Ω **выпукло**, если вместе с любыми двумя своими точками оно содержит весь отрезок между ними: $\lambda x + (1 - \lambda)y \in \Omega$ для всех $x, y \in \Omega$ и $\lambda \in [0, 1]$.

Точка $\lambda x + (1 - \lambda)y$ пробегает отрезок от y (при $\lambda = 0$) до x (при $\lambda = 1$); при $\lambda = \frac{1}{2}$ получается его середина. Чтобы доказать выпуклость множества, нужно убедиться, что отрезок остаётся внутри для любой пары точек; чтобы её опровергнуть, достаточно одной пары точек, отрезок между которыми выходит из множества, как у кольца на рисунке.




Рисунок. Слева направо: круг $\|x\| \leq 2$ выпукл (задача C1); кольцо $1 \leq \|x\| \leq 2$ не выпукло: красная часть отрезка проходит через дыру; x^2 — выпуклая функция, её хорда лежит выше графика; $(x^2 - 1)^2$ не выпукла: хорда между двумя её минимумами лежит ниже графика.

Пример. Любой шар $\{x : \|x - c\| \leq r\}$ в любой норме выпукл, в том числе «ромб» ℓ_1 и «квадрат» ℓ_∞ , у которых есть углы. Доказательство в задаче C1 использует только неравенство треугольника и однородность нормы: выпуклость — это не гладкость.

8.2 Выпуклые функции

Определение: выпуклая функция. Функция f на выпуклом множестве Ω **выпукла**, если

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

для всех $x, y \in \Omega$ и $\lambda \in [0, 1]$. Она **строго выпукла**, если при $x \neq y$ и $0 < \lambda < 1$ неравенство строгое.

Слева стоит значение функции в точке отрезка, справа — значение на хорде, которая соединяет концы графика: график нигде не поднимается выше хорды. В частности, выпуклая функция выпукла вдоль любой прямой: при фиксированных x и s функция одной переменной $t \mapsto f(x + ts)$ выпукла там, где она определена, поэтому одной прямой, вдоль которой это не так, достаточно, чтобы доказать, что f не выпукла.

Теорема: критерий второго порядка. Пусть $f \in C^2$ на открытом выпуклом множестве Ω . Тогда f выпукла $\iff H(x) \succeq 0$ для всех $x \in \Omega$. Если $H(x) \succ 0$ для всех $x \in \Omega$, то f строго выпукла.

Обратное к последнему утверждению неверно: $f(x) = x^4$ строго выпукла, хотя $f''(0) = 0$. Это тот же зазор между $\succeq$ и $\succ$, что и в условиях оптимальности.

Проверьте себя. Выпукла ли функция $f = x_1^2 + x_2^2 + a x_1 x_2$ при $a = 3$?

Ответ. Нет. Гессиан $H = \begin{pmatrix} 2 & 3 \\ 3 & 2 \end{pmatrix}$ имеет собственные значения $2 \pm a$, то есть $(-1; 5)$; одно из них отрицательно, поэтому f не выпукла. Выпукла она ровно при $|a| \leq 2$ (задача C2).

8.3 Всякий локальный минимум глобален

Теорема: локальный минимум выпуклой функции. Пусть f выпукла на выпуклом множестве Ω и x^* — локальный минимум. Тогда x^* — глобальный минимум.

Почему. Если где-то далеко есть точка лучше, то хорда до неё, а вместе с хордой и график, уходит ниже $f(x^*)$, и лучше оказываются точки сколь угодно близко к x^* .

Доказательство. Пусть $f(y) < f(x^*)$ для некоторого $y \in \Omega$, и пусть $z_\lambda = \lambda y + (1 - \lambda)x^*$; эта точка лежит в Ω , потому что Ω выпукло. Выпуклость f даёт $f(z_\lambda) \leq \lambda f(y) + (1 - \lambda)f(x^*)$, то есть $f(z_\lambda) \leq f(x^*) - \lambda(f(x^*) - f(y)) < f(x^*)$ при $\lambda \in (0, 1]$, а $\|z_\lambda - x^*\| = \lambda\|y - x^*\| \rightarrow 0$ при $\lambda \rightarrow 0$. Значит, сколь угодно близко к x^* есть точки с меньшим значением — противоречие с локальной минимальностью.

Следствие. Для выпуклой $f \in C^1$ на $\mathbb{R}^n$ равенство $\nabla f(x^*) = 0$ не только необходимо, но и достаточно для глобального минимума.

Доказательство. Пусть $\nabla f(x^*) = 0$, но $f(y) < f(x^*)$ для некоторого y . Возьмите $s = y - x^*$ и $\varphi(\lambda) = f(x^* + \lambda s)$. По выпуклости $\varphi(\lambda) \leq (1 - \lambda)\varphi(0) + \lambda\varphi(1)$, поэтому $\frac{\varphi(\lambda) - \varphi(0)}{\lambda} \leq \varphi(1) - \varphi(0) < 0$ для всех $\lambda \in (0, 1]$. Переход к пределу при $\lambda \rightarrow 0^+$ даёт $s^\top \nabla f(x^*) \leq f(y) - f(x^*) < 0$, что противоречит равенству $\nabla f(x^*) = 0$.

8.4 Почему это важно в машинном обучении

Эмпирический риск с регуляризационным слагаемым $L(w) = \frac{1}{m} \sum_i \ell(y_i, w^\top a_i) + \rho \|w\|^2$, где $\rho \geq 0$, выпуклый всякий раз, когда функция потерь ℓ выпукла по второму аргументу: композиция с аффинным отображением $w \mapsto w^\top a_i$ и неотрицательная сумма сохраняют выпуклость. Квадратичная и логистическая функции потерь и функция потерь Хьюбера выпуклы, поэтому у линейных моделей любая точка с нулевым градиентом — точка глобального минимума. Нейронная сеть теряет это свойство уже с одним скрытым слоем, поэтому для неё и говорят о ландшафте функции потерь.

Пример. Прямая по точкам из раздела о задачах оптимизации: $L(w) = \frac{1}{m} \|Xw - y\|^2$, где $m = 3$ и $X = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$. Тогда $\nabla L(w) = \frac{2}{m} X^\top (Xw - y)$ и $H_L = \frac{2}{m} X^\top X = \begin{pmatrix} 2 & 2 \\ 2 & \frac{10}{3} \end{pmatrix}$ — одна и та же матрица при любом w . Её элемент H_{11} положителен и $\det H_L = \frac{8}{3} > 0$, поэтому $H_L \succ 0$ и L строго выпукла. Условие $\nabla L = 0$ — это **нормальное уравнение** $X^\top Xw = X^\top y$, здесь $\begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix} w = (7; 10)$, и его решение $w^* = (\frac{5}{6}; \frac{3}{2})$ — единственная точка глобального минимума, $L(w^*) = \frac{1}{18}$. При коллинеарных признаках матрица $X^\top X$ вырождена, H_L лишь полуопределён и точка минимума перестаёт быть единственной; регуляризационное слагаемое $\rho \|w\|^2$ добавляет к H_L матрицу $2\rho I$.

Почему. Для выпуклой функции потерь метод, который довёл градиент до нуля, нашёл ответ; для невыпуклой — лишь кандидата.

9 От доски к клавиатуре

У каждого утверждения семинара есть короткий численный двойник. Хватает двух функций: независимой проверки формулы градиента и теста второго порядка с допуском; с них начинается домашняя практика Н4. Ноутбук этого семинара проверяет каждое число конспекта двумя независимыми вычислениями.

9.1 Проверка градиента: центральные разности

```
def central_diff(f, x, h=1e-5):
    """Gradient by central differences: an independent check of an analytic formula."""
    x = np.asarray(x, dtype=float)
    g = np.empty_like(x)
    for j in range(x.size):
        e = np.zeros_like(x)
        e[j] = h
        g[j] = (f(x + e) - f(x - e)) / (2 * h)
    return g
```

Функция `central_diff` приближает каждую частную производную центральной разностью

$$\frac{\partial f}{\partial x_j}(x) \approx \frac{f(x + he_j) - f(x - he_j)}{2h},$$

ошибка которой имеет порядок h^2 ; здесь e_j — j -й координатный вектор.

- **Проверка должна быть независимой:** если разность повторно использует части аналитического градиента, она проверяет саму себя.
- **У шага есть оптимум:** ошибка аппроксимации $\sim h^2$ конкурирует с ошибкой округления $\sim \varepsilon_{\text{маш}}/h$, поэтому лучший шаг $h \sim \varepsilon_{\text{маш}}^{1/3} \approx 6 \cdot 10^{-6}$ при $\varepsilon_{\text{маш}} \approx 2,2 \cdot 10^{-16}$; отсюда значение по умолчанию $h = 10^{-5}$.
- **Симметризируйте** численный гессиан перед вызовом `eigvalsh`: эта функция читает только один треугольник матрицы.

Пример. Для функции из лекции в точке (1; 1) функция `central_diff` возвращает (11; 12) с ошибкой меньше 10^{-8} , что согласуется с формулой для ∇f .

9.2 Классификация гессиана с допуском

```
def classify(H, rel_tol=1e-9):
    """Second-order test for a symmetric matrix: "min", "max", "saddle" or "
    inconclusive".

    It reads the matrix only, so call it at a stationary point. The tolerance is
    relative to the largest |eigenvalue|.
    """
    H = np.asarray(H, dtype=float)
    w = np.linalg.eigvalsh(0.5 * (H + H.T))
    tol = rel_tol * np.abs(w).max(initial=0.0)
    if np.all(w > tol):
        return "min"
    if np.all(w < -tol):
        return "max"
    if w.min() < -tol and w.max() > tol:
        return "saddle"
    return "inconclusive"
```

`classify` определяет знаки собственных значений симметризованной матрицы с допуском относительно наибольшего по модулю собственного значения, поэтому умножение матрицы на положительное число не меняет ответ. У матрицы, которая равна нулю с точностью до округления, масштаба нет: стройте гессианы точно, вручную или с помощью `sympy`, и только потом вызывайте функцию; гессиан функции $f_1 = x_1^4 + x_2^4$ в начале координат, найденный конечными разностями, классифицируется как "min".

Матрица	Откуда она	Ответ
$\begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$	задача B1, начало координат	"min" (минимум)
$\begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$	задача B2, начало координат	"saddle" (седло)
$\begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$	задачи B3 и B4, начало координат	"inconclusive" (тест молчит)
$\begin{pmatrix} 0 & 0 \\ 0 & 2 \end{pmatrix}$	домашняя практика H1, начало координат	"inconclusive" (тест молчит)
$\begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix}$	ловушка Сильвестра	"inconclusive" (тест молчит)
$\begin{pmatrix} 36 & -4 \\ -4 & 16 \end{pmatrix}$	задача A2, точка (2; -1)	"min" (минимум)

Ловушка. `classify` смотрит на матрицу, а не на точку. Для функции из задачи A2 в точке $(2; -1)$ она возвращает "min", потому что $H = \begin{pmatrix} 36 & -4 \\ -4 & 16 \end{pmatrix} \succ 0$, хотя $\nabla f = (38; -16) \neq 0$: точка даже не стационарна. Сначала проверяйте градиент.

Ловушка. Не записывайте проверку седла цепочкой сравнений `w.min() < -tol < w.max()`. Она означает `w.min() < -tol and -tol < w.max()`, а это верно и тогда, когда наибольшее собственное значение равно 0: отрицательно полуопределённую матрицу `diag(0, -1)` такая проверка назвала бы седлом. Для седла нужно `w.min() < -tol and w.max() > tol`.

Два ответа "inconclusive" для B3 и B4 — не слабость кода: по одним лишь ∇f и H математика решить не может (подробнее — в подразделе о зазоре между полуопределённостью и определённостью).

10 Вопросы, которые задают студенты

Зачем нужны необходимые условия, если они ничего не доказывают?

Они превращают бесконечный поиск в конечный: вместо того чтобы перебирать все допустимые точки, решите систему $\nabla f = 0$ и проверьте найденных кандидатов. Точка, которая нарушает необходимое условие, отбрасывается сразу. Численные методы следуют той же идее: любой градиентный метод первой части курса ведёт ∇f к нулю.

Почему бы просто не посмотреть на график?

При $n \leq 2$ можно, и рисунки этого конспекта так и делают. У линейной модели с 50 весами или у нейронной сети, где параметров около 10^9 , графика уже не увидать, а формулы работают в любой размерности. Даже на плоскости картинка может обмануть: без подписанных уровней яма и холм выглядят одинаково. Картинка даёт интуицию, а доказательство — это оценка или сужение на прямую.

Гессиан всегда симметричен?

Для функций этого курса да: по теореме Шварца смешанные вторые производные равны, если они непрерывны, а контрпримеры требуют разрывных вторых производных. В коде всё равно симметризируйте матрицу: у численного гессиана элементы H_{ij} и H_{ji} расходятся в последних знаках, а `eigvalsh` читает только один треугольник.

Что значит $o(\alpha)$ и можно ли обойтись без него?

«О малое» — точный способ сказать «ошибка, которой можно пренебречь при малых α », и достаточно точный, чтобы выводить из него теоремы: $g(\alpha) = o(\alpha)$ означает, что $g(\alpha)/\alpha \rightarrow 0$ при $\alpha \rightarrow 0$. Например, запись $f(x+h) = f(x) + \nabla f(x)^\top h + o(\|h\|)$ говорит, что ошибка линейного приближения стремится к нулю быстрее, чем $\|h\|$. Без него все утверждения были бы приближёнными.

11 Задачи семинара

Все одиннадцать задач с полными решениями, по четырём блокам семинара. В каждом блоке первая задача разбирается на занятии, остальные — для самостоятельного решения.

11.1 А. Градиенты и гессианы

А1. Градиент и гессиан квадратичной функции

Частные производные по слагаемым; смешанное слагаемое в обоих внедиагональных элементах

Условие. Пусть $f(x) = x_1^2 + x_2^2 - x_1x_2$. **а)** До вычислений: будет ли гессиан H зависеть от точки? **б)** Найдите ∇f и H в произвольной точке и в точке $(1; 1)$. **в)** Является ли $(1; 1)$ кандидатом в точку минимума?

Решение.

1. Дифференцируйте по слагаемым. По x_1 : x_1^2 даёт $2x_1$, x_2^2 не даёт ничего, $-x_1x_2$ даёт $-x_2$. Итак, $\partial f/\partial x_1 = 2x_1 - x_2$ и точно так же $\partial f/\partial x_2 = 2x_2 - x_1$.

2. Вторые производные:

$$H = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}.$$

Переменных не осталось: гессиан квадратичной функции постоянен. Смешанное слагаемое $-x_1x_2$ даёт -1 в **оба** внедиагональных элемента.

3. В точке $(1; 1)$: $\nabla f = (1; 1) \neq 0$. Точка не стационарна, поэтому она не кандидат в точку безусловного минимума, что бы ни говорил H .

4. Собственные значения — корни уравнения $\lambda^2 - 4\lambda + 3 = 0$: $\lambda = 1$ и $\lambda = 3$. Оба положительны в каждой точке, поэтому f строго выпукла, а её единственная точка минимума — решение уравнения $\nabla f = 0$: $x^* = (0; 0)$.

5. Две записи одной функции: $f = \frac{1}{2}x^\top Hx$ с самим H или $f = x^\top Ax$ с $A = \begin{pmatrix} 1 & -\frac{1}{2} \\ -\frac{1}{2} & 1 \end{pmatrix}$, у которой внедиагональный элемент равен $-\frac{1}{2}$; $H = A + A^\top$. Неверные гессианы получаются именно от смешения этих записей.

Ответ. $\nabla f = (2x_1 - x_2; 2x_2 - x_1)^\top$, $H = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$ во всех точках; $\nabla f(1; 1) = (1; 1) \neq 0$, поэтому $(1; 1)$ не кандидат.

А2. Гессиан меняется от точки к точке

Подстановка со знаками; кривизна неквадратичной функции локальна

Условие. Для функции из лекции $f(x) = 3x_1^3 + 2x_1x_2^2 + 4x_2^2$ найдите ∇f , H и $\det H$ в точке $(2; -1)$. Сравните с $\det H = 200$ в точке $(1; 1)$. Стационарна ли точка $(2; -1)$?

Решение.

1. Продифференцируйте: $\partial f/\partial x_1 = 9x_1^2 + 2x_2^2$, $\partial f/\partial x_2 = 4x_1x_2 + 8x_2$ и

$$H(x) = \begin{pmatrix} 18x_1 & 4x_2 \\ 4x_2 & 4x_1 + 8 \end{pmatrix}.$$

2. Не прячьте числа: $\partial f/\partial x_1 = 9 \cdot 2^2 + 2 \cdot (-1)^2 = 38$ и $\partial f/\partial x_2 = 4 \cdot 2 \cdot (-1) + 8 \cdot (-1) = -16$ — сумма двух отрицательных слагаемых. $H(2; -1) = \begin{pmatrix} 36 & -4 \\ -4 & 16 \end{pmatrix}$: оба внедиагональных элемента отрицательны.

3. $\det H = 36 \cdot 16 - (-4)^2 = 560$ против 200 в точке $(1; 1)$. У неквадратичной функции кривизна — локальный объект.

4. Нет: $\nabla f(2; -1) = (38; -16) \neq 0$, так что точка не стационарна. $H \succ 0$ ($\Delta_1 = 36 > 0$, $\Delta_2 = 560 > 0$) ничего не говорит об оптимальности в нестационарной точке.

Ответ. $\nabla f = (38; -16)$, $H = \begin{pmatrix} 36 & -4 \\ -4 & 16 \end{pmatrix}$, $\det H = 560$; точка не стационарна.

А3. Три переменные и критерий Сильвестра

Гессиан три на три, угловые миноры, минимум выпуклой квадратичной функции

Условие. Пусть $f(x) = x_1^2 + 2x_2^2 + 3x_3^2 + 2x_1x_2 - x_2x_3$ на $\mathbb{R}^3$. **а)** Найдите ∇f и H . **б)** По критерию Сильвестра выясните, верно ли $H \succ 0$. **в)** Что это говорит о выпуклости? Где минимум и единствен ли он?

Решение.

1. На диагонали стоят удвоенные коэффициенты при квадратах, (2; 4; 6). Слагаемое $2x_1x_2$ даёт $H_{12} = H_{21} = 2$, слагаемое $-x_2x_3$ даёт $H_{23} = H_{32} = -1$, а x_1 и x_3 вместе нигде не встречаются, поэтому $H_{13} = 0$:

$$\nabla f = \begin{pmatrix} 2x_1 + 2x_2 \\ 2x_1 + 4x_2 - x_3 \\ 6x_3 - x_2 \end{pmatrix}, \quad H = \begin{pmatrix} 2 & 2 & 0 \\ 2 & 4 & -1 \\ 0 & -1 & 6 \end{pmatrix}.$$

2. $\Delta_1 = 2$, $\Delta_2 = 2 \cdot 4 - 2 \cdot 2 = 4$ и, разложением по первой строке, $\Delta_3 = 2(4 \cdot 6 - 1) - 2(2 \cdot 6 - 0) + 0 = 46 - 24 = 22$.
3. Все угловые миноры положительны, значит, $H \succ 0$. Гессиан одинаков во всех точках, поэтому f строго выпукла на $\mathbb{R}^3$.
4. Решите $\nabla f = 0$: $x_1 = -x_2$, $x_2 = 6x_3$, $x_3 = 2x_2$, откуда $x_2 = 6x_3 = 12x_2$, значит, $x_2 = 0$, а затем $x_3 = x_1 = 0$. Единственная стационарная точка $x^* = (0; 0; 0)$ — точка глобального минимума в силу выпуклости.

Ответ. $H = \begin{pmatrix} 2 & 2 & 0 \\ 2 & 4 & -1 \\ 0 & -1 & 6 \end{pmatrix}$, $\Delta = (2; 4; 22)$, поэтому $H \succ 0$ и f строго выпукла; единственная точка глобального минимума — $x^* = (0; 0; 0)$.

11.2 В. Классификация стационарных точек

В1. Чаша: сначала локально, затем отдельно глобально

Полный порядок действий: стационарная точка, гессиан, достаточное условие, отдельное обоснование глобальности

Условие. Пусть $f(x) = x_1^2 + x_2^2$. **а)** Найдите все стационарные точки. **б)** Найдите H и определите его знакоопределённость. **в)** Каким условием вы воспользовались: необходимым или достаточным? **г)** Глобальный ли это минимум и чем именно это обосновано?

Решение.

1. $\nabla f = (2x_1; 2x_2)^T = 0$ только в точке $x^* = (0; 0)$.
2. $H = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$, $\Delta_1 = 2 > 0$ и $\Delta_2 = 4 > 0$, поэтому $H \succ 0$.

3. $\nabla f(x^*) = 0$ и $H(x^*) \succ 0$: применимо **достаточное** условие, и оно даёт **строгий локальный** минимум, не больше.
4. Для глобальности нужна ещё одна фраза: либо выпуклость ($H \succeq 0$ во всех точках), либо прямо $f(x) = x_1^2 + x_2^2 \geq 0 = f(x^*)$, причём равенство достигается только в x^* .
5. Собственные значения 2 и 2 равны: кривизна одинакова по всем направлениям, и линии уровня — окружности. Градиентный спуск с шагом $\frac{1}{2}$ приходит в x^* за один шаг из любой точки x : $x - \frac{1}{2}\nabla f(x) = 0$.

Ответ. Единственная стационарная точка — $x^* = (0; 0)$; $H \succ 0$ даёт строгий локальный минимум по достаточному условию; он глобальный, потому что $f \geq 0 = f(x^*)$ (или в силу выпуклости).

В2. Седло: доказательство без картинки

Знаконеопределённый гессиан; сужение на две прямые как доказательство

Условие. Пусть $f(x) = x_1^2 - x_2^2$. Покажите, не опираясь на картинку, что $(0; 0)$ — стационарная точка, не являющаяся ни минимумом, ни максимумом.

Решение.

1. $\nabla f = (2x_1; -2x_2)^\top$ обращается в нуль только в начале координат, и $H = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$.
2. $\Delta_1 = 2 > 0$ и $\Delta_2 = -4 < 0$: ни один. Раз $\det H < 0$, собственные значения -2 и 2 разных знаков, и гессиан знаконеопределён.
3. Доказательство — сужение f на две оси: $f(t, 0) = t^2 > 0$ и $f(0, t) = -t^2 < 0$ при $t \neq 0$. В любой окрестности начала координат есть значения и больше, и меньше $f(0, 0) = 0$: это седло.
4. Вдоль прямой под углом θ : $f(t \cos \theta, t \sin \theta) = t^2 \cos 2\theta$; это выражение тождественно равно нулю при $\theta = 45^\circ; 135^\circ$ и имеет разные знаки по разные стороны от этих прямых. Картинка — подсказка, а доказательство — два сужения.

Ответ. $\Delta_1 = 2$, $\Delta_2 = -4$, гессиан знаконеопределён; $f(t, 0) = t^2$ и $f(0, t) = -t^2$, поэтому начало координат — седло.

В3. Обезьянье седло

Нулевой гессиан: все условия оптимальности молчат, решает определение

Условие. Пусть $f(x) = x_1^3 - 3x_1x_2^2$. **а)** Найдите все стационарные точки. **б)** Вычислите гессиан в начале координат. **в)** Примените условия оптимальности: что они говорят? **г)** Найдите направление, которое решает вопрос.

Решение.

1. $\partial f / \partial x_1 = 3x_1^2 - 3x_2^2$, $\partial f / \partial x_2 = -6x_1x_2$. Разбор случаев: $-6x_1x_2 = 0$ даёт $x_1 = 0$ или $x_2 = 0$, и в каждом случае первое уравнение обнуляет другую координату. Единственная стационарная точка — начало координат.
2. $H(x) = \begin{pmatrix} 6x_1 & -6x_2 \\ -6x_2 & -6x_1 \end{pmatrix}$, поэтому $H(0, 0) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$ — нулевая матрица.

3. Нулевая матрица $\succeq 0$, поэтому необходимое условие минимума выполнено; она же $\preceq 0$, так что выполнено и необходимое условие максимума. Достаточное условие требует $H \succ 0$ и неприменимо, а все $\Delta_k = 0$, так что критерий Сильвестра молчит. Молчат все инструменты.
4. Воспользуйтесь определением вдоль прямой: $f(t, 0) = t^3$ положительна при $t > 0$ и отрицательна при $t < 0$. В любой окрестности начала координат есть значения и больше, и меньше: ни минимум, ни максимум.
5. Почему «обезьянье»: в полярных координатах $f = r^3 \cos 3\varphi$, поэтому знак чередуется в шести секторах по 60° , три вверх и три вниз: две ложбины для ног и одна для хвоста. Вдоль $\theta = 30^\circ; 90^\circ; 150^\circ$ функция тождественно равна нулю, и эти прямые ничего не решают.

Ответ. Единственная стационарная точка — начало координат; $H(0) = 0$, и тест второго порядка не даёт вердикта; $f(t, 0) = t^3$ меняет знак, поэтому начало координат — ни минимум, ни максимум.

В4. Те же данные, противоположный ответ

Прямая оценка решает там, где тест второго порядка бессильен

Условие. Пусть $f(x) = x_1^4 + x_2^4$. **а)** Найдите стационарные точки и $H(0, 0)$. **б)** Что говорит тест второго порядка? **в)** Решите вопрос одной строкой. **г)** Сравните с В3: что совпадает и что различается?

Решение.

1. $\nabla f = (4x_1^3; 4x_2^3)^\top = 0$ только в начале координат, $H(x) = \begin{pmatrix} 12x_1^2 & 0 \\ 0 & 12x_2^2 \end{pmatrix}$, поэтому снова $H(0, 0) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$.
2. Тест второго порядка снова молчит: необходимые условия выполнены, а достаточное неприменимо.
3. Одна строка: $f(x) = x_1^4 + x_2^4 \geq 0 = f(0, 0)$, причём равенство достигается только в начале координат. **Строгий глобальный** минимум, и никакие теоремы не нужны.
4. У В3 и В4 одинаковые $\nabla f(0)$ и $H(0)$, а ответы противоположные. Когда $H(0)$ вырожден и полуопределён, тест второго порядка заведомо не может решить вопрос: две функции с одинаковыми данными первого и второго порядка ведут себя по-разному.

Ответ. $H(0, 0) = 0$, и тест молчит; $f \geq 0 = f(0, 0)$, причём равенство только в начале координат, поэтому это строгий глобальный минимум. У В3 те же $\nabla f(0)$ и $H(0)$, но экстремума нет.

11.3 С. Выпуклость

С1. Круг выпукл: доказательство по определению

Доказательство выпуклости с обоснованием каждой строки

Условие. Пусть $\Omega = \{x \in \mathbb{R}^2 : x_1^2 + x_2^2 \leq 4\}$. **а)** Докажите по определению, что Ω выпукло. **б)** Какие свойства нормы использованы? **в)** Годится ли рассуждение для квадрата? Для кольца?

Решение.

1. Перепишите множество как шар: $\Omega = \{x : \|x\| \leq 2\}$. Возьмите $x, y \in \Omega$, $\lambda \in [0, 1]$ и $z = \lambda x + (1 - \lambda)y$.

2.

$$\|z\| \stackrel{(1)}{\leq} \|\lambda x\| + \|(1 - \lambda)y\| \stackrel{(2)}{=} \lambda\|x\| + (1 - \lambda)\|y\| \leq 2\lambda + 2(1 - \lambda) = 2,$$

где (1) — неравенство треугольника, а (2) — однородность; λ и $1 - \lambda$ неотрицательны, поэтому модули не появляются. Значит, $z \in \Omega$. ■

3. Доказательство использовало только неравенство треугольника и однородность — ничего об окружностях, размерности или гладкости. Поэтому выпукл любой шар в любой норме, включая ромб ℓ_1 и квадрат ℓ_∞ , у которых есть углы.

4. Кольцо $\{1 \leq \|x\| \leq 2\}$ не выпукло: точки $(-1, 5; 0)$ и $(1, 5; 0)$ лежат в нём, а их середина $(0; 0)$ — в дыре.

Ответ. Выпукло — по неравенству треугольника и однородности; то же доказательство годится для квадрата ℓ_∞ , а кольцо не выпукло.

С2. Важна величина смешанного слагаемого

Выпуклость квадратичной функции по одной постоянной матрице; однопараметрическое семейство

Условие. а) Выпукла ли $f(x) = x_1^2 + x_2^2 - 4x_1x_2$ на $\mathbb{R}^2$? б) Сравните с А1, где коэффициент смешанного слагаемого был -1 . в) При каких a функция $f_a(x) = x_1^2 + x_2^2 + a x_1x_2$ выпукла, а при каких строго выпукла?

Решение.

1. $H = \begin{pmatrix} 2 & -4 \\ -4 & 2 \end{pmatrix}$ во всех точках; $\Delta_1 = 2 > 0$ и $\Delta_2 = 2 \cdot 2 - (-4)^2 = -12 < 0$.

2. $\Delta_2 = \det H < 0$, поэтому собственные значения -2 и 6 разных знаков и гессиан знако-неопределён (одного того, что ни один шаблон Сильвестра не выполнен, было бы мало). Условие $H \succeq 0$ не выполнено ни в одной точке, поэтому f не выпукла.

3. Семейство: $H_a = \begin{pmatrix} 2 & a \\ a & 2 \end{pmatrix}$ с собственными значениями $2 \pm a$. Выпукла $\iff$ оба $\geq 0 \iff |a| \leq 2$; строго выпукла $\iff |a| < 2$ — у квадратичной функции обратное к критерию второго порядка тоже верно, а что происходит при $|a| = 2$, показывает следующий шаг.

4. $f = (x_1 + x_2)^2$: выпукла, но не строго, собственные значения равны 0 и 4 , и вся прямая $x_1 + x_2 = 0$ состоит из точек минимума. В А1 было $a = -1$ (собственные значения 1 и 3 , выпукла); здесь $a = -4$: решает величина смешанного слагаемого, а не его знак.

Ответ. $\Delta_2 = -12$, собственные значения -2 и 6 : не выпукла. f_a выпукла при $|a| \leq 2$ и строго выпукла при $|a| < 2$.

11.4 D. Допустимые направления

D1. Оптимальность на границе

Активные ограничения, множество допустимых направлений и одно нарушающее направление

Условие. Пусть $\Omega = \{x : x_1 \geq 0, x_2 \geq 0\}$, $f(x) = x_1 + x_2$ и $x = (0; 2)$. а) Какие ограничения активны в x ? б) Опишите все допустимые направления в x . в) Проверьте необходимое условие первого порядка $s^\top \nabla f(x) \geq 0$. г) Если оно нарушено, предъявите нарушающее направление.

Решение.

1. $x_1 = 0$: ограничение $x_1 \geq 0$ **активно**. $x_2 = 2 > 0$: ограничение $x_2 \geq 0$ неактивно, запас есть в обе стороны.
2. Допустимые направления — $\{s \neq 0 : s_1 \geq 0\}$, s_2 любое. Если $s_1 < 0$, то $x_1 + \alpha s_1 < 0$ при любом $\alpha > 0$. Если $s_1 \geq 0$, первая координата остаётся неотрицательной, а $x_2 + \alpha s_2 > 0$ при всех $\alpha \in [0, \alpha_0]$, например при $\alpha_0 = 1/|s_2|$, если $s_2 < 0$ (при $s_2 \geq 0$ подходит любое $\alpha_0 > 0$).
3. $\nabla f \equiv (1; 1)$, поэтому проверять нужно условие $s^\top \nabla f = s_1 + s_2 \geq 0$ для **каждого** допустимого s .
4. Возьмите $s = (0; -1)$: оно допустимо, и $s^\top \nabla f = -1 < 0$. Условие нарушено, поэтому $(0; 2)$ не кандидат. Движение вниз вдоль границы уменьшает f вплоть до угла $(0; 0)$, где $f = 0$: это и есть точка минимума.
5. Чтобы отвергнуть точку, достаточно одного нарушающего направления; чтобы принять её, проверку должно пройти каждое допустимое направление. Заменить эту бесконечную проверку конечным числом множителей — идея условий ККТ на следующем семинаре.

Ответ. Активно только $x_1 \geq 0$; допустимые направления — $\{s \neq 0 : s_1 \geq 0\}$; $s = (0; -1)$ даёт $s^\top \nabla f = -1 < 0$, поэтому $(0; 2)$ не кандидат.

D2. Производная по направлению двумя способами

Определение через предел и формула $s^\top \nabla f$; скорость на единицу α и на единицу длины

Условие. Пусть $f(x) = x_1^2 + 2x_2^2$, $x = (1; 1)$ и $s = (1; -1)$. **а)** Найдите $\partial f / \partial s(x)$ по определению, через предел. **б)** Найдите её ещё раз как $s^\top \nabla f(x)$. **в)** Является ли s направлением спуска? **г)** Ваше число — скорость на единицу α или на единицу длины?

Решение.

1. $x + \alpha s = (1 + \alpha; 1 - \alpha)$, поэтому $f(x + \alpha s) = (1 + \alpha)^2 + 2(1 - \alpha)^2 = 3 - 2\alpha + 3\alpha^2$, а $f(x) = 3$ — значение этого выражения при $\alpha = 0$.
2.

$$\frac{\partial f}{\partial s}(x) = \lim_{\alpha \rightarrow 0^+} \frac{f(x + \alpha s) - f(x)}{\alpha} = \lim_{\alpha \rightarrow 0^+} (-2 + 3\alpha) = -2.$$

Предел односторонний, потому что в граничной точке может быть разрешено только $\alpha \geq 0$; в этой внутренней точке оба односторонних предела совпадают.
3. $\nabla f = (2x_1; 4x_2)^\top$, поэтому $\nabla f(x) = (2; 4)$ и $s^\top \nabla f(x) = 1 \cdot 2 + (-1) \cdot 4 = -2$: оба способа дают одно и то же.
4. Значение отрицательно, так что s — направление спуска. Но $\|s\| = \sqrt{2}$, поэтому -2 — скорость на единицу α ; на единицу длины она равна $-\sqrt{2} \approx -1,4142$.
5. Направление наискорейшего убывания — $-\nabla f(x) / \|\nabla f(x)\|$, скорость вдоль него равна $-\|\nabla f(x)\| = -2\sqrt{5} \approx -4,4721$ на единицу длины, в $\sqrt{10} \approx 3,1623$ раза больше по модулю, чем вдоль $s / \|s\|$. Поэтому методы спуска шагают против градиента.

Ответ. $f(x + \alpha s) = 3 - 2\alpha + 3\alpha^2$, оба способа дают -2 на единицу α ; на единицу длины $-\sqrt{2}$; s — направление спуска.

12 Домашняя практика

Четыре задачи для дома: три на бумаге и одна в коде. После каждой идёт полное решение, поэтому сначала попробуйте решить её сами.

Н1. Вырожденный, но ненулевой гессиан

На бумаге

Условие. Найдите стационарные точки $f(x) = x_1^3 + x_2^2$ и классифицируйте их.

Решение.

1. $\nabla f = (3x_1^2; 2x_2)^\top = 0$ только в начале координат.
2. $H(x) = \text{diag}(6x_1, 2)$, поэтому $H(0) = \begin{pmatrix} 0 & 0 \\ 0 & 2 \end{pmatrix}$ с собственными значениями 0 и 2: положительно полуопределён, но не положительно определён. Необходимое условие выполнено, достаточное неприменимо.
3. Вдоль $x_2 = 0$: $f(t, 0) = t^3$ меняет знак, поэтому начало координат — ни минимум, ни максимум. Сравните с ВЗ: там $H(0) = 0$; здесь $H(0)$ не нулевая матрица, но вырожденная, а вывод тот же.

Ответ. Единственная стационарная точка — начало координат; собственные значения $H(0)$ равны 0 и 2; ни минимум, ни максимум.

Н2. Минимумы семейства квадратичных функций

На бумаге

Условие. Пусть $f_a(x) = x_1^2 + x_2^2 + ax_1x_2$. **а)** При $a = 5$ найдите собственные значения H_a и значение $f_a(1; -1)$. **б)** При каких a у f_a единственная точка минимума? **в)** Опишите все точки минимума при $a = 2$.

Решение.

1. Характеристический многочлен равен $\lambda^2 - 4\lambda + 4 - a^2$, поэтому собственные значения равны $2 \pm a$. При $a = 5$ это -3 и 7 , а $f_a(1; -1) = -3 < 0 = f_a(0)$. Так как $f_a(tx) = t^2 f_a(x)$, вдоль этого направления f_a неограниченно убывает.
2. $|a| < 2$: $H_a \succ 0$, f_a строго выпукла, и начало координат — единственная точка минимума. $|a| > 2$: H_a знаконеопределён и f_a не ограничена снизу, поэтому точек минимума нет.
3. $a = 2$: $f = (x_1 + x_2)^2 \geq 0$, и точки минимума заполняют всю прямую $x_1 + x_2 = 0$ (при $a = -2$ — прямую $x_1 = x_2$).

Ответ. При $a = 5$: собственные значения -3 и 7 , $f_a(1; -1) = -3$. Единственная точка минимума есть ровно при $|a| < 2$; при $a = 2$ точки минимума образуют прямую $x_1 + x_2 = 0$.

Н3. Допустимые направления в угловой точке

На бумаге

Условие. Для $\Omega = \{x : x_1 \geq 0, x_2 \geq 0\}$ и $f(x) = x_1 + x_2$ опишите допустимые направления в точке $x = (0; 0)$ и проверьте там необходимое условие первого порядка.

Решение.

1. Активны оба ограничения, поэтому допустимые направления — $\{s \neq 0 : s_1 \geq 0, s_2 \geq 0\}$.
2. $s^\top \nabla f = s_1 + s_2 > 0$ для каждого такого s : условие выполнено. По допустимым единичным направлениям наименьшая скорость равна 1 и достигается вдоль сторон.
3. И действительно, $f \geq 0$ на Ω , а в углу $f = 0$, так что угол — точка минимума. Сравните с D1, где неактивное ограничение оставляло место для нарушающего направления.

Ответ. Активны оба ограничения; допустимые направления — $s \neq 0$ с $s_1 \geq 0$ и $s_2 \geq 0$; условие выполнено, и угол — точка минимума.

Н4. Тест второго порядка в коде

В коде

Условие. С помощью `classify` из блока В проверьте гессианы сегодняшних задач в их точках: A1, A2 в точке $(2; -1)$, A3, B1, B2, B3 и B4 в начале координат, C2, H1 в начале координат и пару $\text{diag}(0, -1)$, $\text{diag}(0, 1)$. Где ответ "inconclusive" и почему A2 получает "min"?

Решение.

1. Постройте каждый гессиан точно (вручную или с помощью `sympy`) как массив `numpy` и вызовите `classify(H)`.
2. Метки: "min" — 4 раза (A1, A2, A3, B1), "saddle" — 2 раза (B2, C2), "inconclusive" — 5 раз (B3, B4, H1 и обе диагональные матрицы).
3. Ни один из ответов "inconclusive" не ошибка: тест второго порядка там действительно ничего не может решить. Версия с цепочкой сравнений `w.min() < -tol < w.max()` называет $\text{diag}(0, -1)$ седлом; тест должен требовать отрицательное **и** положительное собственное значение. С гессианом, вычисленным конечными разностями, дело обстоит иначе: для B4 в начале координат это крошечная положительная диагональная матрица, и `classify` отвечает "min"; никакое правило допуска не отличит точный нуль от крошечного положительного числа без масштаба, взятого из задачи.
4. A2 получает "min", потому что `classify` смотрит только на матрицу: $H(2; -1) \succ 0$, но точка не стационарна, так что метка там ничего не значит.

Ответ. "inconclusive" для B3, B4, H1, $\text{diag}(0, -1)$ и $\text{diag}(0, 1)$; A2 получает "min", потому что функция смотрит только на H , а точка не стационарна.

13 Типичные ошибки

Ошибки, которые повторяются из раза в раз: сначала по темам, затем из задач семинара.

13.1 Градиенты и гессианы

- Смешанное слагаемое $sx_i x_j$ даёт s в оба элемента H_{ij} и H_{ji} . Если записать $s/2$ (элемент A в $f = x^\top A x$) или удвоить s , как на диагонали, гессиан получится неверным.
- Обсуждать гессиан в точке, не проверив там $\nabla f = 0$: в нестационарной точке $H \succ 0$ ничего не говорит об оптимальности.
- Считать гессиан кубической функции постоянным: одинаковый H во всех точках бывает только у квадратичной функции.

Из задач:

- **A1.** Писать вне диагонали -2 (удваивая коэффициент смешанного слагаемого, как на диагонали) или $-\frac{1}{2}$ (элемент A в записи $f = x^\top Ax$) либо ставить -1 только в один из двух элементов.
- **A1.** Обсуждать оптимальность в точке $(1; 1)$ по гессиану: градиент там не равен нулю.
- **A2.** Терять знак: при $x_2 < 0$ оба внедиагональных элемента отрицательны, а $\partial f / \partial x_2$ — сумма двух отрицательных слагаемых.
- **A2.** Объявлять минимум из-за $H \succ 0$ в точке, где $\nabla f \neq 0$.
- **A3.** Делить коэффициенты смешанных слагаемых пополам или записывать каждый из них только в один из двух симметричных элементов.
- **A3.** Называть стационарную точку глобальным минимумом без обоснования: здесь обоснование — выпуклость, из $H \succ 0$ во всех точках.

13.2 Классификация стационарных точек

- Делать вывод «знаконеопределена», раз ни один шаблон Сильвестра не выполнен: у $\text{diag}(0, -1)$ и $\text{diag}(0, 1)$ одинаковые угловые миноры, но первая матрица отрицательно полуопределена, а вторая положительно полуопределена.
- Принимать необходимое условие $H(x^*) \succeq 0$ за сертификат: у обезьяньего седла $H = 0$, а экстремума нет.
- Заявлять глобальный минимум по $\nabla f = 0$ и $H \succ 0$: достаточное условие даёт только строгий локальный минимум.
- Предъявлять картинку линий уровня как доказательство седла: доказательство — сужения на прямые.

Из задач:

- **V1.** Заявлять глобальный минимум только на основании $H(x^*) \succ 0$.
- **V2.** Предъявлять картинку линий уровня как доказательство: это лишь подсказка.
- **V3.** Делать вывод о минимуме из $H(0) = 0 \succeq 0$: так необходимое условие принимают за достаточное. Ради этой ошибки задача и существует.
- **V3.** Проверять только ось x_2 , где $f \equiv 0$, и решать, что ничего не происходит.
- **V4.** Списывать молчание теста на «невозмездие»: при вырожденном полуопределённом H данные первого и второго порядка не могут отличить V3 от V4.

13.3 Выпуклость

- Судить о выпуклости квадратичной функции по знаку смешанного слагаемого: решает его величина.
- Путать выпуклость с гладкостью: у ромба ℓ_1 есть углы, но он выпукл, а у кольца гладкая граница, но оно не выпукло.
- Доказывать выпуклость рисунком или несколькими отрезками, оставшимися внутри: годится только доказательство для всех пар.

Из задач:

- **C1.** Приводить рисунок вместо доказательства или цепочку неравенств без обоснования каждого шага.
- **C2.** Судить по знаку смешанного слагаемого: и в A1, и в C2 он отрицательный.
- **C2.** Делать вывод «знаконеопределён» только потому, что ни один шаблон Сильвестра не выполнен: здесь это доказывает отрицательный определитель.

13.4 Допустимые направления

- Объявлять в граничной точке допустимыми все направления или ни одного.
- Принимать граничную точку после проверки нескольких направлений: чтобы отвергнуть её, хватит одного нарушающего направления, а чтобы принять, нужно проверить все.
- Сравнивать производные по направлениям разной длины: сначала нормируйте, иначе самым крутым окажется самое длинное.

Из задач:

- **D1.** Объявлять допустимыми все направления или ни одного.
- **D1.** Проверять только направления внутрь множества и заключать, что условие выполнено.
- **D2.** Выдавать -2 за скорость на единицу длины: s не единичный вектор.
- **D2.** Забывать вычитать $f(x)$ перед делением на α : у отношения $f(x + \alpha s)/\alpha$ нет конечного предела.

14 Глоссарий

Английские термины семинара с кратким значением и их русские эквиваленты.

Английский	Русский	Значение
optimization problem	задача оптимизации	поиск наименьшего значения функции на множестве
objective function	целевая функция	минимизируемая функция; в машинном обучении — функция потерь
empirical risk	эмпирический риск	среднее значение функции потерь модели на обучающих данных
feasible set	допустимое множество	множество точек, среди которых ищется минимум
interior point	внутренняя точка	точка, которая лежит в множестве вместе с небольшим шаром вокруг неё
boundary point	граничная точка	точка множества, сколь угодно близко к которой есть точки вне множества
local minimum	локальный минимум	точка с наименьшим значением среди всех близких допустимых точек

Английский	Русский	Значение
global minimum	глобальный минимум	точка с наименьшим значением на всём допустимом множестве
strict minimum	строгий минимум	минимум, при котором любая другая допустимая точка даёт строго большее значение
minimizer	точка минимума	точка, в которой достигается минимум
stationary point	стационарная точка	точка, в которой градиент равен нулю
saddle point	седловая точка	стационарная точка, которая не является ни минимумом, ни максимумом
monkey saddle	обезьянье седло	седло с тремя секторами убывания вместо двух
level set	множество уровня (линия уровня)	множество точек, в которых функция принимает заданное значение
partial derivative	частная производная	производная по одной переменной при фиксированных остальных
gradient	градиент	вектор-столбец всех первых частных производных
Hessian	гессиан	матрица всех вторых частных производных
directional derivative	производная по направлению	скорость изменения функции при движении из точки вдоль направления
descent direction	направление спуска	направление, вдоль которого функция убывает уже в первом порядке
steepest descent direction	направление наискорейшего убывания	направление, противоположное градиенту
Taylor's formula	формула Тейлора	приближение гладкой функции многочленом вблизи точки
quadratic form	квадратичная форма	скалярное произведение векторов h и $A h$ для симметричной матрицы A
cross term	смешанное слагаемое	произведение двух разных переменных с коэффициентом
eigenvalue	собственное значение	коэффициент растяжения матрицы вдоль одного из её собственных векторов
positive definite matrix	положительно определённая матрица	симметричная матрица, квадратичная форма которой положительна на любом ненулевом векторе
positive semidefinite matrix	положительно полуопределённая матрица	симметричная матрица, квадратичная форма которой неотрицательна на любом векторе
indefinite matrix	знаконеопределённая матрица	симметричная матрица, квадратичная форма которой принимает значения обоих знаков
determinant	определитель	число $ad - bc$ для матрицы два на два, а в общем случае — произведение собственных значений
leading principal minor	угловой минор	определитель левого верхнего квадратного блока матрицы

Английский	Русский	Значение
principal minor	главный минор	определитель на наборе строк и том же наборе столбцов
Sylvester's criterion	критерий Сильвестра	симметричная матрица положительно определена тогда и только тогда, когда все её угловые миноры положительны
necessary condition	необходимое условие	условие, которому удовлетворяет любой минимум; если оно нарушено, точка отбрасывается
sufficient condition	достаточное условие	условие, которое гарантирует минимум
feasible direction	допустимое направление	направление, в котором малый шаг оставляет точку в допустимом множестве
active constraint	активное ограничение	неравенство, которое в данной точке выполняется как равенство
convex set	выпуклое множество	множество, которое содержит отрезок между любыми двумя своими точками
convex function	выпуклая функция	функция, график которой лежит не выше любой своей хорды
strictly convex function	строго выпуклая функция	выпуклая функция, для которой неравенство с хордой строгое при любых различных точках
condition number	число обусловленности	отношение наибольшего собственного значения положительно определённой матрицы к наименьшему
central difference	центральная разность	оценка производной по значениям функции в двух точках, симметричных относительно данной
tolerance	допуск	порог, ниже которого вычисленное число считается нулём

15 Литература

- [1] S. Boyd, L. Vandenberghe. *Convex Optimization*. Cambridge University Press. Главы о выпуклых множествах и выпуклых функциях и приложение с математическими сведениями: нормы, производные, приближение второго порядка и симметричные матрицы.
- [2] Андрей Игнатов. Лекции курса «Методы оптимизации», НИУ ВШЭ, факультет компьютерных наук: лекция «Оптимизация как основа машинного обучения».