Шпаргалка к семинару 3

# Градиентный спуск и автоматическое дифференцирование

**Методы оптимизации**
НИУ ВШЭ, факультет компьютерных наук, 2026–2027
Лектор курса: Андрей Игнатов
Автор: Евгений Баулин, Telegram @tarakan_tuc

## Неравенство Йенсена

- **Выпуклая** $f$ на выпуклом множестве: $f\big((1-t)x+ty\big) \le (1-t)f(x)+tf(y)$ для всех $x, y$ и $t \in [0,1]$; хорда лежит не ниже графика, производные не нужны. **Строго выпуклая**: неравенство строгое при $x \neq y$, $t \in (0,1)$. Для $x^2$ зазор равен $t(1-t)(x-y)^2$.
- **Три равносильных критерия** (множество открытое и выпуклое): хорда (определение); касательная $f(y) \ge f(x) + \nabla f(x)^\top (y-x)$ для дифференцируемой $f$; кривизна $\nabla^2 f(x) \succeq 0$ для дважды дифференцируемой $f$. Из $\nabla^2 f \succ 0$ всюду следует строгая выпуклость, обратное неверно: $|x|^3$.
- **Веса** $t_i \ge 0$, $\sum_i t_i = 1$: $f\big(\sum_i t_i x_i\big) \le \sum_i t_i f(x_i)$; также $f(\mathbb{E}X) \le \mathbb{E} f(X)$; для вогнутой функции наоборот: $\log \mathbb{E}X \ge \mathbb{E} \log X$. **Одна пара опровергает** выпуклость: у $x^3$ при $x=-2$, $y=1$, $t=0{,}5$ график $(-0{,}125)$ выше хорды $(-3{,}5)$.

## Константы $\mu$, $L$ и $\kappa$

- $\mu$**-сильно выпуклая**: $f - \frac{\mu}{2}\|\cdot\|^2$ выпукла, или $\nabla^2 f \succeq \mu I$. $L$**-гладкая**: $\|\nabla f(x) - \nabla f(y)\| \le L\|x-y\|$, или $-LI \preceq \nabla^2 f \preceq LI$.
- **Две параболы**: $\frac{\mu}{2}\|y-x\|^2 \le f(y) - f(x) - \nabla f(x)^\top (y-x) \le \frac{L}{2}\|y-x\|^2$. В форме Йенсена зазор между хордой и графиком лежит между $\frac{\mu}{2}t(1-t)\|x-y\|^2$ и $\frac{L}{2}t(1-t)\|x-y\|^2$.
- **Квадратичная** $f = \frac{1}{2}x^\top Q x - b^\top x$, $Q \succ 0$: $\nabla f = Qx - b$, $\mu = \lambda_{\min}(Q)$, $L = \lambda_{\max}(Q)$. **Число обусловленности** $\kappa = L/\mu \ge 1$; большое $\kappa$ — длинная узкая долина.
- **Условие Поляка–Лоясевича** (PL): $\frac{1}{2}\|\nabla f(x)\|^2 \ge \mu\big(f(x) - f^*\big)$ для всех $x$. Оно следует из $\mu$-сильной выпуклости, и при нём любая стационарная точка — точка глобального минимума; выпуклость для него не нужна $(x^2 + 3\sin^2 x)$ и не достаточна $(x^4)$.

## Градиентный спуск

- **Итерация** $x_{k+1} = x_k - \alpha \nabla f(x_k)$ вдоль направления наискорейшего спуска $-\nabla f(x_k)$; $d$ — направление спуска, если $\nabla f(x)^\top d < 0$.
- **Лемма о спуске** ($L$-гладкая $f$): $f(y) \le f(x) + \nabla f(x)^\top (y-x) + \frac{L}{2}\|y-x\|^2$. За один шаг $f(x^+) \le f(x) - \alpha\big(1 - \frac{L\alpha}{2}\big)\|\nabla f(x)\|^2$ — убывание при $0 < \alpha < 2/L$; **безопасный шаг** $1/L$ даёт $f(x^+) \le f(x) - \frac{1}{2L}\|\nabla f(x)\|^2$.
- **Квадратичная** $f$, собственные координаты: $z_{k,i} = (1 - \alpha\lambda_i)^k z_{0,i}$. Сходимость из любой начальной точки $\iff 0 < \alpha < 2/L$. **Граница устойчивости** $2/L$ не входит: на ней жёсткая координата без конца меняет знак.
- **Коэффициент сжатия** $\rho(\alpha) = \max\big(|1-\alpha\mu|, |1-\alpha L|\big)$: $\|x_k - x^*\| \le \rho^k \|x_0 - x^*\|$, $f(x_k) - f^* \le \rho^{2k}\big(f(x_0) - f^*\big)$, $\rho(1/L) = 1 - 1/\kappa$. **Оптимальный шаг** $\frac{2}{L+\mu}$: $\rho = \frac{\kappa-1}{\kappa+1}$.

## Скорость сходимости

- **Выпуклая** $f$, $\alpha = 1/L$: $f(x_k) - f^* \le \frac{L\|x_0 - x^*\|^2}{2k} = O(1/k)$, так как сумма неравенств $f(x_{k+1}) - f^* \le \frac{L}{2}\big(\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2\big)$ телескопируется.
- $\mu$**-сильно выпуклая** $f$ или **условие PL**, $\alpha = 1/L$: $f(x_k) - f^* \le (1 - \mu/L)^k \big(f(x_0) - f^*\big)$ — из $f(x_{k+1}) \le f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2$ и условия PL, без выпуклости.
- **Число итераций**, чтобы невязка уменьшилась в $1/\varepsilon$ раз: $k \ge \frac{\ln \varepsilon}{\ln(1-1/\kappa)}$, примерно $\kappa \ln(1/\varepsilon)$. При $\kappa = 1000$, $\varepsilon = 10^{-6}$: 13809 при $1/L$ и 3454 при $\frac{2}{L+\mu}$ на квадратичной функции. Это оценка, а не прогноз: на практике итераций часто меньше.

## Бэктрекинг по Армихо

- **Условие Армихо**: $f(x + \alpha d) \le f(x) + c\alpha \nabla f(x)^\top d$; для $d = -\nabla f$ правая часть равна $f(x) - c\alpha\|\nabla f(x)\|^2$. **Бэктрекинг**: $\alpha = \alpha_0, \beta\alpha_0, \beta^2\alpha_0, \dots$, пока условие не выполнится; обычно $\beta = \frac{1}{2}$, $c = 10^{-4}$.
- **Конечность** ($L$-гладкая $f$): проверку проходит любой $\alpha \le 2(1-c)/L$, поэтому цикл останавливается и $\alpha \ge \min\big(\alpha_0, 2\beta(1-c)/L\big)$. Проверяйте $\nabla f(x)^\top d < 0$ и ограничивайте число уменьшений.

## Критерии остановки

- **Масштабированные критерии**: $\|\nabla f(x_k)\| \le \varepsilon_g \max\big(1, |f(x_k)|\big)$, $\|x_{k+1} - x_k\| \le \varepsilon_x \max\big(1, \|x_k\|\big)$, $|f(x_{k+1}) - f(x_k)| \le \varepsilon_f \max\big(1, |f(x_k)|\big)$; в коде $\mathrm{atol} + \mathrm{rtol} \cdot \max(1, s)$.
- Критерии по изменению уменьшаются вместе с шагом, $\|x_{k+1} - x_k\| = \alpha_k \|\nabla f(x_k)\|$, и крошечный шаг включает их в любой точке. **Комбинированное правило**: успех — только по критерию по градиенту; критерий по изменению без него — сигнал застоя; ограничьте число итераций и остановитесь, если $f$ или $\nabla f$ не конечны.

## Автоматическое дифференцирование

- **Вычислительный граф**: промежуточные переменные в топологическом порядке; $z = \sin(xy) + x^2$: $u = xy$, $v = \sin u$, $w = x^2$, $z = v + w$. **Прямой проход** вычисляет и сохраняет значения.
- **Обратный проход**: сопряжённая переменная $\bar v = \partial z / \partial v$; $\bar z = 1$, остальные 0; вершины обходятся в обратном топологическом порядке, и для каждого ребра $u \to v$ выполняется $\bar u \mathrel{+}= \bar v\, \partial v / \partial u$. Здесь $\bar x = y\cos u + 2x$, $\bar y = x \cos u$.
- **Накопление**: вершина, от которой зависят несколько других, собирает по слагаемому с каждого ребра, $\bar v_i = \sum_{j:\, i \to j} \bar v_j\, \partial v_j / \partial v_i$; для $z = x^2 + x^3$ получаем $\bar x = 2x + 3x^2$. Присваивание сохраняет только последнее слагаемое.
- **Прямой режим** даёт произведение якобиана на вектор $J\dot x$ (JVP): для градиента в $\mathbb{R}^n$ нужно $n$ проходов. **Обратный режим** даёт произведение вектора на якобиан $\bar z^\top J$ (VJP): весь градиент скалярной функции за один проход. Проход в небольшое число раз дороже одного вычисления $f$; обратный режим хранит все промежуточные значения (ленту).

## Конечные разности

- **Центральная разность** $\frac{f(x + he_i) - f(x - he_i)}{2h}$, ошибка $\approx \frac{h^2}{6}|\partial_i^3 f| + \frac{\varepsilon |f|}{h}$: ошибка отбрасывания плюс ошибка округления, $\varepsilon$ — машинный эпсилон. Лучший $h \sim \varepsilon^{1/3} \approx 6 \cdot 10^{-6}$, ошибка $\sim \varepsilon^{2/3}$. Это проверка градиента, а не способ его вычислять.

## Логистическая функция потерь

- **Производная**: $\frac{d\ell}{ds} = \sigma(s) - y$ для $\ell = \log(1 + e^s) - ys$, $s = w^\top x + b$, $y \in \{0,1\}$, $\sigma(s) = \frac{1}{1+e^{-s}}$; поэтому $\nabla_w \ell = \big(\sigma(s) - y\big)x$ и $\frac{\partial \ell}{\partial b} = \sigma(s) - y$.
- **Гладкость** средней функции потерь по строкам $X$: $\nabla^2 f = \frac{1}{n} X^\top \operatorname{diag}\big(\sigma_i(1-\sigma_i)\big) X$ и $\sigma(1-\sigma) \le \frac{1}{4}$, поэтому $f$ выпукла и $L \le \frac{\lambda_{\max}(X^\top X)}{4n}$; оценка достигается при $w = 0$.

## Главные ловушки

- При $\alpha = 2/L$ сходимости уже нет: это граница, а не рабочий шаг; предел задаёт $L = \lambda_{\max}$, а $\mu$ влияет только на скорость.
- Условие Армихо с $+c\alpha\|\nabla f\|^2$ принимает шаги, увеличивающие $f$; малое изменение $x$ или $f$ может означать крошечный шаг, а не решение.
- Обратный проход: $=$ вместо $+=$ теряет слагаемые; $\sigma(s) - y$ — это $d\ell/ds$, а в градиенте по $w$ есть множитель $x$.

© 2026 Евгений Баулин, t.me/tarakan_tuc Лицензия MIT