Методы оптимизации

Семинар 3

Градиентный спуск и автоматическое дифференцирование

Конспект теории

НИУ ВШЭ, факультет компьютерных наук

2026–2027 учебный год

Лектор курса: Андрей Игнатов

Евгений Баулин

Telegram: @tarakan_tuc

Содержание

1 Определения **3**

2 Неравенство Йенсена **5**

2.1 Как читать неравенство 5

2.2 Три равносильных критерия 6

2.3 Конечная форма и форма для математического ожидания 7

2.4 Вогнутые функции и неравенство о средних 7

2.5 Контрпример 8

2.6 Квадратичный запас с обеих сторон 8

3 Градиентный спуск **9**

3.1 Почему антиградиент 9

3.2 Лемма о спуске и безопасный шаг 10

3.3 Квадратичные функции и точное условие устойчивости 10

3.4 Обусловленность и оптимальный постоянный шаг 12

3.5 Задачи семинара 13

4 Линейный поиск и критерии остановки **16**

4.1 Бэктрекинг по Армихо 16

4.2 Критерии остановки 17

4.3 Критерий по изменению, срабатывающий слишком рано 18

4.4 Задачи семинара 18

5 Скорость сходимости **21**
5.1 Выпуклый случай . . . 21
5.2 Сильная выпуклость . . . 22
5.3 Условие Поляка–Лоясевича . . . 23
5.4 Число обусловленности и число итераций . . . 24

6 Автоматическое дифференцирование в обратном режиме **25**
6.1 Вычисление как граф . . . 25
6.2 Прямой режим . . . 25
6.3 Обратный режим . . . 26
6.4 Почему сопряжённые переменные накапливаются . . . 26
6.5 Стоимость и память . . . 27
6.6 Обратное распространение для логистической функции потерь . . . 27
6.7 Символьное, численное и автоматическое дифференцирование . . . 28
6.8 Задачи блока C . . . 29

7 Коллоквиум **31**
7.1 Список определений . . . 31
7.2 Четыре доказательства . . . 32
7.3 Билет T1: обусловленность и скорость сходимости . . . 33
7.4 Билет T2: бэктрекинг по Армихо . . . 33
7.5 Билет T3: обратный проход . . . 34

8 Полезные константы **34**
8.1 Логистическая регрессия . . . 34
8.2 Квадратичные функции семинара . . . 35

Этот конспект собирает теорию третьего семинара: определения для коллоквиума, неравенство Йенсена, градиентный спуск с постоянным шагом и с бэктрекингом, скорости сходимости и автоматическое дифференцирование в обратном режиме. Каждое утверждение дано вместе с условиями, а там, где его могут спросить на коллоквиуме, — с полным доказательством. Задачи семинара разобраны целиком.

Обозначения.
Векторы — столбцы, $x^\top y$ — скалярное произведение, $\|\cdot\|$ — евклидова норма, если нижний индекс не указывает иное. Функция f задана на $\mathbb{R}^n$, $f^* = \inf_x f(x)$ — оптимальное значение, x^* — точка минимума, если она существует. Итерации — $x_0, x_1, \ldots$, шаг — α или α_k, направление — d или d_k, а x^+ внутри доказательства — следующая итерация. Константы сильной выпуклости и гладкости — μ и L, а $\kappa = L/\mu$. Для симметричных матриц запись $A \preceq B$ означает, что матрица $B - A$ положительно полуопределена. В автоматическом дифференцировании $\dot{v}$ — касательная переменная, а $\bar{v} = \partial z/\partial v$ — сопряжённая переменная.

1 Определения

На коллоквиуме сначала спрашивают определения, и определение засчитывается только вместе с условиями. Каждый блок ниже — формулировка, которую нужно воспроизвести; короткие абзацы между блоками — следствия, а не часть определений.

Определение: Локальный и глобальный минимум. Пусть $f : \mathbb{R}^n \to \mathbb{R}$. Точка x^* — **точка глобального минимума** f, если $f(x^*) \le f(x)$ для всех $x \in \mathbb{R}^n$. Это **точка локального минимума**, если существует $\varepsilon > 0$, при котором $f(x^*) \le f(x)$ для всех x с $\|x - x^*\| < \varepsilon$. Точка минимума **строгая**, если неравенство строгое для всех $x \neq x^*$ из соответствующего множества. Тогда значение $f(x^*)$ называют глобальным или локальным **минимумом**, а $f^* = \inf_x f(x)$ — оптимальным значением.

Оптимальное значение может равняться $-\infty$, а может быть конечным, но не достигаться: у $f(x) = e^x$ на $\mathbb{R}$ значение $f^* = 0$, а точки минимума нет.

Определение: Стационарная точка. Пусть $f : \mathbb{R}^n \to \mathbb{R}$ дифференцируема в точке x. Точка x называется **стационарной**, если $\nabla f(x) = 0$.

Точка локального минимума дифференцируемой функции стационарна: если $\nabla f(x^*) \neq 0$, то $d = -\nabla f(x^*)$ — направление спуска (определение ниже), и вдоль него f убывает. Обратное неверно: стационарная точка может оказаться точкой локального максимума или седловой точкой. У выпуклой дифференцируемой f любая стационарная точка — точка глобального минимума: достаточно подставить $\nabla f(x^*) = 0$ в неравенство для касательной из следующего раздела.

Определение: Выпуклое множество. Множество $C \subseteq \mathbb{R}^n$ **выпукло**, если $(1 - t)x + ty \in C$ для всех $x, y \in C$ и всех $t \in [0, 1]$, то есть если вместе с любыми двумя своими точками оно содержит отрезок между ними.

Определение: Выпуклая и строго выпуклая функция. Пусть $C \subseteq \mathbb{R}^n$ — выпуклое множество, обычно $C = \mathbb{R}^n$. Функция $f : C \to \mathbb{R}$ **выпукла**, если для неё выполнено

неравенство Йенсена

$$f\big((1-t)x+ty\big) \le (1-t)f(x)+tf(y) \quad \text{для всех } x,y\in C,\ t\in[0,1].$$

Она **строго выпукла**, если неравенство строгое при $x\neq y$ и $t\in(0,1)$, и **вогнута**, если функция $-f$ выпукла.

Определение: μ-сильная выпуклость. Пусть $\mu>0$. Функцию $f:\mathbb{R}^n\to\mathbb{R}$ называют **μ-сильно выпуклой**, если функция $f(x)-\frac{\mu}{2}\|x\|^2$ выпукла. Равносильное определение — неравенство Йенсена с квадратичным запасом:

$$f\big((1-t)x+ty\big) \le (1-t)f(x)+tf(y)-\frac{\mu}{2}t(1-t)\|x-y\|^2 \quad \text{для всех } x,y,\ t\in[0,1].$$

Если f дифференцируема, это равносильно условию первого порядка

$$f(y)\ge f(x)+\nabla f(x)^\top(y-x)+\frac{\mu}{2}\|y-x\|^2 \quad \text{для всех } x,y,$$

а если f дважды дифференцируема — условию $\nabla^2 f(x)\succeq \mu I$ для всех x.

Эти формулировки равносильны, потому что $(1-t)\|x\|^2+t\|y\|^2-\|(1-t)x+ty\|^2=t(1-t)\|x-y\|^2$ (тождество из следующего раздела), а условие первого порядка — это неравенство для касательной, записанное для $f-\frac{\mu}{2}\|\cdot\|^2$. Сильно выпуклая функция строго выпукла и имеет ровно одну точку минимума. Строгая выпуклость слабее: у $f(x)=\log(1+e^x)$ вторая производная $f''(x)=\sigma(x)\big(1-\sigma(x)\big)>0$, где $\sigma(x)=1/(1+e^{-x})$, но $f''(x)\to 0$ при $|x|\to\infty$, так что никакое $\mu>0$ не подходит, а точки минимума у этой f нет вовсе.

Определение: L-гладкость. Пусть $L>0$. Дифференцируемую функцию $f:\mathbb{R}^n\to\mathbb{R}$ называют **L-гладкой**, если её градиент L-липшицев:

$$\|\nabla f(x)-\nabla f(y)\|\le L\|x-y\| \quad \text{для всех } x,y.$$

Если f дважды непрерывно дифференцируема, это равносильно условию $-LI\preceq\nabla^2 f(x)\preceq LI$ для всех x. Для выпуклой f левое неравенство выполнено автоматически, и условие принимает вид $\nabla^2 f(x)\preceq LI$.

В лекции одно и то же свойство называется двумя способами: L-гладкость и L-липшицев градиент. Доказательства сходимости используют его в форме леммы о спуске из раздела о градиентном спуске: $f(y)\le f(x)+\nabla f(x)^\top(y-x)+\frac{L}{2}\|y-x\|^2$.

Определение: Число обусловленности. Пусть f — μ-сильно выпуклая и L-гладкая функция, причём μ — наибольшая, а L — наименьшая из констант, при которых это верно. **Число обусловленности** f — это $\kappa=L/\mu$, и $\kappa\ge 1$. У квадратичной функции $f(x)=\frac{1}{2}x^\top Qx-b^\top x$ с симметричной матрицей $Q\succ 0$ наилучшие константы — $\mu=\lambda_{\min}(Q)$ и $L=\lambda_{\max}(Q)$, поэтому $\kappa=\lambda_{\max}(Q)/\lambda_{\min}(Q)$.

Множества уровня такой квадратичной функции — эллипсоиды, и отношение их наибольшей полуоси к наименьшей равно $\sqrt{\kappa}$. Большое κ означает длинную узкую долину.

Определение: Направление спуска. Пусть $f:\mathbb{R}^n\to\mathbb{R}$ дифференцируема в точке x. Вектор $d\in\mathbb{R}^n$ называется **направлением спуска** в точке x, если $\nabla f(x)^\top d<0$. Тогда $f(x+\alpha d)<f(x)$ при всех достаточно малых $\alpha>0$, поскольку $f(x+\alpha d)=f(x)+$

$\alpha \nabla f(x)^\top d + o(\alpha)$.

Если $\nabla f(x) \neq 0$, то вектор $d = -\nabla f(x)$ — направление спуска: $\nabla f(x)^\top d = -\|\nabla f(x)\|^2 < 0$. Это условие достаточно для локального убывания, но не необходимо: в точке максимума 0 функции $f(x) = -x^2$ любое $d \neq 0$ уменьшает f, хотя $f'(0)\, d = 0$.

Определение: Условие Поляка–Лоясевича. Пусть $f : \mathbb{R}^n \to \mathbb{R}$ дифференцируема, $f^* = \inf_x f(x) > -\infty$ и $\mu > 0$. Функция f удовлетворяет **условию Поляка–Лоясевича (PL)** с константой μ, если

$$\frac{1}{2}\|\nabla f(x)\|^2 \geq \mu\big(f(x) - f^*\big) \quad \text{для всех } x.$$

При условии PL любая стационарная точка — точка глобального минимума: из $\nabla f(x) = 0$ следует $f(x) = f^*$. Дифференцируемая μ-сильно выпуклая функция удовлетворяет PL с тем же μ: минимизируя правую часть условия первого порядка по y (минимум достигается при $y = x - \nabla f(x)/\mu$), получаем $f^* \geq f(x) - \frac{1}{2\mu}\|\nabla f(x)\|^2$. Обратное неверно, и PL не требует даже выпуклости: $f(x) = x^2 + 3\sin^2 x$ удовлетворяет PL с некоторым $\mu > 0$, хотя $f''(\pi/2) = 2 + 6\cos\pi < 0$.

2 Неравенство Йенсена

Неравенство Йенсена — это определение выпуклости. Обычные условия теорем о сходимости — то же неравенство с квадратичным запасом: снизу для сильной выпуклости, сверху для гладкости.

2.1 Как читать неравенство

Выпуклость f на выпуклом множестве — это неравенство Йенсена

$$f\big((1-t)x + ty\big) \leq (1-t)f(x) + tf(y), \qquad t \in [0,1].$$

Когда t меняется от 0 до 1, точка $(1-t)x + ty$ пробегает отрезок от x до y, так что левая часть — это график f над отрезком. В правой части те же веса применены к значениям функции: это хорда от $(x, f(x))$ до $(y, f(y))$. Выпуклость означает ровно то, что хорда нигде не опускается ниже графика. Производные здесь не участвуют: $f(x) = |x|$ выпукла в силу неравенства треугольника $|(1-t)x + ty| \leq (1-t)|x| + t|y|$, хотя в точке 0 производной у неё нет.

Ограничение $t \in [0,1]$ существенно. При других t точка $(1-t)x + ty$ по-прежнему лежит на прямой, проходящей через x и y, но уже не между ними, и неравенство нарушается даже для $f(x) = x^2$. При $x = 0$, $y = 1$ и $t = 2$ получаем точку 2; левая часть равна $f(2) = 4$, а правая — $(1-t)f(x) + tf(y) = 2$.

Утверждение: Тождество для x^2. Для всех вещественных x, y и t

$$(1-t)x^2 + ty^2 - \big((1-t)x + ty\big)^2 = t(1-t)(x-y)^2.$$

Доказательство. Раскроем квадрат $\big((1-t)x + ty\big)^2 = (1-t)^2x^2 + 2t(1-t)xy + t^2y^2$ и воспользуемся равенствами $(1-t) - (1-t)^2 = t(1-t)$ и $t - t^2 = t(1-t)$: разность равна $t(1-t)(x^2 - 2xy + y^2) = t(1-t)(x-y)^2$.

При $t \in [0,1]$ правая часть неотрицательна, поэтому x^2 выпукла, а в нуль она обращается только при $t \in \{0,1\}$ или $x = y$, поэтому x^2 строго выпукла. При $t \notin [0,1]$ множитель $t(1-t)$ отрицателен, и неравенство нарушается для любых $x \neq y$; в примере выше $t(1-t)(x-y)^2 = 2 - 4 < 0$. То же вычисление со скалярными произведениями даёт для векторов

$$(1-t)\|x\|^2 + t\|y\|^2 - \|(1-t)x + ty\|^2 = t(1-t)\|x-y\|^2,$$

а для $f(x) = \frac{1}{2}x^\top Q x$ с симметричной Q зазор между хордой и графиком равен $\frac{1}{2}\,t(1-t)(x-y)^\top Q(x-y)$.

2.2 Три равносильных критерия

Определение выпуклости — неравенство для хорды. Ему равносильны ещё два критерия, но каждый из них требует гладкости, а определение обходится без неё.

Критерий	Что требуется	Смысл
Хорда (Йенсен): $f\big((1-t)x+ty\big) \le (1-t)f(x)+tf(y)$	выпуклая область определения, производные не нужны	график лежит не выше любой хорды
Касательная: $f(y) \ge f(x) + \nabla f(x)^\top (y-x)$	f дифференцируема на открытом выпуклом множестве	график лежит не ниже любой касательной плоскости; линейная модель — глобальная оценка снизу
Кривизна: $\nabla^2 f(x) \succeq 0$	f дважды дифференцируема на открытом выпуклом множестве	$d^\top \nabla^2 f(x)\, d \ge 0$ для любого d: вдоль любой прямой график изгибается вверх

Теорема: Критерии выпуклости. Пусть $C \subseteq \mathbb{R}^n$ — открытое выпуклое множество. Если f дифференцируема на C, то она выпукла тогда и только тогда, когда $f(y) \ge f(x) + \nabla f(x)^\top (y-x)$ для всех $x, y \in C$. Если f дважды дифференцируема на C, то она выпукла тогда и только тогда, когда $\nabla^2 f(x) \succeq 0$ для всех $x \in C$.

Доказательство. От хорды к касательной: неравенство Йенсена при $t \in (0,1]$ даёт $f\big(x + t(y-x)\big) - f(x) \le t\big(f(y) - f(x)\big)$; делим на t и, переходя к пределу при $t \to 0$, получаем $\nabla f(x)^\top (y-x) \le f(y) - f(x)$. От касательной к хорде: для $z = (1-t)x + ty$ неравенство для касательной в точке z даёт $f(x) \ge f(z) + \nabla f(z)^\top (x-z)$ и $f(y) \ge f(z) + \nabla f(z)^\top (y-z)$; умножаем их на $1-t$ и t соответственно и складываем; слагаемые с градиентом сокращаются, так как $(1-t)(x-z) + t(y-z) = 0$. Кривизна: f выпукла тогда и только тогда, когда выпукло каждое её сужение $\varphi(s) = f(x + sd)$ на прямую; дважды дифференцируемая функция одной переменной выпукла тогда и только тогда, когда $\varphi'' \ge 0$, а $\varphi''(s) = d^\top \nabla^2 f(x+sd)\, d$.

Для строгой выпуклости верна только одна импликация: из $\nabla^2 f(x) \succ 0$ при всех x следует строгая выпуклость, но $f(x) = |x|^3$ строго выпукла, хотя $f''(x) = 6|x|$ обращается в нуль в точке 0.

2.3 Конечная форма и форма для математического ожидания

Теорема: Неравенство Йенсена для нескольких точек. Пусть f выпукла на выпуклом множестве C, $x_1, \dots, x_N \in C$ и $t_1, \dots, t_N \geq 0$, причём $\sum_i t_i = 1$. Тогда

$$f\Big(\sum_{i=1}^{N} t_i x_i\Big) \leq \sum_{i=1}^{N} t_i f(x_i).$$

Доказательство. Индукция по N. При $N = 1$ обе части равны $f(x_1)$, а случай $N = 2$ — это определение. Пусть $N \geq 3$ и утверждение верно для $N-1$ точки. Если $t_N = 1$, все остальные веса равны нулю и доказывать нечего. Иначе

$$\sum_{i=1}^{N} t_i x_i = (1 - t_N)\, y + t_N x_N, \qquad y = \sum_{i=1}^{N-1} \frac{t_i}{1 - t_N}\, x_i,$$

и y — выпуклая комбинация $N-1$ точки из C: её веса неотрицательны и в сумме дают 1, поэтому $y \in C$. Определение, а затем предположение индукции дают

$$f\Big(\sum_{i=1}^{N} t_i x_i\Big) \leq (1 - t_N) f(y) + t_N f(x_N) \leq \sum_{i=1}^{N-1} t_i f(x_i) + t_N f(x_N).$$

Теорема: Неравенство Йенсена для математического ожидания. Пусть $f : \mathbb{R}^n \to \mathbb{R}$ выпукла, а X — случайный вектор в $\mathbb{R}^n$, для которого $\mathbb{E}\|X\| < \infty$ и $\mathbb{E}|f(X)| < \infty$. Тогда

$$f(\mathbb{E}X) \leq \mathbb{E} f(X).$$

Доказательство. Положим $m = \mathbb{E}X$. Если f дифференцируема, неравенство для касательной в точке m имеет вид $f(X) \geq f(m) + \nabla f(m)^{\top}(X - m)$; берём математическое ожидание обеих частей и пользуемся тем, что $\mathbb{E}(X - m) = 0$. Без дифференцируемости то же рассуждение проходит с субградиентом в точке m — вектором g, для которого $f(y) \geq f(m) + g^{\top}(y - m)$ при всех y; у выпуклой $f : \mathbb{R}^n \to \mathbb{R}$ он существует в каждой точке. Случайный вектор, принимающий значение x_i с вероятностью t_i, возвращает нас к конечной форме.

2.4 Вогнутые функции и неравенство о средних

Ловушка. Для вогнутой g знак каждого неравенства выше меняется на противоположный: $g\big(\sum_i t_i x_i\big) \geq \sum_i t_i g(x_i)$ и $g(\mathbb{E}X) \geq \mathbb{E} g(X)$. Логарифм вогнут, поэтому для положительной случайной величины X выполнено $\mathbb{E}\log X \leq \log \mathbb{E}X$, а не наоборот.

Утверждение: Неравенство о средних для двух чисел. Для $a, b > 0$

$$\sqrt{ab} \leq \frac{a + b}{2},$$

причём равенство достигается тогда и только тогда, когда $a = b$.

Доказательство. Функция $-\log$ строго выпукла на выпуклом множестве $(0,\infty)$, так как $(-\log x)'' = 1/x^2 > 0$. Неравенство Йенсена при $t = \frac{1}{2}$ даёт

$$-\log\frac{a+b}{2} \le \frac{1}{2}\big(-\log a - \log b\big) = -\log\sqrt{ab},$$

причём неравенство строгое при $a \neq b$. Остаётся умножить на -1 и применить возрастающую функцию $\exp$.

Пример. $a = 1$, $b = 9$: $\sqrt{ab} = 3 \le 5 = \frac{a+b}{2}$. Конечная форма неравенства Йенсена тем же рассуждением даёт взвешенный вариант $\prod_i a_i^{t_i} \le \sum_i t_i a_i$ для $a_i > 0$, $t_i \ge 0$, $\sum_i t_i = 1$.

2.5 Контрпример

Пример. Возьмём $f(x) = x^3$ на $\mathbb{R}$ и $x = -2$, $y = 1$, $t = 0{,}5$. Тогда $(1-t)x + ty = -0{,}5$, левая часть равна $f(-0{,}5) = -0{,}125$, а правая — $(1-t)x^3 + ty^3 = -3{,}5$. Так как $-0{,}125 > -3{,}5$, неравенство нарушено, и x^3 не выпукла на $\mathbb{R}$.

Одной пары точек и одного t достаточно, чтобы опровергнуть выпуклость; никакое число удачных проверок её не доказывает. На $[0,\infty)$ функция x^3 выпукла, так как там $f''(x) = 6x \ge 0$, поэтому случайная проверка, которая берёт 10000 пар из $[0,2]$, находит 0 нарушений и ничего не говорит об отрицательных аргументах. Выпуклость доказывают по определению или с помощью одного из критериев выше.

2.6 Квадратичный запас с обеих сторон

На языке хорды μ и L ограничивают зазор между хордой и графиком снизу и сверху. Если f — μ-сильно выпуклая и L-гладкая функция, то для всех x, y и $t \in [0,1]$

$$\frac{\mu}{2}\,t(1-t)\|x-y\|^2 \le (1-t)f(x) + tf(y) - f\big((1-t)x + ty\big) \le \frac{L}{2}\,t(1-t)\|x-y\|^2,$$

а в форме первого порядка

$$\frac{\mu}{2}\|y-x\|^2 \le f(y) - f(x) - \nabla f(x)^{\top}(y-x) \le \frac{L}{2}\|y-x\|^2.$$

Левые неравенства — определение сильной выпуклости. Правое неравенство в форме первого порядка — лемма о спуске, а его вариант для хорды получается так: записываем лемму о спуске в точке $z = (1-t)x + ty$ для точек x и y и складываем с весами $1-t$ и t. Для выпуклой дифференцируемой f каждое из правых неравенств на самом деле равносильно L-гладкости.

Для $f(x) = \frac{1}{2}x^{\top}Qx$ зазор между хордой и графиком равен $\frac{1}{2}t(1-t)(x-y)^{\top}Q(x-y)$. Он лежит между двумя оценками с $\mu = \lambda_{\min}(Q)$ и $L = \lambda_{\max}(Q)$ и достигает каждой из них, когда $x - y$ — соответствующий собственный вектор. Отношение $\kappa = L/\mu$ показывает, насколько сильно расходятся две параболы, а в следующих разделах мы увидим, что оно определяет число итераций градиентного спуска.

Проверьте себя. Примените неравенство Йенсена к $f(x) = x^2$ и случайной величине X с конечной дисперсией. Что получится и чему равна разность его частей?

Ответ. Получится $(\mathbb{E}X)^2 \le \mathbb{E}X^2$. Разность равна $\mathbb{E}X^2 - (\mathbb{E}X)^2 = \operatorname{Var} X \ge 0$ и обращается в нуль, только если X постоянна с вероятностью единица. Если $X = x$ с вероятностью $1-t$ и $X = y$ с вероятностью t, то $\operatorname{Var} X = t(1-t)(x-y)^2$: тождество для x^2 — это и

есть формула для этой дисперсии.

3 Градиентный спуск

Итерационный метод начинает с точки x_0 и повторяет

$$d_k = \mathcal{D}(x_k, f, \nabla f, \dots), \qquad \alpha_k = \mathcal{S}(x_k, d_k), \qquad x_{k+1} = x_k + \alpha_k d_k.$$

Метод задаётся ответами на три вопроса: как выбрать направление d_k, как выбрать шаг α_k и когда остановиться. Градиентный спуск берёт $d_k = -\nabla f(x_k)$. В этом разделе шаг постоянный; бэктрекинг и критерии остановки — в следующем.

Определение: Градиентный спуск. Пусть $f : \mathbb{R}^n \to \mathbb{R}$ дифференцируема и $\alpha > 0$. Градиентный спуск с постоянным шагом α из точки x_0 — это последовательность

$$x_{k+1} = x_k - \alpha \nabla f(x_k), \qquad k = 0, 1, 2, \dots$$

Каждая итерация требует одного вычисления градиента.

3.1 Почему антиградиент

Теорема: Наискорейшее возрастание в евклидовой норме. Пусть f дифференцируема в точке x и $\nabla f(x) \neq 0$. Тогда

$$\arg\max_{\|d\|_2 \le 1} \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} = \frac{\nabla f(x)}{\|\nabla f(x)\|_2},$$

а наибольшая скорость возрастания равна $\|\nabla f(x)\|_2$.

Доказательство. Из дифференцируемости следует, что $f(x + td) = f(x) + t\,\nabla f(x)^\top d + o(t)$, поэтому предел равен $\nabla f(x)^\top d$. По неравенству Коши — Буняковского — Шварца

$$\nabla f(x)^\top d \le \|\nabla f(x)\|_2 \, \|d\|_2 \le \|\nabla f(x)\|_2,$$

причём равенство достигается при $d = \nabla f(x)/\|\nabla f(x)\|_2$. Равенство в неравенстве Коши — Буняковского — Шварца возможно, только если d получается из $\nabla f(x)$ умножением на неотрицательное число, а равенство во втором неравенстве требует $\|d\|_2 = 1$, так что эта точка максимума единственна.

Заменив d на $-d$, получаем: среди единичных векторов направление наискорейшего спуска — $-\nabla f(x)/\|\nabla f(x)\|_2$, а скорость изменения функции вдоль него равна $-\|\nabla f(x)\|_2$.

Слово *наискорейший* относится к единичному шару евклидовой нормы. Для произвольной нормы наискорейшее направление единичной длины — решение задачи $\max_{\|d\| \le 1} \nabla f(x)^\top d = \|\nabla f(x)\|_*$, где $\|\cdot\|_*$ — двойственная норма, и ответ зависит от нормы. Для $\|d\|_M = \sqrt{d^\top M d}$ с $M \succ 0$ сделаем замену $u = M^{1/2} d$: задача превращается в $\max_{\|u\|_2 \le 1} \left(M^{-1/2}\nabla f(x)\right)^\top u$, теорема даёт $u \propto M^{-1/2}\nabla f(x)$, а значит, $d \propto M^{-1}\nabla f(x)$. В этой норме направление наискорейшего спуска идёт вдоль $-M^{-1}\nabla f(x)$; на этой идее основаны предобусловливание и натуральный градиент. Для $\|\cdot\|_\infty$ одно из направлений наискорейшего спуска — $-\operatorname{sign} \nabla f(x)$, где знак берётся покомпонентно.

3.2 Лемма о спуске и безопасный шаг

Лемма: Лемма о спуске. Пусть $f:\mathbb{R}^n\to\mathbb{R}$ дифференцируема и её градиент липшицев с константой L. Тогда для любых x, y

$$f(y)\le f(x)+\nabla f(x)^\top(y-x)+\frac{L}{2}\|y-x\|^2.$$

Доказательство. Положим $r(t)=f\big(x+t(y-x)\big)$ при $t\in[0,1]$. Эта функция непрерывно дифференцируема, и $r'(t)=\nabla f\big(x+t(y-x)\big)^\top(y-x)$, поэтому

$$f(y)-f(x)=\int_0^1 r'(t)\,dt=\nabla f(x)^\top(y-x)+\int_0^1\big(\nabla f(x+t(y-x))-\nabla f(x)\big)^\top(y-x)\,dt.$$

По неравенству Коши — Буняковского — Шварца и условию Липшица подынтегральное выражение не больше $\|\nabla f(x+t(y-x))-\nabla f(x)\|\,\|y-x\|\le Lt\|y-x\|^2$, а $\int_0^1 Lt\,dt=\frac{L}{2}$.

Та же оценка с модулями даёт $\big|f(y)-f(x)-\nabla f(x)^\top(y-x)\big|\le\frac{L}{2}\|y-x\|^2$: L-гладкая функция зажата между двумя параболами вокруг своей касательной плоскости. Градиентному спуску нужна только верхняя. Утверждение глобальное: одна константа L оценивает ошибку линейной модели в любой точке и при любой длине шага.

Следствие: Убывание за один шаг. Пусть f — L-гладкая функция, $\alpha>0$ и $x^+=x-\alpha\nabla f(x)$. Тогда

$$f(x^+)\le f(x)-\alpha\Big(1-\frac{L\alpha}{2}\Big)\|\nabla f(x)\|^2.$$

Доказательство. Подставим $y=x^+$ в лемму о спуске. Поскольку $y-x=-\alpha\nabla f(x)$, получаем

$$f(x^+)\le f(x)-\alpha\|\nabla f(x)\|^2+\frac{L\alpha^2}{2}\|\nabla f(x)\|^2.$$

Отсюда получаются две константы. При $0<\alpha<2/L$ множитель $1-L\alpha/2$ положителен, поэтому каждый шаг из нестационарной точки строго уменьшает f. Гарантированное убывание $\alpha(1-L\alpha/2)$ — вогнутая парабола по α с максимумом в точке $\alpha=1/L$, где

$$f(x^+)\le f(x)-\frac{1}{2L}\|\nabla f(x)\|^2,$$

и это лучшая гарантия, которую может дать такая оценка. При любом $\alpha\le 1/L$ выполнено $1-L\alpha/2\ge\frac{1}{2}$, а значит, $f(x^+)\le f(x)-\frac{\alpha}{2}\|\nabla f(x)\|^2$.

Ловушка. Значение $2/L$ — это граница, на которой кончается гарантия строгого убывания, а не доказательство того, что при более длинных шагах метод расходится: при $\alpha=2/L$ оценка лишь исключает рост, при $\alpha>2/L$ она его допускает, а конкретная функция может всё равно убывать. У квадратичной функции $2/L$ — точная граница, как показано в следующем подразделе.

3.3 Квадратичные функции и точное условие устойчивости

Возьмём $f(x)=\frac{1}{2}x^\top Qx-b^\top x$ с симметричной матрицей $Q\succ 0$. Тогда $\nabla f(x)=Qx-b$, единственная точка минимума — $x^*=Q^{-1}b$, и $\nabla f(x)=Q(x-x^*)$. Для ошибки $e_k=x_k-x^*$

один шаг градиентного спуска даёт

$$e_{k+1} = e_k - \alpha Q e_k = (I - \alpha Q)\, e_k.$$

Диагонализуем $Q = U \Lambda U^\top$, где U ортогональна и $\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$, и перейдём к координатам в собственном базисе $z_k = U^\top e_k$. Координаты меняются независимо друг от друга:

$$z_{k+1,i} = (1 - \alpha\lambda_i)\, z_{k,i}, \qquad z_{k,i} = (1 - \alpha\lambda_i)^k z_{0,i},$$

а $f(x_k) - f^* = \frac{1}{2} e_k^\top Q e_k = \frac{1}{2} \sum_i \lambda_i z_{k,i}^2$.

Теорема: Устойчивость на квадратичной функции. Пусть $f(x) = \frac{1}{2} x^\top Q x - b^\top x$ с симметричной $Q \succ 0$. Градиентный спуск с постоянным шагом α сходится к x^* при любом начальном приближении в том и только в том случае, если

$$0 < \alpha < \frac{2}{\lambda_{\max}(Q)}.$$

Доказательство. Из рекуррентного соотношения видно, что $z_{k,i} \to 0$ при любом $z_{0,i}$ в том и только в том случае, если $|1 - \alpha\lambda_i| < 1$, а $\|x_k - x^*\| = \|z_k\|$, так как U ортогональна. Поэтому $x_k \to x^*$ из любой точки x_0 в том и только в том случае, если $|1 - \alpha\lambda_i| < 1$ для всех i. Поскольку $\lambda_i > 0$, это означает $0 < \alpha\lambda_i < 2$ при всех i, и определяющим оказывается наибольшее собственное значение.

На границе $\alpha = 2/\lambda_{\max}$ множитель самой жёсткой координаты равен -1: эта координата без конца меняет знак, сохраняя модуль, а остальные по-прежнему уменьшаются. За границей она растёт в геометрической прогрессии. Между $1/\lambda_{\max}$ и $2/\lambda_{\max}$ её множитель отрицателен, но по модулю меньше 1, и она стремится к нулю, чередуя знаки. Здесь $L = \lambda_{\max}(Q)$, так что безопасный диапазон $0 < \alpha < 2/L$ из леммы о спуске в точности совпадает с областью устойчивости: для квадратичных функций лемма неулучшаема.

Пример. В задаче A1 $Q = \operatorname{diag}(1;\ 10)$, поэтому $L = 10$ и граница равна $2/L = 0{,}2$. При $\alpha = 0{,}2$ множители равны $0{,}8$ и -1. Из $x_0 = (2;\ 2)$ жёсткая координата принимает попеременно значения 2 и -2, и

$$f(x_k) = 20 + 2 \cdot 0{,}64^k :$$

значения убывают к 20 и никогда не опускаются ниже, потому что одна только жёсткая координата даёт вклад $\frac{1}{2} \cdot 10 \cdot 2^2 = 20$.

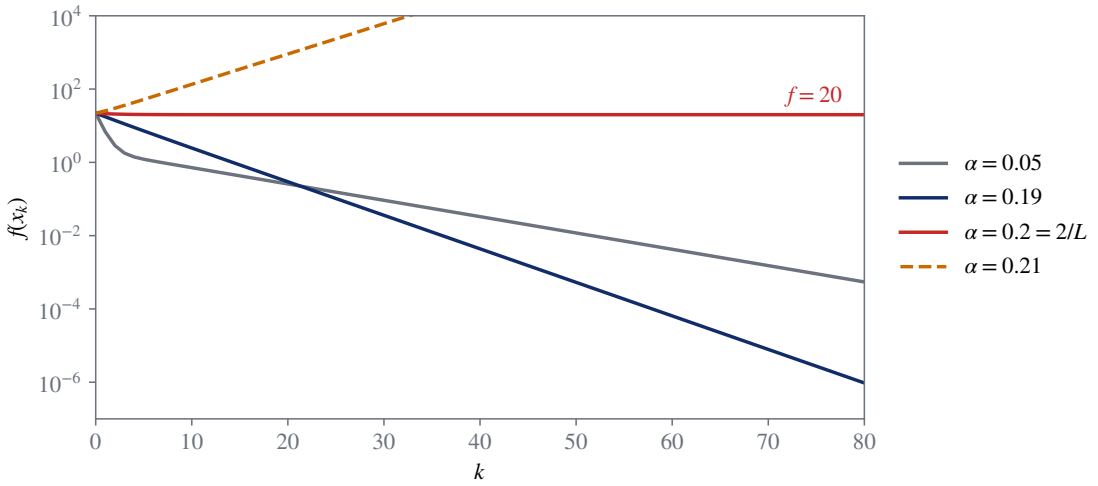


Рисунок. Значения $f(x_k)$, логарифмическая шкала, для $f(x) = \frac{1}{2}x^\top Qx$ с $Q = \mathrm{diag}(1;\ 10)$, $x_0 = (2;\ 2)$ и четырьмя шагами из задачи A1. При шагах ниже границы $2/L = 0{,}2$ значения убывают в геометрической прогрессии, при $\alpha = 2/L$ стабилизируются на уровне 20, а выше границы растут.

3.4 Обусловленность и оптимальный постоянный шаг

Для квадратичной функции положим $\mu = \lambda_{\min}(Q)$ и $L = \lambda_{\max}(Q)$. За один шаг норма ошибки умножается не более чем на

$$\rho(\alpha) = \max_i |1 - \alpha\lambda_i| = \max\big(|1 - \alpha\mu|,\ |1 - \alpha L|\big),$$

потому что $|1-\alpha\lambda|$ выпукла по λ и её максимум на $[\mu, L]$ достигается на конце отрезка. Вместе с $\|e_k\| = \|z_k\|$ это даёт

$$\|x_k - x^*\| \le \rho(\alpha)^k\,\|x_0 - x^*\|, \qquad f(x_k) - f^* \le \rho(\alpha)^{2k}\big(f(x_0) - f^*\big).$$

При $\alpha = 1/L$ множители $1 - \lambda_i/L$ лежат в $[0, 1 - 1/\kappa]$, поэтому $\rho(1/L) = 1 - 1/\kappa$. Так как $\ln\frac{1}{1-1/\kappa} \ge \frac{1}{\kappa}$, ошибка становится меньше $\varepsilon\|x_0 - x^*\|$, как только $k \ge \kappa\ln(1/\varepsilon)$: число итераций растёт пропорционально κ. Геометрически большое κ — это длинная узкая долина; градиент направлен в основном поперёк неё, и шаг, достаточно короткий для крутого направления, почти не сдвигает точку вдоль пологого. Поэтому на квадратичной функции при $\alpha = 1/L$ невязка по функции за шаг умножается не более чем на $(1-\mu/L)^2$. Это точнее общей гарантии $f(x_k) - f^* \le (1 - \mu/L)^k\big(f(x_0) - f^*\big)$, которая выполняется при $\alpha = 1/L$ для любой μ-сильно выпуклой L-гладкой функции и доказывается в разделе «Скорость сходимости». В задачах A2 и A3 речь идёт именно об этой общей гарантии, поэтому множитель в них равен $1 - \mu/L$, а не $(1 - \mu/L)^2$.

Утверждение: Оптимальный постоянный шаг. Для квадратичной функции с $\mu = \lambda_{\min}(Q) > 0$ и $L = \lambda_{\max}(Q)$ минимум множителя $\rho(\alpha)$ по $\alpha > 0$ достигается при

$$\alpha^* = \frac{2}{L + \mu}, \qquad \rho(\alpha^*) = \frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1}.$$

Доказательство. При $\alpha > 0$ имеем $|1 - \alpha\lambda| = \max(1 - \alpha\lambda,\ \alpha\lambda - 1)$; первое выражение максимально при $\lambda = \mu$, второе — при $\lambda = L$. Поэтому $\rho(\alpha) = \max(1 - \alpha\mu,\ \alpha L - 1)$ — максимум убывающей и возрастающей линейных функций от α. Он минимален там, где они равны: из $1 - \alpha\mu = \alpha L - 1$ получаем $\alpha^* = 2/(L + \mu)$ и $\rho(\alpha^*) = 1 - \frac{2\mu}{L+\mu} = \frac{L-\mu}{L+\mu}$. При

> $\alpha < \alpha^*$ первая функция больше своего значения в α^*, а при $\alpha > \alpha^*$ — вторая, так что любой другой шаг даёт больший множитель. Разделив числитель и знаменатель на μ, получаем $(\kappa - 1)/(\kappa + 1)$.

При α^* два крайних множителя равны $1 - \alpha^*\mu = \rho(\alpha^*)$ и $1 - \alpha^* L = -\rho(\alpha^*)$, то есть одинаковы по модулю. В задаче A3 значения $\mu = 1$ и $L = 50$ дают $\alpha^* = \frac{2}{51} \approx 0{,}039216$, а $\kappa = 50$ даёт $\rho(\alpha^*) = \frac{49}{51} \approx 0{,}960784$ против $1 - 1/\kappa = 0{,}98$ при $\alpha = 1/L$. Когда у Q есть только собственные значения μ и L, как во всех двумерных примерах семинара, модуль каждой координаты за шаг умножается ровно на $\rho(\alpha^*)$, и $f(x_k) - f^* = \rho(\alpha^*)^{2k}\bigl(f(x_0) - f^*\bigr)$ выполняется как равенство. Для любой μ-сильно выпуклой L-гладкой функции тот же шаг даёт ту же оценку для $\|x_k - x^*\|$ с тем же множителем, но доказательство длиннее.

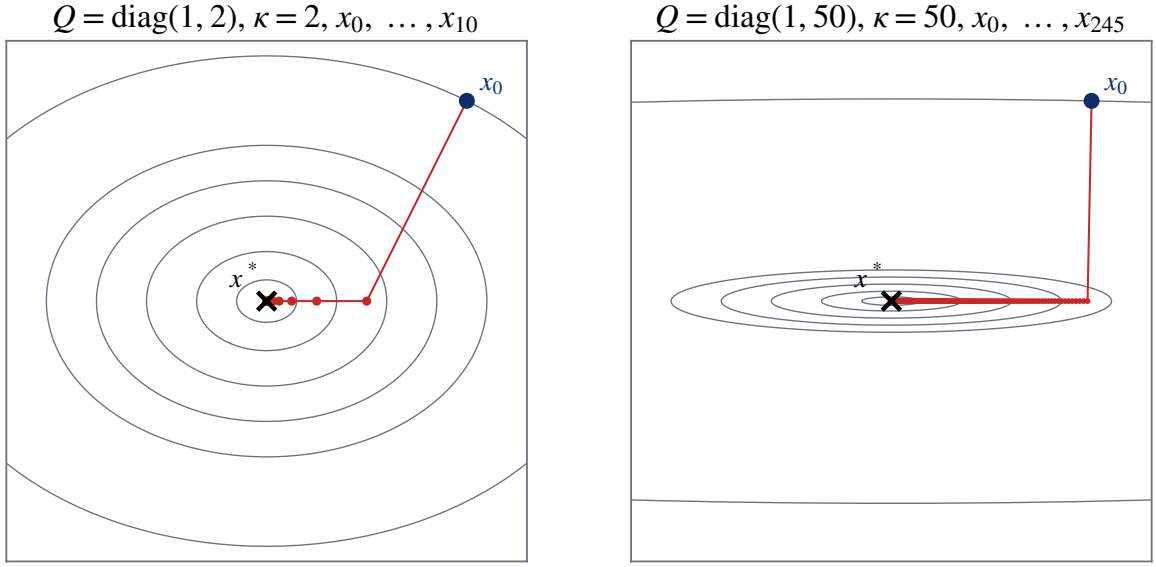


Рисунок. Линии уровня $f(x) = \frac{1}{2}x^\top Q x$ и итерации градиентного спуска с $\alpha = 1/L$ из $x_0 = (1;\ 1)$. Слева: $Q = \mathrm{diag}(1;\ 2)$, $\kappa = 2$. Справа: $Q = \mathrm{diag}(1;\ 50)$, $\kappa = 50$. Пологая координата за шаг умножается на $1 - 1/\kappa$, то есть на 0,5 слева и на 0,98 справа, а чтобы добиться $f(x_k) \le 10^{-6} f(x_0)$, нужно 10 итераций слева и 245 справа.

3.5 Задачи семинара

Задачи блока A с полными решениями.

A1. Четыре шага на одной квадратичной функции

У доски

Условие. Минимизируйте $f(x) = \frac{1}{2}x^\top Q x$, где $Q = \mathrm{diag}(1;\ 10)$, градиентным спуском с постоянным шагом α из $x_0 = (2;\ 2)$. **а)** Найдите границу устойчивости: такое значение $\alpha_{\max}$, что метод сходится из любой начальной точки тогда и только тогда, когда $0 < \alpha < \alpha_{\max}$. **б)** Классифицируйте шаги $\alpha = 0{,}05,\ 0{,}19,\ 0{,}2$ и $0{,}21$ с помощью покоординатного рекуррентного соотношения $z_{k+1,i} = (1 - \alpha\lambda_i)\, z_{k,i}$: сходится ли метод и как именно?

Решение.

1. Здесь $x^* = 0$, $f^* = 0$, а Q уже диагональна, так что собственные координаты совпадают с обычными: $z_k = x_k$, $\mu = \lambda_1 = 1$, $L = \lambda_2 = 10$, $\kappa = 10$. Шаг $x_{k+1} = x_k - \alpha Q x_k$ распадается на $z_{k+1,i} = (1 - \alpha\lambda_i)\, z_{k,i}$, и $f(x_k) = \frac{1}{2}\bigl(\lambda_1 z_{k,1}^2 + \lambda_2 z_{k,2}^2\bigr)$, поэтому $f(x_0) = 22$.

2. Для сходимости из любой начальной точки нужно $|1 - \alpha\lambda_i| < 1$ при обоих i, то есть $0 < \alpha < 2/\lambda_i$. Пологая координата допускает $\alpha < 2/\mu = 2$, жёсткая — только $\alpha < 2/L = 0{,}2$. Границу задаёт жёсткое направление: $0 < \alpha < 0{,}2$.

3. Множители для четырёх шагов:

α	$1 - \alpha\lambda_1$	$1 - \alpha\lambda_2$
0,05	0,95	0,5
0,19	0,81	$-0{,}9$
0,2	0,8	-1
0,21	0,79	$-1{,}1$

4. $\alpha = 0{,}05$: оба множителя лежат в $(0, 1)$, поэтому обе координаты убывают, не меняя знака. Жёсткая уменьшается вдвое на каждом шаге, пологая теряет лишь двадцатую часть. После десяти шагов $f = 0{,}7170$, и почти всё это значение приходится на пологую координату. Сходится, но медленно.

5. $\alpha = 0{,}19$: множитель жёсткой координаты $-0{,}9$ отрицателен, поэтому $z_{k,2}$ меняет знак на каждом шаге, но по модулю всё равно убывает. Сходится со сменой знака. Вначале преобладает жёсткая координата: на неё приходится 20 из $f(x_0) = 22$, и здесь она по модулю умножается на $|-0{,}9|$, а при $\alpha = 0{,}05$ — на 0,5, поэтому после десяти итераций этот шаг отстаёт: $f = 2{,}4611$ против 0,7170. Но на длинной дистанции темп задаёт больший по модулю множитель, здесь $|-0{,}9|$ против 0,95, и после пятидесяти итераций этот шаг далеко впереди: $f = 5{,}31 \cdot 10^{-4}$ против $1{,}18 \cdot 10^{-2}$.

6. $\alpha = 0{,}2 = 2/L$: множитель жёсткой координаты равен ровно -1. Жёсткая координата без конца перескакивает между $+2$ и -2 и сама по себе на каждом шаге даёт в f вклад $\frac{1}{2} \cdot 10 \cdot 2^2 = 20$. Пологая координата по-прежнему умножается на 0,8, поэтому $f(x_k) = 20 + 2 \cdot 0{,}64^k$: значение убывает к 20 и никогда не опускается ниже (20,0231 после десяти шагов). Ни сходимости к x^*, ни расходимости.

7. $\alpha = 0{,}21$: $|-1{,}1| > 1$, поэтому $|z_{k,2}|$ растёт на каждом шаге, а знак чередуется, и $f(x_k) \to \infty$: 134,5679 после десяти шагов, $2{,}76 \cdot 10^5$ после пятидесяти. Пологая координата сходится, но это не помогает. Расходится.

8. Границу задаёт наибольшее собственное значение, а скорость — наименьшее: при любом $\alpha < 2/L$ множитель пологой координаты $1 - \alpha\mu > 1 - 2/\kappa$. При большом κ приходится брать шаг, который почти не сдвигает пологую координату.

Ответ. Метод устойчив при $0 < \alpha < 2/L = 0{,}2$. $\alpha = 0{,}05$: сходится, медленно по пологой координате; 0,19: сходится со сменой знака жёсткой координаты; 0,2: жёсткая координата без конца перескакивает между ± 2, а $f(x_k)$ убывает к 20, не опускаясь ниже; 0,21: расходится.

A2. Гарантированное и фактическое число итераций

Самостоятельно

Условие. Запустите градиентный спуск для $f(x) = \frac{1}{2}x^\top Qx$, где $Q = \operatorname{diag}(1;\ 2)$, с шагом $\alpha = 1/L$ из $x_0 = (1;\ 1)$. Найдите **а)** κ; **б)** множитель q в оценке из лекции $f(x_k) - f^* \le q^k \left(f(x_0) - f^*\right)$; **в)** наименьшее k, при котором эта оценка даёт $f(x_k) - f^* \le 10^{-6}\left(f(x_0) - f^*\right)$; **г)** наименьшее k, при котором итерации на самом деле удовлетворяют этому неравенству.

Решение.

1. $L = \lambda_{\max} = 2$, $\mu = \lambda_{\min} = 1$, поэтому $\kappa = 2$ и $\alpha = 1/L = 0{,}5$.

2. Линейная скорость при $\alpha = 1/L$: $f(x_k) - f^* \le (1-\mu/L)^k \left(f(x_0) - f^*\right)$, поэтому $q = 1 - \mu/L = 0{,}5$.

3. Множитель в оценке опускается до 10^{-6}, когда $0{,}5^k \le 10^{-6}$, то есть $k \ge \dfrac{\ln 10^{-6}}{\ln 0{,}5} = 19{,}93$. Округляем вверх: 20 итераций.

4. Теперь сами итерации; здесь $f^* = 0$. Множители $1 - \alpha\lambda_i$ равны 0,5 для $\lambda = 1$ и 0 для $\lambda = 2$: жёсткая координата обнуляется после первого же шага.

5. Тогда $f(x_0) = \frac{1}{2}\left(1 + 2\right) = 1{,}5$ и $f(x_k) = \frac{1}{2} \cdot 0{,}5^{2k}$ при $k \ge 1$. Дальше невязка за итерацию умножается на $0{,}5^2$, а не на 0,5.

6. $f(x_k) \le 10^{-6}\, f(x_0)$ означает $0{,}5^{2k} \le 2 \cdot 1{,}5 \cdot 10^{-6}$, то есть $k \ge \dfrac{\ln\left(2 \cdot 1{,}5 \cdot 10^{-6}\right)}{2 \ln 0{,}5} = 9{,}17$. На деле нужно 10 итераций.

7. Оценка слабее, потому что в её доказательстве используются только неравенство из леммы о спуске и $\|\nabla f\|^2 \ge 2\mu\,(f - f^*)$, а они верны для любой функции с такими μ и L. На квадратичной функции при $\alpha = 1/L$ каждое координатное слагаемое невязки умножается на $(1 - \lambda_i/L)^2 \le (1 - \mu/L)^2$.

Ответ. $\kappa = 2$, $q = 0{,}5$; по оценке нужно 20 итераций, на деле — 10.

A3. Плохо обусловленная чаша и оптимальный шаг

Самостоятельно

Условие. Та же постановка, что в A2, но $Q = \mathrm{diag}(1;\ 50)$ и $x_0 = (1;\ 1)$. **а)–г)** Найдите те же четыре величины при $\alpha = 1/L$. **д)** Найдите значение оптимального постоянного шага $\alpha^* = 2/(L+\mu)$. **е)** При шаге α^* каждая координата ошибки $x_k - x^*$ на каждом шаге умножается на множитель, модуль которого не больше $\rho = (\kappa - 1)/(\kappa + 1)$. Сколько итераций нужно по получающейся отсюда оценке разности $f(x_k) - f^*$ для того же уменьшения — до доли 10^{-6} от начального значения?

Решение.

1. $L = 50$, $\mu = 1$, $\kappa = 50$, $\alpha = 1/L = 0{,}02$ и $q = 1 - \mu/L = 0{,}98$.

2. Оценка: $k \ge \dfrac{\ln 10^{-6}}{\ln 0{,}98} = 683{,}84$, то есть 684 итераций.

3. Множители при $\alpha = 1/L$ равны $1 - \mu/L = 0{,}98$ и $1 - L/L = 0$. На жёсткую координату приходится $\frac{1}{2} \cdot 50$ из $f(x_0) = 25{,}5$, и после первого шага она обнуляется; дальше $f(x_k) = \frac{1}{2} \cdot 0{,}98^{2k}$ при $k \ge 1$.

4. $f(x_k) \le 10^{-6}\, f(x_0)$ означает $0{,}98^{2k} \le 2 \cdot 25{,}5 \cdot 10^{-6}$, то есть $k \ge \dfrac{\ln\left(2 \cdot 25{,}5 \cdot 10^{-6}\right)}{2 \ln 0{,}98} = 244{,}6$. На деле нужно 245 итераций, а по оценке — 684.

5. Оптимальный шаг: $\alpha^* = \dfrac{2}{L + \mu} = \frac{2}{51} \approx 0{,}039216$. Множители равны $1 - \alpha^*\mu = \frac{49}{51}$ и $1 - \alpha^* L = -\frac{49}{51}$: модули одинаковы, $\rho = \dfrac{\kappa - 1}{\kappa + 1} = \frac{49}{51} \approx 0{,}960784$.

6. Невязка квадратична по координатам, поэтому $f(x_k) - f^* \le \rho^{2k} \left(f(x_0) - f^*\right)$. По оценке нужно $k \ge \dfrac{\ln 10^{-6}}{2 \ln \rho} = 172{,}67$, то есть 173 итераций. Если взять ρ^k вместо ρ^{2k}, получится 346 — число итераций для расстояния $\|x_k - x^*\|$.

7. Здесь обе координаты по модулю умножаются ровно на ρ, поэтому $f(x_k) = \rho^{2k} f(x_0)$ в точности, и на деле тоже нужно 173 итераций. С шагом α^* оценка и фактическое число итераций совпадают; при $\alpha = 1/L$ они различаются почти втрое.

Ответ. $\kappa = 50$, $q = 0{,}98$; по оценке нужно 684 итераций, на деле — 245; $\alpha^* = \frac{2}{51} \approx 0{,}039216$, и оценка при α^* даёт 173 — ровно столько, сколько нужно на деле.

4 Линейный поиск и критерии остановки

Для постоянного шага нужна константа L, которая редко известна, а шаг, безопасный там, где f искривлена сильнее всего, в остальных местах слишком мал. Бэктрекинг выбирает шаг на каждой итерации по значениям f вдоль луча.

4.1 Бэктрекинг по Армихо

Определение: Бэктрекинг по Армихо. Зафиксируем начальный шаг $\alpha_0 > 0$, коэффициент уменьшения $\beta \in (0,1)$ и константу $c \in (0,1)$, и пусть d — направление спуска в точке x. Положим $\alpha = \alpha_0$ и будем повторять $\alpha \leftarrow \beta\alpha$ до тех пор, пока условие достаточного убывания (условие Армихо)

$$f(x + \alpha d) \le f(x) + c\,\alpha\,\nabla f(x)^{\top} d$$

не выполнится. Принимается первый шаг вида $\alpha = \beta^j \alpha_0$, $j = 0, 1, 2, \dots$, который проходит проверку. Для градиентного спуска $d = -\nabla f(x)$, и правая часть равна $f(x) - c\,\alpha \|\nabla f(x)\|^2$. Обычно берут $\beta = \frac{1}{2}$ и $c = 10^{-4}$.

Вдоль луча положим $\varphi(\alpha) = f(x + \alpha d)$, так что $\varphi(0) = f(x)$ и $\varphi'(0) = \nabla f(x)^{\top} d < 0$. Прямая Армихо $\varphi(0) + c\alpha\varphi'(0)$ — это касательная, у которой наклон умножен на c, поэтому при $\alpha > 0$ она лежит выше касательной. Так как $\varphi(\alpha) = \varphi(0) + \alpha\varphi'(0) + o(\alpha)$, короткие шаги проходят проверку; длинный шаг не проходит, когда кривизна загибает φ обратно выше этой прямой. Проверка отбрасывает шаги, убывание на которых составляет ничтожную долю того, что обещает наклон.

Теорема: Конечность бэктрекинга. Пусть f — L-гладкая функция, $\nabla f(x) \neq 0$, $d = -\nabla f(x)$, $\alpha_0 > 0$ и $\beta, c \in (0,1)$. Условие Армихо выполняется при всех $\alpha \in \big(0, 2(1-c)/L\big]$. Следовательно, бэктрекинг останавливается после конечного числа уменьшений, и принятый шаг удовлетворяет оценке

$$\alpha \ge \min\Big(\alpha_0,\ \frac{2\beta(1-c)}{L}\Big).$$

Доказательство. По оценке убывания за один шаг $f\big(x - \alpha\nabla f(x)\big) \le f(x) - \alpha\big(1 - \frac{L\alpha}{2}\big)\|\nabla f(x)\|^2$. Если $\alpha \le 2(1-c)/L$, то $1 - L\alpha/2 \ge c$, и правая часть не больше $f(x) - c\alpha\|\nabla f(x)\|^2$: условие Армихо выполнено. Пробные шаги $\beta^j\alpha_0$ стремятся к 0, поэтому при некотором конечном j они попадают в $\big(0, 2(1-c)/L\big]$, и цикл остановится не позже этого. Если α_0 проходит проверку, принимается шаг α_0. Иначе принятому шагу α предшествует отвергнутый пробный шаг α/β, каждый отвергнутый шаг больше $2(1-c)/L$, и поэтому $\alpha > 2\beta(1-c)/L$.

Доказательство заодно оценивает объём работы: число уменьшений не превосходит наименьшего $j \ge 0$, при котором $\beta^j\alpha_0 \le 2(1-c)/L$, то есть $\big\lceil \log_{1/\beta}\big(\alpha_0 L/(2(1-c))\big)\big\rceil$ при $\alpha_0 > 2(1-c)/L$.

Цикл может остановиться раньше, потому что вдоль конкретного направления условие может выполняться и за пределами $2(1-c)/L$. Для квадратичной функции диапазон известен точно: обозначим $g = \nabla f(x)$, тогда

$$f(x - \alpha g) = f(x) - \alpha\, g^\top g + \frac{\alpha^2}{2}\, g^\top Q g,$$

поэтому условие Армихо выполняется тогда и только тогда, когда $\alpha \le 2(1-c)\,\dfrac{g^\top g}{g^\top Q g}$, и эта величина не меньше $2(1-c)/L$, потому что $g^\top Q g \le L\, g^\top g$.

Пример. В задаче B1 $Q = \mathrm{diag}(1;\ 10)$, $x_0 = (2;\ 2)$, $L = 10$ и $c = 10^{-4}$. Теорема гарантирует принятие шага при $\alpha \le 2(1-c)/L = 0{,}19998$, а вдоль $d = -\nabla f(x_0)$ точный диапазон — $\alpha \le 0{,}20178$. Если делить шаг пополам, начиная с $\alpha_0 = 1$ первый пробный шаг, попадающий в оба диапазона, равен 0,125; он получается после 3 делений и лежит между $1/L = 0{,}1$ и $2/L = 0{,}2$.

Без L-гладкости бэктрекинг всё равно завершается для любого направления спуска d дифференцируемой функции f, потому что $f(x + \alpha d) - f(x) - c\alpha \nabla f(x)^\top d = (1-c)\,\alpha\, \nabla f(x)^\top d + o(\alpha)$ отрицательно при малых α. Пропадает только оценка снизу на принятый шаг.

Ловушка. Если d не является направлением спуска, короткие пробные шаги не проходят проверку, и цикл может никогда не закончиться. Поэтому в реализации проверяют $\nabla f(x)^\top d < 0$ и ограничивают число уменьшений.

4.2 Критерии остановки

В лекции используются три масштабированных критерия с допусками ε_g, ε_x и ε_f:

$$\|\nabla f(x_k)\| \le \varepsilon_g \max\big(1, |f(x_k)|\big),$$

$$\|x_{k+1} - x_k\| \le \varepsilon_x \max\big(1, \|x_k\|\big),$$

$$|f(x_{k+1}) - f(x_k)| \le \varepsilon_f \max\big(1, |f(x_k)|\big).$$

Множитель $\max(1, \cdot)$ делает проверку относительной, когда масштаб велик, и абсолютной, когда он меньше 1, так что от величины, близкой к нулю, не требуется недостижимая относительная точность.

В коде допуск часто разбивают на абсолютную и относительную части, $\mathrm{atol} + \mathrm{rtol} \cdot \max(1, s)$, где s — масштаб: $|f(x_k)|$ или $\|x_k\|$. В задаче B3 используется именно такая форма с $\mathrm{atol} = 10^{-8}$ и $\mathrm{rtol} = 10^{-6}$.

Критерии измеряют разное. Критерии по изменению следят за движением метода: для градиентного спуска $\|x_{k+1} - x_k\| = \alpha_k \|\nabla f(x_k)\|$ и $f(x_k) - f(x_{k+1}) \approx \alpha_k \|\nabla f(x_k)\|^2$, и обе величины малы, как только мал шаг, как бы далеко точка ни была от решения. Малые изменения могут означать сходимость, крошечный шаг, плохое масштабирование или застой из-за арифметики с плавающей точкой. Критерий по градиенту смотрит на саму точку. Малый градиент — сертификат стационарности первого порядка; при условии Поляка–Лоясевича (PL) он оценивает ошибку по f, а для μ-сильно выпуклой f — ещё и расстояние до x^*:

$$f(x) - f^* \le \frac{1}{2\mu}\|\nabla f(x)\|^2, \qquad \|x - x^*\| \le \frac{1}{\mu}\|\nabla f(x)\|.$$

Первое неравенство — это переписанное условие PL. Для второго запишем неравенство сильной выпуклости первого порядка в точках x и x^* и сложим: получится $\big(\nabla f(x) - \nabla f(x^*)\big)^\top (x -$

$x^*) \geq \mu\|x - x^*\|^2$; остаётся воспользоваться тем, что $\nabla f(x^*) = 0$, и неравенством Коши — Буняковского — Шварца.

Комбинированное правило

Сообщайте об успехе и останавливайтесь, когда выполнен критерий по градиенту с допуском, умноженным на $\max(1, |f(x_k)|)$, как в лекции. Критерии по изменению считайте лишь сигналом застоя: если они выполнены, а критерий по градиенту нет, остановитесь и сообщите, что метод застрял, а не сошёлся. Всегда добавляйте ограничение на число итераций и вычислений функции и останавливайтесь, если f или ∇f перестают быть конечными.

4.3 Критерий по изменению, срабатывающий слишком рано

В задаче B3 такой сбой построен намеренно. Возьмём $f(x) = \frac{1}{2}x^\top Qx$ с $Q = \operatorname{diag}(1;\ 50)$, так что $x^* = 0$ и $f^* = 0$, начнём с $x_0 = (1;\ 1)$, где $f(x_0) = 25{,}5$, и сделаем один шаг градиентного спуска с заданным шагом $\alpha = 10^{-8}$. Получаем $x_1 = (0{,}99999999,\ 0{,}9999995)$ и $f(x_1) = 25{,}49997499$. Три критерия с $\mathrm{atol} = 10^{-8}$ и $\mathrm{rtol} = 10^{-6}$ дают следующее.

Критерий	Значение	Порог	Срабатывает
изменение функции $\lvert f(x_1) - f(x_0)\rvert$	$2{,}501 \cdot 10^{-5}$	$\mathrm{atol} + \mathrm{rtol}\max(1, \lvert f(x_0)\rvert) = 2{,}551 \cdot 10^{-5}$	да
шаг $\lVert x_1 - x_0\rVert$	$5{,}001 \cdot 10^{-7}$	$\mathrm{atol} + \mathrm{rtol}\max(1, \lVert x_0\rVert) = 1{,}424 \cdot 10^{-6}$	да
градиент $\lVert\nabla f(x_1)\rVert$	50,01	$\mathrm{atol} + \mathrm{rtol}\max(1, \lvert f(x_1)\rvert) = 2{,}551 \cdot 10^{-5}$	нет

Оба критерия по изменению срабатывают после одного шага, хотя f уменьшилась меньше чем на миллионную долю своего значения, а точка почти не приблизилась к x^*. Только критерий по градиенту не даёт остановиться. Критерии по изменению срабатывают потому, что их левые части пропорциональны шагу: $\|x_1 - x_0\| = \alpha\|\nabla f(x_0)\|$ и $|f(x_1) - f(x_0)| \approx \alpha\|\nabla f(x_0)\|^2$, где $\|\nabla f(x_0)\| = 50{,}01$, и крошечный шаг делает обе величины крошечными. В критерии по градиенту множителя α нет — он измеряет градиент в самой точке x_1, а после крошечного шага градиент почти такой же, как в x_0: $\|\nabla f(x_1)\| \approx \|\nabla f(x_0)\|$.

4.4 Задачи семинара

Задачи блока B с полными решениями.

B1. Бэктрекинг по Армихо вручную

У доски

Условие. Пусть $f(x) = \frac{1}{2}x^\top Qx$, где $Q = \operatorname{diag}(1, 10)$, и $x_0 = (2;\ 2)$. Выполните бэктрекинг по Армихо вдоль $d = -\nabla f(x_0)$ с $\alpha_0 = 1$, $\beta = 0{,}5$ и $c = 10^{-4}$: сначала попробуйте $\alpha = \alpha_0$ и заменяйте $\alpha \leftarrow \beta\alpha$, пока $f(x_0 + \alpha d) > f(x_0) + c\alpha\nabla f(x_0)^\top d$. Сколько раз шаг делится пополам, прежде чем условие выполнится, какой шаг принимается и как он соотносится с $1/L$ и $2/L$?

Решение.

1. Данные в точке x_0: $f(x_0) = 22$, $\nabla f(x_0) = Qx_0 = (2;\ 20)$ и $\nabla f(x_0)^\top d = -\|\nabla f(x_0)\|^2 = -404$. Здесь $L = 10$, $1/L = 0{,}1$ и $2/L = 0{,}2$.
2. Вдоль луча у каждой координаты свой множитель: $x_0 + \alpha d = \big(2(1-\alpha),\ 2(1-10\alpha)\big)$. Условие принимает вид $f(x_0 + \alpha d) \leq 22 - 10^{-4} \cdot 404\,\alpha$.

3. Попытки с делением шага пополам, начиная с α_0:

α	$f(x_0+\alpha d)$	$f(x_0)+c\alpha\nabla f(x_0)^\top d$	выполнено
1	1620	21,9596	нет
0,5	320,5	21,9798	нет
0,25	46,125	21,9899	нет
0,125	2,78125	21,99495	да

4. Первая попытка, прошедшая проверку, — $\alpha = 0{,}125$ после 3 делений пополам, и на ней цикл останавливается. Этот шаг лежит между $1/L = 0{,}1$ и $2/L = 0{,}2$, то есть внутри области устойчивости из блока А.

5. Почему цикл обязательно остановится: лемма о спуске даёт $f(x_0+\alpha d) \le f(x_0) - \alpha(1 - L\alpha/2)\|\nabla f(x_0)\|^2$, поэтому условие выполнено при всех $\alpha \le 2(1-c)/L = 0{,}19998$. Каждая отвергнутая попытка больше этой границы, так что принятый шаг не меньше этой границы, умноженной на β.

6. Для квадратичной функции неравенство Армихо решается точно. Обозначим $g = \nabla f(x_0)$; тогда $f(x_0 - \alpha g) = f(x_0) - \alpha\|g\|^2 + \frac{1}{2}\alpha^2 g^\top Q g$, и условие выполнено при $\alpha \le 2(1-c)\|g\|^2/(g^\top Q g) = 0{,}20178$. Это чуть больше 0,19998, потому что кривизна вдоль g меньше L. Минимум вдоль луча достигается при шаге $\|g\|^2/(g^\top Q g) = 0{,}1009$, но бэктрекинг по Армихо его не ищет.

Ответ. Число делений пополам: 3; принятый шаг $\alpha = 0{,}125$ лежит между $1/L = 0{,}1$ и $2/L = 0{,}2$; условие выполнено при всех $\alpha \le 2(1-c)/L = 0{,}19998$.

B2. Бэктрекинг на более жёсткой квадратичной функции

Самостоятельно

Условие. Пусть $f(x) = \frac{1}{2}x^\top Q x$, где $Q = \mathrm{diag}(1, 50)$, и $x_0 = (2;\ 2)$. Выполните тот же бэктрекинг, что в B1, вдоль $d = -\nabla f(x_0)$ с $\alpha_0 = 1$, $\beta = 0{,}5$ и $c = 10^{-4}$: сначала попробуйте $\alpha = \alpha_0$ и заменяйте $\alpha \leftarrow \beta\alpha$, пока $f(x_0+\alpha d) > f(x_0) + c\alpha\nabla f(x_0)^\top d$. Сколько раз шаг делится пополам, какой шаг принимается и где он лежит относительно $1/L$ и $2/L$?

Решение.

1. Данные: $f(x_0) = 102$, $\nabla f(x_0) = (2;\ 100)$, $\|\nabla f(x_0)\|^2 = 10004$; $L = 50$, $1/L = 0{,}02$, $2/L = 0{,}04$. Так как $x_0 + \alpha d = \big(2(1-\alpha),\ 2(1-50\alpha)\big)$, условие имеет вид $f(x_0+\alpha d) \le 102 - 10^{-4}\cdot 10004\,\alpha$.

2. Таблица попыток: шаг делится пополам, начиная с α_0:

α	$f(x_0+\alpha d)$	$f(x_0)+c\alpha\nabla f(x_0)^\top d$	выполнено
1	240100	100,9996	нет
0,5	57600,5	101,4998	нет
0,25	13226,125	101,7499	нет
0,125	2757,78125	101,87495	нет
0,0625	453,3203125	101,937475	нет
0,03125	33,517578125	101,9687375	да

3. Условие Армихо впервые выполняется при $\alpha = 0{,}03125$, после 5 делений пополам. Как и в B1, этот шаг лежит между $1/L = 0{,}02$ и $2/L = 0{,}04$.

4. Гарантия: любой шаг $\alpha \le 2(1-c)/L = 0{,}039996$ проходит проверку, а эта граница чуть меньше $2/L$. Попытки пересекают эту границу между 0,0625 и 0,03125, и принятый шаг не меньше этой границы, умноженной на β.

5. Точный порог для этой квадратичной функции: $2(1-c)\|g\|^2/(g^\top Qg) = 0{,}040012$ при $g = \nabla f(x_0)$, а это чуть больше $2/L$. Условие Армихо проверяет убывание за один шаг, а не устойчивость: попытка чуть больше $2/L$ здесь прошла бы проверку, хотя градиентный спуск с таким постоянным шагом расходится.

6. По сравнению с B1 константа L выросла с 10 до 50, и бэктрекингу понадобилось 5 делений пополам вместо 3. В обеих задачах принятый шаг попадает между $1/L$ и $2/L$, хотя L бэктрекинг ни разу не использовал.

Ответ. Число делений пополам: 5; принятый шаг $\alpha = 0{,}03125$ лежит между $1/L = 0{,}02$ и $2/L = 0{,}04$ и меньше гарантированной границы $2(1-c)/L = 0{,}039996$.

B3. Три критерия остановки после крошечного шага

Самостоятельно

Условие. Пусть $f(x) = \frac{1}{2}x^\top Qx$, где $Q = \mathrm{diag}(1, 50)$, и $x_0 = (1;\ 1)$. Сделайте один градиентный шаг $x_1 = x_0 - \alpha\nabla f(x_0)$ с заданным шагом $\alpha = 10^{-8}$. При $\mathrm{atol} = 10^{-8}$, $\mathrm{rtol} = 10^{-6}$ и евклидовых нормах проверьте три критерия с учётом масштаба

$$\begin{aligned} \text{градиент:} &\quad \|\nabla f(x_1)\| \le \mathrm{atol} + \mathrm{rtol}\cdot\max(1, |f(x_1)|), \\ \text{шаг:} &\quad \|x_1 - x_0\| \le \mathrm{atol} + \mathrm{rtol}\cdot\max(1, \|x_0\|), \\ \text{функция:} &\quad |f(x_1) - f(x_0)| \le \mathrm{atol} + \mathrm{rtol}\cdot\max(1, |f(x_0)|). \end{aligned}$$

Критерий срабатывает, когда его неравенство выполнено. Найдите $|f(x_1)-f(x_0)|$, $\|\nabla f(x_1)\|$ и число сработавших критериев. Близка ли точка x_1 к точке минимума? Затем сформулируйте комбинированный критерий остановки и укажите, на какую величину он нормирован.

Решение.

1. Один шаг: $\nabla f(x_0) = Qx_0 = (1, 50)$, $\|\nabla f(x_0)\| = 50{,}01$ и $x_1 = x_0 - \alpha\nabla f(x_0) = (0{,}99999999,\ 0{,}9999995)$.

2. Критерий по функции: $f(x_0) = 25{,}5$ и $f(x_1) = 25{,}49997499$, поэтому $|f(x_1)-f(x_0)| = 2{,}501\cdot 10^{-5}$, что совпадает с первым приближением $\alpha\|\nabla f(x_0)\|^2$. Порог равен $\mathrm{atol} + \mathrm{rtol}\cdot 25{,}5 = 2{,}551\cdot 10^{-5}$: критерий срабатывает.

3. Критерий по шагу: $\|x_1 - x_0\| = \alpha\|\nabla f(x_0)\| = 5{,}001\cdot 10^{-7}$ при пороге $\mathrm{atol}+\mathrm{rtol}\cdot\max(1, \|x_0\|) = \mathrm{atol} + \mathrm{rtol}\sqrt{2} = 1{,}424\cdot 10^{-6}$: он тоже срабатывает.

4. Критерий по градиенту: $\|\nabla f(x_1)\| = 50{,}01$, почти как в точке x_0, а порог равен $\mathrm{atol} + \mathrm{rtol}\cdot\max(1, |f(x_1)|) = 2{,}551\cdot 10^{-5}$. Этот критерий не срабатывает, так что из 3 критериев срабатывают 2.

5. Точка минимума — $x^* = 0$, и в ней $f^* = 0$, а у нас $\|x_1 - x^*\| \approx \sqrt{2}$ и $f(x_1) \approx f(x_0)$. Критерии по изменениям сработали потому, что оба изменения уменьшаются вместе с α (в первом приближении они ему пропорциональны): они измеряют шаг, а не расстояние до x^*.

6. Общее правило: объявляйте сходимость, только если $\|\nabla f(x_k)\| \le \mathrm{atol}+\mathrm{rtol}\cdot\max(1, |f(x_k)|)$, то есть по норме градиента с масштабом $\max(1, |f(x_k)|)$. Если срабатывают только критерии по изменениям, останавливайтесь с предупреждением о застое и не выдавайте точку за решение; всегда ограничивайте число итераций и останавливайтесь при бесконечных или нечисловых значениях.

Ответ. $|f(x_1) - f(x_0)| = 2{,}501 \cdot 10^{-5}$ и $\|x_1 - x_0\| = 5{,}001 \cdot 10^{-7}$ меньше своих порогов, а $\|\nabla f(x_1)\| = 50{,}01$ — нет: 2 критерия срабатывают далеко от $x^* = 0$. Останавливайтесь по норме градиента с масштабом $\max(1, |f(x_k)|)$, а критерии по изменениям считайте только сигналом застоя и ограничивайте число итераций.

5 Скорость сходимости

В лекции доказаны три оценки для градиентного спуска с шагом $\alpha = 1/L$: для выпуклых функций невязка по функции имеет порядок $1/k$, а для сильно выпуклых функций и, в более общем случае, при условии PL она на каждом шаге умножается на $1 - \mu/L$. Все три доказательства начинаются с неравенства для шага спуска из раздела о градиентном спуске: для L-гладкой f и $x_{k+1} = x_k - \frac{1}{L}\nabla f(x_k)$ лемма о спуске даёт

$$f(x_{k+1}) \le f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2.$$

В частности, $f(x_k)$ никогда не возрастает. Всюду ниже $f^* = \inf f$, а x^* — точка минимума, если она существует.

5.1 Выпуклый случай

Теорема: Скорость сходимости для выпуклых функций. Пусть f — выпуклая L-гладкая функция, x^* — точка минимума, $f^* = f(x^*)$. Тогда для градиентного спуска с $\alpha = 1/L$ выполнено

$$f(x_k) - f^* \le \frac{L\|x_0 - x^*\|^2}{2k} \qquad \text{для всех } k \ge 1.$$

Доказательство. Обозначим $g_k = \nabla f(x_k)$. По выпуклости касательная плоскость в точке x_k лежит под графиком, поэтому $f^* \ge f(x_k) + g_k^\top(x^* - x_k)$, то есть $f(x_k) \le f^* + g_k^\top(x_k - x^*)$. Подставив это в неравенство для шага спуска, получаем

$$f(x_{k+1}) - f^* \le g_k^\top(x_k - x^*) - \frac{1}{2L}\|g_k\|^2.$$

Правая часть — разность квадратов расстояний. Так как $x_{k+1} - x^* = (x_k - x^*) - \frac{1}{L}g_k$, раскрыв квадрат, получаем тождество трёх точек

$$\|x_{k+1} - x^*\|^2 = \|x_k - x^*\|^2 - \frac{2}{L}\,g_k^\top(x_k - x^*) + \frac{1}{L^2}\|g_k\|^2,$$

а умножив это тождество на $L/2$, превращаем предыдущее неравенство в ключевое:

$$f(x_{k+1}) - f^* \le \frac{L}{2}\Big(\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2\Big).$$

Просуммируем его по шагам $0, 1, \dots, k-1$: правая часть сокращается телескопически:

$$\sum_{j=1}^{k}\big(f(x_j) - f^*\big) \le \frac{L}{2}\Big(\|x_0 - x^*\|^2 - \|x_k - x^*\|^2\Big) \le \frac{L}{2}\|x_0 - x^*\|^2.$$

Наконец, последовательность $f(x_j)$ не возрастает, поэтому каждое из k слагаемых слева не меньше $f(x_k) - f^*$. Отсюда $k\big(f(x_k) - f^*\big) \le \frac{L}{2}\|x_0 - x^*\|^2$.

У ключевого неравенства есть и второе следствие. Его левая часть неотрицательна, поэтому $\|x_{k+1} - x^*\| \le \|x_k - x^*\|$: итерации никогда не удаляются ни от одной точки минимума.

> **Почему.** Каждый шаг оплачивает свою невязку уменьшением квадрата расстояния до x^*, а весь бюджет равен $\|x_0 - x^*\|^2$. Поэтому в среднем по первым k шагам невязки малы, а раз они только убывают, последняя не больше среднего.

Скорость **сублинейная**: чтобы уменьшить оценку вдвое, нужно вдвое больше шагов, а невязка меньше ε гарантирована только после $L\|x_0 - x^*\|^2/(2\varepsilon)$ шагов.

> **Проверьте себя.** Теорема верна для любой точки минимума x^*. Если точки минимума образуют целое множество, какая из них даёт лучшую оценку?
>
> **Ответ.** Ближайшая к x_0. Во всех точках минимума функция принимает одно и то же значение f^*, а больше ничего об x^* доказательство не использует, поэтому $\|x_0 - x^*\|$ можно заменить расстоянием от x_0 до множества точек минимума.

5.2 Сильная выпуклость

Дифференцируемая функция f называется μ-**сильно выпуклой**, $\mu > 0$, если

$$f(y) \ge f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2}\|y - x\|^2 \qquad \text{для всех } x, y.$$

Для L-гладкой f лемма о спуске добавляет оценку сверху, и выражение $f(y) - f(x) - \nabla f(x)^\top (y - x)$ оказывается зажатым между $\frac{\mu}{2}\|y - x\|^2$ и $\frac{L}{2}\|y - x\|^2$, поэтому $\mu \le L$ и $\kappa = L/\mu \ge 1$.

> **Лемма: Из сильной выпуклости следует условие PL.** Если f — μ-сильно выпуклая функция, то для любого x
>
> $$\frac{1}{2}\|\nabla f(x)\|^2 \ge \mu\big(f(x) - f^*\big).$$

> *Доказательство.* Зафиксируем x и обозначим $g = \nabla f(x)$. Правая часть определения — квадратичная функция от y:
>
> $$q(y) = f(x) + g^\top (y - x) + \frac{\mu}{2}\|y - x\|^2.$$
>
> Её градиент $g + \mu(y - x)$ обращается в нуль при $y = x - g/\mu$, поэтому её наименьшее значение равно
>
> $$q\Big(x - \frac{g}{\mu}\Big) = f(x) - \frac{1}{\mu}\|g\|^2 + \frac{1}{2\mu}\|g\|^2 = f(x) - \frac{1}{2\mu}\|g\|^2.$$
>
> Значит, $f(y) \ge q(y) \ge f(x) - \frac{1}{2\mu}\|g\|^2$ для любого y. Переходя к инфимуму по y, получаем $f^* \ge f(x) - \frac{1}{2\mu}\|g\|^2$; остаётся умножить на μ и перенести слагаемые.

> **Теорема: Линейная скорость при сильной выпуклости.** Пусть f — μ-сильно выпуклая и L-гладкая функция. Тогда для градиентного спуска с $\alpha = 1/L$ выполнено
>
> $$f(x_{k+1}) - f^* \le \Big(1 - \frac{\mu}{L}\Big)\big(f(x_k) - f^*\big), \qquad f(x_k) - f^* \le \Big(1 - \frac{\mu}{L}\Big)^k \big(f(x_0) - f^*\big).$$

Доказательство. Вычтем f^* из обеих частей неравенства для шага спуска и оценим слагаемое с градиентом снизу по лемме: $\frac{1}{2L}\|\nabla f(x_k)\|^2 \geq \frac{\mu}{L}\big(f(x_k) - f^*\big)$. Получаем

$$f(x_{k+1}) - f^* \leq f(x_k) - f^* - \frac{1}{2L}\|\nabla f(x_k)\|^2 \leq \Big(1 - \frac{\mu}{L}\Big)\big(f(x_k) - f^*\big).$$

Применив это неравенство k раз, получаем второе.

Множитель $1 - \mu/L = 1 - 1/\kappa$ лежит в $[0, 1)$. Оценка вида Cq^k с $q < 1$ называется **линейной скоростью сходимости**: в логарифмическом масштабе оценка убывает по прямой.

Почему. Сильная выпуклость не даёт градиенту быть малым, пока невязка велика. Поэтому с шагом $1/L$ каждая итерация убирает по меньшей мере долю μ/L оставшейся невязки.

Проверьте себя. Возьмём $f(x) = \frac{1}{2}x^\top Qx$ с $\kappa = 1$. Что даёт теорема и что на самом деле делает градиентный спуск с $\alpha = 1/L$?

Ответ. Множитель равен $1 - \mu/L = 0$, поэтому невязка обращается в нуль за один шаг. Действительно, $\kappa = 1$ означает, что $Q = LI$, и $x_1 = x_0 - \frac{1}{L} \cdot Lx_0 = 0 = x^*$.

5.3 Условие Поляка–Лоясевича

Доказательство выше использовало сильную выпуклость только один раз — через неравенство из леммы. Это неравенство и есть условие PL, и его одного достаточно.

Теорема: Линейная скорость при условии PL. Пусть f — L-гладкая функция с $f^* = \inf f > -\infty$, удовлетворяющая условию Поляка–Лоясевича с некоторым $\mu > 0$:

$$\frac{1}{2}\|\nabla f(x)\|^2 \geq \mu\big(f(x) - f^*\big) \qquad \text{для всех } x.$$

Тогда для градиентного спуска с $\alpha = 1/L$ выполнено $f(x_k) - f^* \leq (1 - \mu/L)^k\big(f(x_0) - f^*\big)$.

Доказательство. Неравенство для шага спуска даёт $f(x_{k+1}) \leq f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2$, а условие PL оценивает вычитаемое снизу величиной $\frac{\mu}{L}\big(f(x_k) - f^*\big)$. Вычитая f^*, получаем $f(x_{k+1}) - f^* \leq (1 - \mu/L)\big(f(x_k) - f^*\big)$, и остаётся применить это неравенство шаг за шагом. Выпуклость нигде не использовалась.

Условие PL означает, что градиент велик везде, где велика невязка. В стационарной точке левая часть равна 0, поэтому $f(x) = f^*$: **любая стационарная точка — точка глобального минимума**. Обычно для этого и нужна выпуклость, а PL даёт то же самое без неё.

Пример. Функция $f(x) = x^2 + 3\sin^2 x$ на $\mathbb{R}$ удовлетворяет условию PL, но не выпукла. Она не выпукла, потому что $f''(x) = 2 + 6\cos 2x$ при $x = \pi/2$ равна $2 - 6 < 0$. Она L-гладкая с $L = 8$, так как $|f''| \leq 8$. Её единственная стационарная точка — точка минимума 0: при $0 < x < \frac{3}{2}$ оба слагаемых в $f'(x) = 2x + 3\sin 2x$ положительны, при $x \geq \frac{3}{2}$ имеем $2x \geq 3 \geq -3\sin 2x$, причём оба неравенства не обращаются в равенства одновременно, а f' нечётна. Поэтому отношение $\frac{1}{2}f'(x)^2/f(x)$ непрерывно и положительно при $x \neq 0$. При $x \to 0$ оно стремится к 8, поскольку там $f(x) \approx 4x^2$ и $f'(x) \approx 8x$, а при $|x| \to \infty$ — к 2. Значит, его инфимум положителен, и условие PL выполнено с μ, равным этому инфимуму.

Ловушка. Условие PL и выпуклость независимы. Функция из примера выше удовлетворяет PL, но не выпукла. Функция $f(x) = x^4$ выпукла, но условию PL не удовлетворяет: $\frac{1}{2}f'(x)^2 = 8x^6$ меньше μx^4 при любом $\mu > 0$, как только $|x|$ достаточно мало. Вблизи точки минимума функция x^4 слишком пологая для линейной скорости сходимости.

5.4 Число обусловленности и число итераций

При $\alpha = 1/L$ оценка имеет вид $f(x_k) - f^* \le (1 - 1/\kappa)^k \big(f(x_0) - f^*\big)$. Чтобы невязка уменьшилась до доли ε от начальной, достаточно, чтобы $(1 - 1/\kappa)^k \le \varepsilon$, то есть

$$k \ge \frac{\ln \varepsilon}{\ln(1 - 1/\kappa)},$$

где оба логарифма отрицательны. Так как $\ln(1 - 1/\kappa) \le -1/\kappa$, правая часть не больше $\kappa \ln(1/\varepsilon)$, а при больших κ близка к этой величине. Число итераций растёт линейно по κ и лишь логарифмически по точности: это и есть $O(\kappa \log(1/\varepsilon))$ из лекции.

Пример. Возьмём $\kappa = 1000$ и $\varepsilon = 10^{-6}$. Тогда $\ln \varepsilon / \ln(1 - 1/\kappa)$ после округления вверх даёт $k = 13809$, а оценка $\kappa \ln(1/\varepsilon)$ — примерно 13816. Для квадратичной функции оптимальный шаг $2/(L + \mu)$ умножает каждую собственную компоненту ошибки на число, по модулю не большее $\rho = (\kappa - 1)/(\kappa + 1)$, поэтому за шаг невязка умножается не более чем на ρ^2, и для того же уменьшения нужно

$$k \ge \frac{\ln \varepsilon}{2 \ln \rho},$$

то есть $k = 3454$. Это примерно четверть числа итераций при шаге $1/L$, потому что $\ln \rho \approx -2/\kappa$ при больших κ.

Эти числа — гарантии, и на деле метод может сойтись намного быстрее. В A2 при $\kappa = 2$ оценка даёт 20 итераций, а фактически нужно 10; в A3 при $\kappa = 50$ оценка даёт 684, а фактически нужно 245. Разницу объясняют два эффекта. Для квадратичной функции с шагом $\alpha = 1/L$ за каждый шаг i-я собственная компонента невязки умножается на $(1 - \lambda_i/L)^2$, так что самая медленная умножается на $(1 - \mu/L)^2$, то есть на квадрат гарантированного множителя; уже одно это вдвое сокращает число итераций. Кроме того, жёсткая компонента исчезает на первом же шаге, ведь её множитель равен $1 - L/L = 0$: в A3 имеем $f(x_0) = 25{,}5$, но $f(x_k) = \frac{1}{2}\,(0{,}98)^{2k}$ при $k \ge 1$.

С оптимальным шагом $2/(L + \mu) = \frac{2}{51}$ обе компоненты A3 за шаг умножаются на число, по модулю равное ровно $\frac{49}{51}$, оценка $f(x_k) \le \rho^{2k} f(x_0)$ выполняется как равенство, и оценка совпадает с фактическим числом итераций: 173 в обоих случаях.

Проверьте себя. Что происходит с числом итераций при фиксированном κ, если заменить ε на ε^2?

Ответ. Оно удваивается: число итераций пропорционально $\ln(1/\varepsilon)$, а $\ln(1/\varepsilon^2) = 2\ln(1/\varepsilon)$. Чтобы уменьшить невязку на вдвое большее число порядков, нужно вдвое больше итераций; при больших κ вдвое большее число обусловленности тоже примерно удваивает число итераций.

6 Автоматическое дифференцирование в обратном режиме

Градиентному спуску на каждом шаге нужен ∇f. **Автоматическое дифференцирование** (AD) получает его из программы, которая вычисляет f: цепное правило (правило дифференцирования сложной функции) применяется к элементарным операциям по одной, и результат точен, если не считать ошибок округления. Обратный режим выдаёт весь градиент за время, в небольшое постоянное число раз превышающее стоимость одного вычисления f, сколько бы ни было переменных. Здесь всё делается вручную на небольших графах.

6.1 Вычисление как граф

Программа вычисляет f через последовательность промежуточных переменных, каждая из которых — элементарная функция предыдущих. В примере из лекции $z = \sin(xy) + x^2$:

$$u = xy, \qquad v = \sin u, \qquad w = x^2, \qquad z = v + w.$$

Вершины графа — входы x, y и промежуточные переменные u, v, w, z; ребро $a \to b$ означает, что b использует a. Каждая переменная использует только более ранние, поэтому циклов нет: это **ориентированный ациклический граф** (DAG). Порядок x, y, u, v, w, z, в котором программа вычисляет вершины, — **топологический порядок**: все рёбра в нём направлены вперёд.

Каждая вершина знает свои локальные частные производные: $\partial u/\partial x = y$, $\partial u/\partial y = x$, $\partial v/\partial u = \cos u$, $\partial w/\partial x = 2x$, $\partial z/\partial v = \partial z/\partial w = 1$. AD комбинирует эти числа по цепному правилу и никогда не строит формулу для $\partial z/\partial x$ целиком.

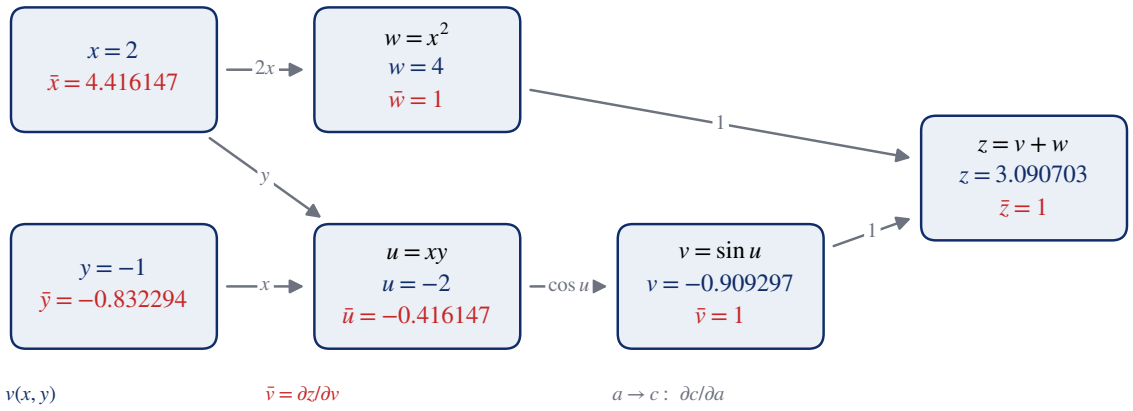


Рисунок. Граф задачи C1 в точке $(x, y) = (2;\ -1)$. Значения на прямом проходе: $u = -2$, $v = -0{,}909297$, $w = 4$, $z = 3{,}090703$. Сопряжённые переменные обратного прохода: $\bar z = \bar v = \bar w = 1$, $\bar u = \cos u = -0{,}416147$, $\bar x = 4{,}416147$, $\bar y = -0{,}832294$.

6.2 Прямой режим

Выберем направление $(\dot x, \dot y)$ в пространстве входов и будем вместе с каждым значением переносить его **касательное значение**: производную этого значения по выбранному направлению. Касательные значения распространяются по графу вперёд с теми же локальными производными:

$$\dot u = y\dot x + x\dot y, \qquad \dot v = \cos(u)\,\dot u, \qquad \dot w = 2x\,\dot x, \qquad \dot z = \dot v + \dot w.$$

Для отображения $F : \mathbb{R}^n \to \mathbb{R}^m$ с якобианом J один прямой проход с начальным вектором $\dot x \in \mathbb{R}^n$ возвращает **произведение якобиана на вектор** $J\dot x$. Для скалярной f это производная

по направлению $\nabla f(x)^\top \dot{x}$, одно число, так что для полного градиента нужно n проходов, по одному на каждый базисный вектор $e_1, \dots, e_n$.

Пример. В точке задачи C1 с начальным вектором $\dot{x} = 1$, $\dot{y} = 0$ один проход даёт $\dot{z} = y\cos u + 2x = 4{,}416147$ — частную производную по x. Для производной по y нужен второй проход с $\dot{x} = 0$, $\dot{y} = 1$.

6.3 Обратный режим

Для скалярного выхода z **сопряжённая переменная** вершины v — это $\bar{v} = \partial z / \partial v$, производная выхода по этой вершине с учётом всего, что вычисляется из неё дальше. Начнём с $\bar{z} = 1$, все остальные сопряжённые переменные положим равными 0, обойдём вершины в обратном топологическом порядке и для каждого ребра $u \to v$ прибавим вклад

$$\bar{u} \mathrel{+}= \bar{v}\,\frac{\partial v}{\partial u}.$$

Когда обход доходит до вершины, все вершины, которые её используют, уже обработаны, поэтому её сопряжённая переменная уже вычислена полностью. Одной формулой:

$$\bar{v}_i = \sum_{j:\ i \to j} \bar{v}_j\,\frac{\partial v_j}{\partial v_i},$$

где сумма берётся по всем вершинам j, использующим v_i.

В примере: $\bar{z} = 1$; вершина $z = v + w$ даёт $\bar{v} = 1$ и $\bar{w} = 1$; $w = x^2$ даёт $\bar{x} \mathrel{+}= 2x$; $v = \sin u$ даёт $\bar{u} = \cos u$; $u = xy$ даёт $\bar{x} \mathrel{+}= y\cos u$ и $\bar{y} \mathrel{+}= x\cos u$. Следовательно,

$$\bar{x} = y\cos u + 2x = \frac{\partial z}{\partial x}, \qquad \bar{y} = x\cos u = \frac{\partial z}{\partial y}.$$

Один обратный проход дал обе частные производные.

Для $F : \mathbb{R}^n \to \mathbb{R}^m$ обратный проход, начатый с вектора $\bar{z} \in \mathbb{R}^m$, возвращает **произведение вектора на якобиан** $\bar{z}^\top J$. Для скалярной функции потерь ($m = 1$, $\bar{z} = 1$) это весь градиент за один проход, каким бы ни было n. Обратный режим, применённый к модели со скалярной функцией потерь и множеством параметров, — это **обратное распространение ошибки** (backpropagation).

6.4 Почему сопряжённые переменные накапливаются

Вершина, от которой зависят несколько других, получает вклад по каждому выходящему ребру, и цепное правило для функций многих переменных эти вклады складывает. Для $z = x^2 + x^3$ с вершинами $a = x^2$, $b = x^3$, $z = a + b$:

$$\frac{dz}{dx} = \frac{\partial z}{\partial a}\frac{da}{dx} + \frac{\partial z}{\partial b}\frac{db}{dx} = 2x + 3x^2.$$

Поэтому правило и записано через $+=$: сопряжённая переменная $\bar{x}$ собирает $2x$ от a и $3x^2$ от b. Реализация, которая присваивает вместо того, чтобы прибавлять, сохраняет только вклад последнего обработанного ребра, то есть $2x$ или $3x^2$, и неверный ответ ещё и зависит от порядка обхода.

В общем случае $\partial z / \partial x$ — это сумма по всем путям из x в z произведений локальных производных вдоль пути. Обратный проход вычисляет эту сумму, не перечисляя путей: сопряжённая переменная каждой вершины уже содержит сумму по всем путям из этой вершины в z. В C1 вход x используется в u и w, поэтому у $\bar{x}$ два слагаемых; в C2 он входит и в xy, и в $xy + x$.

Ловушка. По той же причине фреймворки накапливают градиенты параметров от вызова к вызову. Перед вычислением нового градиента сохранённые сопряжённые переменные нужно обнулить, иначе новый градиент прибавится к старому.

6.5 Стоимость и память

Пусть $f : \mathbb{R}^n \to \mathbb{R}$ вычисляется за N элементарных операций. И прямой, и обратный проход выполняют ограниченный объём работы на каждую операцию, поэтому каждый из них в небольшое постоянное число раз дороже одного вычисления f. Режимы различаются числом проходов.

Свойство	Прямой режим	Обратный режим
Начальный вектор	направление $\dot{x} \in \mathbb{R}^n$	веса выходов $\bar{z} \in \mathbb{R}^m$
Один проход даёт	$J\dot{x}$ — произведение якобиана на вектор	$\bar{z}^\top J$ — произведение вектора на якобиан
Градиент $f : \mathbb{R}^n \to \mathbb{R}$	n проходов	один прямой и один обратный проход
Якобиан $F : \mathbb{R}^n \to \mathbb{R}^m$	n проходов	m проходов
Дополнительная память	по одному касательному значению на каждое используемое значение	все промежуточные значения (лента)

Обратный режим дёшев по числу операций, но не по памяти. Локальным производным нужны значения прямого прохода ($\partial v/\partial u = \cos u$ требует u), поэтому прямой проход должен записать все промежуточные значения — **ленту**, — прежде чем начнётся обратный, и память растёт с длиной вычисления.

Контрольные точки (checkpointing) позволяют экономить память за счёт дополнительных вычислений. Прямой проход сохраняет только часть промежуточных значений — контрольные точки; во время обратного прохода каждый участок между двумя контрольными точками пересчитывается от предыдущей из них, когда понадобятся его значения. Если взять около $\sqrt{N}$ контрольных точек через каждые $\sqrt{N}$ операций, память сокращается до порядка $\sqrt{N}$ хранимых значений ценой примерно одного дополнительного прямого прохода.

6.6 Обратное распространение для логистической функции потерь

Одно наблюдение состоит из признаков $x \in \mathbb{R}^d$ и метки $y \in \{0, 1\}$. Модель вычисляет

$$s = w^\top x + b, \qquad p = \sigma(s) = \frac{1}{1 + e^{-s}}, \qquad \ell = -y \log p - (1 - y) \log(1 - p).$$

Так как $\log p = s - \log(1 + e^s)$ и $\log(1 - p) = -\log(1 + e^s)$, функция потерь равна $\ell = \log(1 + e^s) - ys$ — именно в таком виде она используется в С3.

Обратный проход начинается с $\bar{\ell} = 1$. Вершина $\ell(s)$ даёт

$$\bar{s} = \frac{d\ell}{ds} = \frac{e^s}{1 + e^s} - y = \sigma(s) - y,$$

а вершина $s = w^\top x + b$ передаёт это значение параметрам: $\bar{w} = \bar{s}\, x$ и $\bar{b} = \bar{s}$. Итак,

$$\nabla_w \ell = \big(\sigma(s) - y\big)\, x, \qquad \frac{\partial \ell}{\partial b} = \sigma(s) - y,$$

и значение $p = \sigma(s)$ с прямого прохода используется повторно. Для среднего значения потерь $\frac{1}{n}\sum_i \ell_i$ вклады наблюдений складываются и делятся на n: $\nabla_w \frac{1}{n}\sum_i \ell_i = \frac{1}{n}\sum_i \big(\sigma(s_i) - y_i\big)\, x_i$.

С метками $\tilde{y} = 2y - 1 \in \{-1, +1\}$ та же функция потерь записывается как

$$\ell = \log\big(1 + e^{-\tilde{y}s}\big).$$

Проверим оба случая: при $y = 1$, $\tilde{y} = 1$ получаем $\log(1 + e^{-s}) = \log(1 + e^{s}) - s$, а при $y = 0$, $\tilde{y} = -1$ — $\log(1 + e^{s})$. Производная $d\ell/ds = -\tilde{y}\,\sigma(-\tilde{y}s)$ в обоих случаях равна $\sigma(s) - y$. Два соглашения описывают одну и ту же функцию.

> **Ловушка.** $\sigma(s) - y$ — производная по s, а не по w. В градиенте по w есть множитель x; без него вместо вектора из $\mathbb{R}^d$ получается число.

6.7 Символьное, численное и автоматическое дифференцирование

Метод	Основная идея	Точность	Типичная проблема	Стоимость градиента в $\mathbb{R}^n$
Символьное	преобразует формулу функции в формулу производной	точное	разбухание выражений: формула производной может быть намного больше программы	вычисление этой формулы, размер которой никак не контролируется
Конечные разности	сдвигает входы и делит разности значений на шаг	приближённое: в лучшем случае относительная ошибка около $\varepsilon^{2/3}$ для центральных разностей, где ε — машинный эпсилон	при больших шагах — ошибка отбрасывания, при малых — потеря точности при вычитании близких чисел	$2n$ вычислений f для центральных разностей
Автоматическое, обратный режим	применяет цепное правило к программе, вершина за вершиной	точное, если не считать ошибок округления	память под ленту; ветвления и циклы в программе, негладкие операции	в небольшое постоянное число раз дороже одного вычисления f

У центральной разности

$$\frac{\partial f}{\partial x_i}(x) \approx \frac{f(x + he_i) - f(x - he_i)}{2h}$$

две ошибки. В формуле Тейлора $f(x \pm he_i) = f \pm h\,\partial_i f + \frac{h^2}{2}\partial_i^2 f \pm \frac{h^3}{6}\partial_i^3 f + O(h^4)$ при вычитании сокращаются чётные члены, поэтому ошибка **отбрасывания** равна $\frac{h^2}{6}|\partial_i^3 f| + O(h^3)$, то есть имеет порядок h^2. Каждое вычисленное значение f содержит ошибку **округления** около $\varepsilon|f|$, где ε — машинный эпсилон двойной точности. Разность двух близких чисел сохраняет эти абсолютные ошибки, и после деления на $2h$ получается ошибка порядка $\varepsilon|f|/h$. Суммарная ошибка

$$E(h) \approx \frac{h^2}{6}M + \frac{\varepsilon|f|}{h}, \qquad M = |\partial_i^3 f|,$$

минимальна там, где $E'(h) = \frac{hM}{3} - \frac{\varepsilon|f|}{h^2} = 0$, то есть при $h^3 = 3\varepsilon|f|/M$. Поэтому лучший шаг имеет порядок $\varepsilon^{1/3} \approx 6 \cdot 10^{-6}$, а лучшая ошибка — порядок $\varepsilon^{2/3}$. У односторонней разности

$\big(f(x+he_i)-f(x)\big)/h$ ошибка отбрасывания имеет порядок h, и то же рассуждение даёт лучший шаг порядка $\sqrt{\varepsilon}$.

Демонстрация D3 измеряет это для $\partial z/\partial x$ из C1 в точке $(x, y) = (2;\ -1)$. Относительная ошибка убывает как h^2 от $1{,}6\cdot10^{-4}$ при $h = 10^{-1}$, достигает минимума $5{,}7\cdot10^{-12}$ при $h = 10^{-5}$, близком к $\varepsilon^{1/3}$, и снова растёт до $1{,}4\cdot10^{-7}$ при $h = 10^{-10}$, когда начинает преобладать ошибка округления.

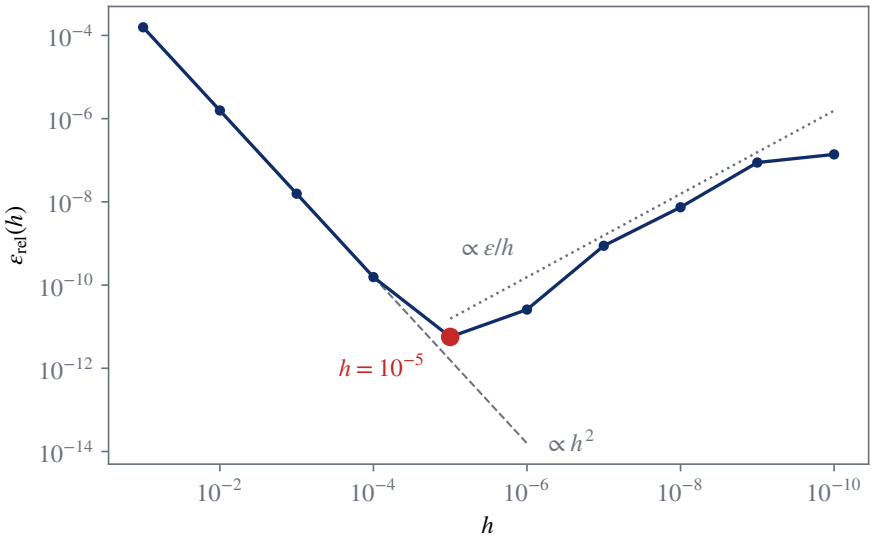


Рисунок. Относительная ошибка центральной разности для $\partial z/\partial x$ из C1 в точке $(x, y) = (2;\ -1)$ при h от 10^{-1} до 10^{-10}. При больших h преобладает ошибка отбрасывания, и она убывает как h^2; при малых h преобладает ошибка округления, и она растёт как $1/h$.

У AD нет шага, который нужно выбирать, и нет ошибки отбрасывания: оно вычисляет точную производную программы в арифметике с плавающей точкой. Конечные разности остаются полезны как независимая проверка градиента: в нескольких точках, с h около $\varepsilon^{1/3}$ и относительной мерой ошибки.

6.8 Задачи блока C

Три задачи семинара на обратный проход с полными решениями.

C1. Граф из лекции в конкретной точке

У доски

Условие. Возьмите $z = \sin(xy) + x^2$ в точке $(x, y) = (2;\ -1)$ с промежуточными вершинами $u = xy$, $w = x^2$, $v = \sin u$. Выпишите вершины в топологическом порядке, выполните прямой проход, затем обратный проход, начиная с $\bar{z} = 1$. Найдите z, $\partial z/\partial x$ и $\partial z/\partial y$ и проверьте обе производные аналитически.

Решение.

1. Топологический порядок (каждая вершина идёт после своих входов): x, y, $u = xy$, $w = x^2$, $v = \sin u$, $z = v + w$. Из входа x выходят два ребра: в u и в w.

2. Прямой проход в точке $(x, y) = (2;\ -1)$, все значения сохраняем:

$$u = -2, \quad w = 4, \quad v = \sin(-2) = -0{,}909297, \quad z = v + w = 3{,}090703.$$

   На обратном проходе снова понадобятся u, x и y.

3. Обратный проход, вершина $z = v + w$: начинаем с $\bar{z} = 1$. Обе локальные производные равны 1, поэтому $\bar{v} = 1$ и $\bar{w} = 1$.

4. Вершина $v = \sin u$, угол u в радианах: $\bar{u}\ +\!= \bar{v}\cos u = \cos(-2) = -0{,}416147$.

5. Вершина $w = x^2$: локальная производная равна $2x$, поэтому $\bar{x}\ +\!= \bar{w}\cdot 2x = 2\cdot 2$. Это первый из двух вкладов в $\bar{x}$.

6. Вершина $u = xy$: локальные производные равны y и x, поэтому

$$\bar{x}\ +\!= \bar{u}\,y = (-0{,}416147)(-1) = 0{,}416147, \qquad \bar{y}\ +\!= \bar{u}\,x = (-0{,}416147)\cdot 2 = -0{,}832294.$$

С учётом обоих вкладов $\bar{x} = 0{,}416147 + 2\cdot 2 = 4{,}416147$; при перезаписи осталось бы только 0,416147.

7. Аналитическая проверка: $\partial z/\partial x = y\cos(xy) + 2x$ и $\partial z/\partial y = x\cos(xy)$ дают те же числа. Обратный проход вычислил эти формулы слагаемое за слагаемым: $\bar{u}\,y$ — это $y\cos(xy)$, а $\bar{w}\cdot 2x$ — это $2x$. Один проход дал обе частные производные.

Ответ. $z = 3{,}090703$, $\partial z/\partial x = 4{,}416147$, $\partial z/\partial y = -0{,}832294$.

C2. Входная переменная, использованная дважды

Самостоятельно

Условие. Возьмите $q = (xy + x)^2$ в точке $(x, y) = (2;\ 3)$ с вершинами $a = xy$, $b = a + x$, $q = b^2$. Вычислите q прямым проходом, а $\partial q/\partial x$ и $\partial q/\partial y$ — одним обратным проходом, вручную, на бумаге.

Решение.

1. Топологический порядок: x, y, $a = xy$, $b = a + x$, $q = b^2$. Из x выходят два ребра: одно в a, другое прямо в b.

2. Прямой проход в точке $(x, y) = (2;\ 3)$: $a = xy = 6$, $b = a + x = 8$, $q = b^2 = 64$.

3. Обратный проход: $\bar{q} = 1$, и вершина $q = b^2$ даёт $\bar{b} = \bar{q}\cdot 2b = 16$.

4. Вершина $b = a + x$: обе локальные производные равны 1, поэтому $\bar{a}\ +\!= \bar{b} = 16$ и $\bar{x}\ +\!= \bar{b} = 16$.

5. Вершина $a = xy$: $\bar{x}\ +\!= \bar{a}\,y = 48$ и $\bar{y}\ +\!= \bar{a}\,x = 32$. Итого $\bar{x} = 16 + 48 = 64$; с `=` вместо `+=` получилось бы 48 — только последнее слагаемое.

6. Аналитическая проверка: $q = x^2(y+1)^2$, поэтому $\partial q/\partial x = 2x(y+1)^2 = 64$ и $\partial q/\partial y = 2x^2(y+1) = 32$. Значение q и производная $\partial q/\partial x$ совпадают здесь лишь потому, что $x = 2$: их отношение равно $x/2$.

Ответ. $q = 64$, $\partial q/\partial x = 48 + 16 = 64$, $\partial q/\partial y = 32$.

C3. Вершина логистической функции потерь

Самостоятельно

Условие. Для одного примера с логитом s и меткой $y \in \{0, 1\}$ логистическая функция потерь равна $\ell(s) = \log(1+e^s) - ys$, а $\sigma(s) = 1/(1+e^{-s})$. При $s = 0{,}5$ и $y = 1$ разбейте ℓ на элементарные вершины, выполните прямой и обратный проходы и найдите ℓ, $\sigma(s)$ и $d\ell/ds$. Затем перепишите

функцию потерь для меток $\tilde{y} = 2y - 1 \in \{-1, 1\}$ как функцию одного только $\tilde{y}s$ и проверьте её для обеих меток.

Решение.

1. Вершины в топологическом порядке: s, $u = e^s$, $v = 1 + u$, $w = \log v$, $\ell = w - ys$. Метка y — константа. Логит s идёт в две вершины, u и ℓ, поэтому у $\bar{s}$ будет два слагаемых.

2. Прямой проход при $s = 0{,}5$, $y = 1$:

$$u = e^s = 1{,}648721, \quad v = 1 + 1{,}648721, \quad w = \log v = 0{,}974077,$$

$$\ell = w - ys = 0{,}974077 - 1 \cdot 0{,}5 = 0{,}474077.$$

3. Обратный проход: $\bar{\ell} = 1$. У вершины $\ell = w - ys$ локальная производная по w равна 1, а по s равна $-y$, поэтому $\bar{w} = 1$ и $\bar{s} \mathrel{+}= -y = -1$.

4. Через логарифм: $\bar{v} = \bar{w}/v = \dfrac{1}{1 + e^s}$, затем $\bar{u} = \bar{v}$, и наконец

$$\bar{s} \mathrel{+}= \bar{u}\, e^s = \frac{e^s}{1 + e^s} = \frac{1}{1 + e^{-s}} = \sigma(s) = 0{,}622459.$$

5. Оба слагаемых вместе: $d\ell/ds = \bar{s} = \sigma(s) - y = 0{,}622459 - 1 = -0{,}377541$. Это $p - y$ из лекции, где $p = \sigma(s)$. Производная отрицательна, поэтому шаг градиентного спуска повышает логит положительного примера.

6. Метки ± 1: положим $\tilde{y} = 2y - 1$. При $y = 1$ получаем $\tilde{y} = 1$ и $\log(1 + e^s) - s = \log \dfrac{1 + e^s}{e^s} = \log(1 + e^{-s})$. При $y = 0$ получаем $\tilde{y} = -1$, а функция потерь остаётся прежней, $\log(1 + e^s)$. Оба случая записываются одной формулой:

$$\ell = \log\left(1 + e^{-\tilde{y}s}\right).$$

7. Проверка в точке: $\tilde{y} = 1$ и $\log(1 + e^{-\tilde{y}s}) = 0{,}474077$ — то же число, что и ℓ. Два соглашения задают одну и ту же функцию, поэтому у них совпадают все значения и производная $\sigma(s) - y$. В лекции функция потерь записана для меток из $\{0, 1\}$, а запись с ± 1 — второе распространённое соглашение.

Ответ. $\ell = 0{,}474077$, $\sigma(s) = 0{,}622459$, $d\ell/ds = \sigma(s) - y = -0{,}377541$; при $\tilde{y} = 2y - 1$ функция потерь равна $\log(1 + e^{-\tilde{y}s})$.

7 Коллоквиум

На коллоквиуме сначала спрашивают определения, поэтому и здесь первым идёт список определений из первого раздела. За ним — четыре доказательства с ключевыми неравенствами и три задачи в формате билета с полными решениями.

7.1 Список определений

Для каждого определения нужны название, формула и кванторы: для каких точек или пар точек формула должна выполняться.

- Точка локального минимума: точка x^*, для которой найдётся $\varepsilon > 0$, при котором $f(x) \geq f(x^*)$ для всех x с $\|x - x^*\| < \varepsilon$.

- Точка глобального минимума: точка x^*, для которой $f(x) \geq f(x^*)$ при всех x.
- Стационарная точка: точка x, в которой f дифференцируема и $\nabla f(x) = 0$.
- Выпуклое множество: $(1-t)x + ty \in C$ для всех $x, y \in C$ и $t \in [0,1]$.
- Выпуклая функция (неравенство Йенсена): $f\big((1-t)x+ty\big) \leq (1-t)f(x)+tf(y)$ для всех x, y и $t \in [0,1]$.
- Строго выпуклая функция: то же неравенство выполняется строго при всех $x \neq y$ и $t \in (0,1)$.
- μ-сильно выпуклая функция, $\mu > 0$: $f(y) \geq f(x) + \nabla f(x)^\top (y-x) + \frac{\mu}{2}\|y-x\|^2$ для всех x, y; или, что равносильно, функция $f - \frac{\mu}{2}\|\cdot\|^2$ выпукла.
- L-гладкая функция: $\|\nabla f(x) - \nabla f(y)\| \leq L\|x-y\|$ для всех x, y.
- Число обусловленности: $\kappa = L/\mu \geq 1$; для $f = \frac{1}{2}x^\top Q x$ оно равно $\lambda_{\max}(Q)/\lambda_{\min}(Q)$.
- Направление спуска в точке x: вектор d, для которого $\nabla f(x)^\top d < 0$.
- Условие Поляка–Лоясевича (PL) с константой $\mu > 0$: $\frac{1}{2}\|\nabla f(x)\|^2 \geq \mu\big(f(x) - f^*\big)$ для всех x.

7.2 Четыре доказательства

Лемма о спуске

Если ∇f липшицев с константой L, то $f(y) \leq f(x) + \nabla f(x)^\top (y-x) + \frac{L}{2}\|y-x\|^2$. Положим $r(t) = f(x+t(y-x))$ и запишем $f(y) - f(x) = \int_0^1 r'(t)\,dt$, где $r'(t) = \nabla f(x+t(y-x))^\top (y-x)$. Вычтем $\nabla f(x)^\top (y-x)$ и оценим остаток с помощью неравенства Коши — Буняковского — Шварца и условия Липшица:

$$f(y) - f(x) - \nabla f(x)^\top (y-x) = \int_0^1 \big(\nabla f(x + t(y-x)) - \nabla f(x)\big)^\top (y-x)\,dt \leq$$
$$\int_0^1 Lt\|y-x\|^2\,dt = \frac{L}{2}\|y-x\|^2.$$

Конечность бэктрекинга по Армихо

Если ∇f липшицев с константой L и $g = \nabla f(x) \neq 0$, то бэктрекинг вдоль $d = -g$ останавливается после конечного числа уменьшений шага. Лемма о спуске при $y = x - \alpha g$ даёт

$$f(x - \alpha g) \leq f(x) - \alpha\Big(1 - \frac{L\alpha}{2}\Big)\|g\|^2,$$

и правая часть не больше $f(x) - c\alpha\|g\|^2$, как только $1 - L\alpha/2 \geq c$, то есть при всех $\alpha \leq 2(1-c)/L$. Пробные шаги $\beta^j\alpha_0$ стремятся к 0, поэтому один из них попадёт в этот промежуток. Принятый шаг равен либо α_0, либо отвергнутому пробному шагу, умноженному на β, а любой отвергнутый пробный шаг больше $2(1-c)/L$, поэтому $\alpha \geq \min\{\alpha_0,\ 2\beta(1-c)/L\}$.

Скорость сходимости для выпуклых функций

Для выпуклой L-гладкой f и $\alpha = 1/L$ выполнено $f(x_k) - f^* \leq L\|x_0 - x^*\|^2/(2k)$. Неравенство для шага спуска $f(x_{k+1}) \leq f(x_k) - \frac{1}{2L}\|g_k\|^2$, выпуклость $f(x_k) - f^* \leq g_k^\top (x_k - x^*)$ и тождество трёх точек для $x_{k+1} = x_k - \frac{1}{L}g_k$ вместе дают ключевое неравенство

$$f(x_{k+1}) - f^* \leq \frac{L}{2}\Big(\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2\Big).$$

Просуммируем его по первым k шагам: правая часть телескопически сокращается. Остаётся воспользоваться тем, что $f(x_j)$ не возрастает.

Линейная скорость при сильной выпуклости и при условии PL

Из сильной выпуклости следует условие PL: минимизируем по y нижнюю оценку $f(x) + \nabla f(x)^\top (y-x) + \frac{\mu}{2}\|y-x\|^2$ и получаем $f^* \geq f(x) - \frac{1}{2\mu}\|\nabla f(x)\|^2$. При условии PL и $\alpha = 1/L$ ключевое неравенство имеет вид

$$f(x_{k+1}) - f^* \leq f(x_k) - f^* - \frac{1}{2L}\|\nabla f(x_k)\|^2 \leq \Big(1 - \frac{\mu}{L}\Big)\big(f(x_k) - f^*\big),$$

а применяя его шаг за шагом, получаем $(1-\mu/L)^k$. Второе доказательство использует только условие PL, выпуклость в нём не нужна.

7.3 Билет T1: обусловленность и скорость сходимости

Проверьте себя. Пусть $f(x) = \frac{1}{2}x^\top Q x$, где $Q = \operatorname{diag}(4;\ 100)$. Найдите μ, L и κ. При каких постоянных шагах градиентный спуск сходится из любой начальной точки? Сколько итераций нужно по гарантированной оценке при $\alpha = 1/L$, чтобы разность $f(x_k) - f^*$ уменьшилась до доли 10^{-6} от начального значения? Найдите оптимальный постоянный шаг, его коэффициент сжатия и число итераций, которое ему нужно для такого же уменьшения.

Ответ. $\mu = \lambda_{\min}(Q) = 4$, $L = \lambda_{\max}(Q) = 100$, $\kappa = L/\mu = 25$. В собственных координатах итерация имеет вид $x_{k+1,i} = (1 - \alpha\lambda_i)x_{k,i}$, поэтому она сходится из любой начальной точки ровно тогда, когда $|1 - \alpha\lambda_i| < 1$ для обоих i, то есть при $0 < \alpha < 2/L = 0{,}02$. При $\alpha = 1/L = 0{,}01$ в оценке $f(x_k) - f^* \leq (1-\mu/L)^k\big(f(x_0) - f^*\big)$ стоит множитель $1 - \mu/L = 0{,}96$, и неравенство $(0{,}96)^k \leq 10^{-6}$ требует $k \geq \ln(10^{-6})/\ln(0{,}96)$, то есть $k = 339$. Оптимальный постоянный шаг минимизирует наибольший из множителей $\max\{|1 - \alpha\mu|,\ |1 - \alpha L|\}$. Первая величина убывает с ростом α, а вторая растёт при $\alpha > 1/L$, поэтому минимум достигается там, где $1 - \alpha\mu = \alpha L - 1$:

$$\alpha^* = \frac{2}{L+\mu} = \tfrac{1}{52} \approx 0{,}019231, \qquad \rho = \frac{L-\mu}{L+\mu} = \frac{\kappa - 1}{\kappa + 1} = \tfrac{12}{13} \approx 0{,}923077.$$

На каждом шаге обе компоненты x_k по модулю умножаются ровно на ρ, поэтому $f(x_k) = \rho^{2k} f(x_0)$, и неравенство $\rho^{2k} \leq 10^{-6}$ требует $k \geq \ln(10^{-6})/(2\ln\rho)$, то есть $k = 87$: почти вчетверо меньше итераций, чем по оценке при $1/L$.

7.4 Билет T2: бэктрекинг по Армихо

Проверьте себя. Запустите бэктрекинг по Армихо для $f(x) = \frac{1}{2}x^\top \operatorname{diag}(2;\ 20)\,x$ из точки $x_0 = (1;\ 1)$ вдоль $d = -\nabla f(x_0)$ при $\alpha_0 = 1$, $\beta = 0{,}5$ и $c = 0{,}25$. Выпишите пробные шаги, найдите принятый шаг и число делений пополам, затем сверьте результат с теоремой о конечности бэктрекинга.

Ответ. Здесь $L = \lambda_{\max} = 20$, $f(x_0) = 11$, $g = \nabla f(x_0) = (2;\ 20)$ и $\|g\|^2 = 404$. Пробный

шаг α принимается, если $f(x_0 - \alpha g) \le f(x_0) - c\alpha\|g\|^2$:

α	$f(x_0 - \alpha g)$	$f(x_0) - c\alpha\|g\|^2$	принят
1	3611	-90	нет
0,5	810	$-39{,}5$	нет
0,25	160,25	$-14{,}25$	нет
0,125	23,0625	$-1{,}625$	нет
0,0625	1,390625	4,6875	да

Цикл останавливается после 4 делений пополам; принят шаг $\alpha = 0{,}0625$. Теорема гарантирует, что принимается любой шаг $\alpha \le 2(1-c)/L = 0{,}075$, поэтому цикл не пойдёт дальше первого пробного шага, меньшего этого значения, а это 0,0625. Поскольку хотя бы один пробный шаг был отвергнут, принятый шаг удовлетворяет и оценке $\alpha \ge \beta \cdot 2(1-c)/L = 0{,}0375$. Обе проверки согласуются с расчётом: $0{,}0375 \le 0{,}0625 \le 0{,}075$.

7.5 Билет T3: обратный проход

Проверьте себя. Вычислите $f(x, y) = xe^y + y^2$ и обе частные производные в точке $(x, y) = (2;\ 1)$ обратным проходом: выпишите вершины в топологическом порядке, найдите значения на прямом проходе, затем сопряжённые переменные и сверьте результат с аналитическим градиентом.

Ответ. Вершины в топологическом порядке: входы x, y, затем $a = e^y$, $b = xa$, $c = y^2$, $f = b + c$. Значения на прямом проходе: $a = e \approx 2{,}718282$, $b = 5{,}436564$, $c = 1$, $f = 6{,}436564$. Обратный проход начинается с $\bar f = 1$: вершина $f = b + c$ даёт $\bar b = 1$ и $\bar c = 1$; $c = y^2$ даёт $\bar y \mathrel{+}= \bar c \cdot 2y = 2$; $b = xa$ даёт $\bar x \mathrel{+}= \bar b\, a = 2{,}718282$ и $\bar a \mathrel{+}= \bar b\, x = 2$; $a = e^y$ даёт $\bar y \mathrel{+}= \bar a\, e^y = 5{,}436564$. Вход y используется в двух вершинах, поэтому его сопряжённая переменная накапливается: $\bar y = 2 + 5{,}436564 = 7{,}436564$. Аналитически $\partial f/\partial x = e^y = e$ и $\partial f/\partial y = xe^y + 2y = 2e + 2$; в этой точке они равны 2,718282 и 7,436564. Если перезаписывать $\bar y$, а не накапливать, получится 2 или 5,436564 в зависимости от порядка.

8 Полезные константы

Для шага $1/L$, границы устойчивости $2/L$ и скорости $1 - \mu/L$ нужны константы задачи. У квадратичной функции это собственные значения, а для логистической регрессии у L есть простая верхняя оценка.

8.1 Логистическая регрессия

Данные — векторы $x_1, \dots, x_n \in \mathbb{R}^d$, строки матрицы $X \in \mathbb{R}^{n \times d}$, с метками $\tilde y_i \in \{-1, +1\}$. Средняя логистическая функция потерь равна

$$f(w) = \frac{1}{n} \sum_{i=1}^{n} \log\left(1 + e^{-\tilde y_i w^\top x_i}\right),$$

или, в записи с метками $\{0, 1\}$, $\frac{1}{n}\sum_i \left(\log(1 + e^{s_i}) - y_i s_i\right)$, где $s_i = w^\top x_i$ и $\tilde y_i = 2y_i - 1$; это одна и та же функция. Свободный член включается в w, если добавить к каждому x_i постоянный признак 1.

Утверждение: Гладкость логистической функции потерь. Обозначим $\sigma_i = \sigma(w^\top x_i)$. Тогда

$$\nabla^2 f(w) = \frac{1}{n} X^\top D X, \qquad D = \operatorname{diag}\big(\sigma_i(1-\sigma_i)\big),$$

и $0 \preceq \nabla^2 f(w) \preceq \frac{1}{4n} X^\top X$ при всех w. Значит, функция f выпуклая и L-гладкая, причём

$$L \le \frac{\lambda_{\max}(X^\top X)}{4n}.$$

Доказательство. Если метки взяты из $\{0,1\}$, то i-е слагаемое равно $\varphi(s_i) - y_i s_i$, где $\varphi(s) = \log(1+e^s)$, $\varphi'(s) = \sigma(s)$ и $\varphi''(s) = \sigma(s)\big(1-\sigma(s)\big)$; линейное слагаемое кривизны не даёт. По цепному правилу с $s_i = w^\top x_i$ гессиан i-го слагаемого равен $\sigma_i(1-\sigma_i)\, x_i x_i^\top$, а среднее таких матриц — $\frac{1}{n} X^\top D X$. Поскольку $p(1-p) \le \frac{1}{4}$ при $p \in [0,1]$, причём равенство достигается при $p = \frac{1}{2}$, для любого v

$$0 \le v^\top \nabla^2 f(w)\, v = \frac{1}{n}\sum_i \sigma_i(1-\sigma_i)(x_i^\top v)^2 \le \frac{1}{4n}\sum_i (x_i^\top v)^2 = \frac{1}{4n}\|Xv\|^2 \le \frac{\lambda_{\max}(X^\top X)}{4n}\|v\|^2.$$

Дважды дифференцируемая функция, у которой всюду $0 \preceq \nabla^2 f \preceq LI$, выпукла, а её градиент липшицев с константой L, потому что $\nabla f(y) - \nabla f(x) = \int_0^1 \nabla^2 f\big(x + t(y-x)\big)(y-x)\, dt$.

Здесь $\lambda_{\max}(X^\top X) = \|X\|_2^2$ — квадрат наибольшего сингулярного числа X. Оценка достигается в точке $w = 0$, где все $\sigma_i = \frac{1}{2}$ и $\nabla^2 f(0) = \frac{1}{4n} X^\top X$, поэтому меньшей константы, верной на всём пространстве, не существует. Функция потерь не является сильно выпуклой: вдоль луча $w = tv$, где $x_i^\top v \neq 0$ при всех i, веса $\sigma_i(1-\sigma_i)$ стремятся к 0 при $t \to \infty$, а вместе с ними и гессиан.

Добавим штраф: $f_\lambda(w) = f(w) + \lambda\|w\|^2$ с весом $\lambda > 0$ (здесь это число, а не собственное значение). Гессиан получает добавку $\nabla^2\big(\lambda\|w\|^2\big) = 2\lambda I$:

$$2\lambda I \preceq \nabla^2 f_\lambda(w) \preceq \Big(\frac{\lambda_{\max}(X^\top X)}{4n} + 2\lambda\Big) I.$$

Значит, f_λ — 2λ-сильно выпуклая и L-гладкая функция, причём $L \le \frac{\lambda_{\max}(X^\top X)}{4n} + 2\lambda$, и

$$\kappa = \frac{L}{\mu} \le \frac{\lambda_{\max}(X^\top X)/(4n) + 2\lambda}{2\lambda} = 1 + \frac{\lambda_{\max}(X^\top X)}{8n\lambda}.$$

Тогда градиентный спуск с $\alpha = 1/L$ сходится линейно, а чем меньше λ, тем больше оценка для κ и тем медленнее гарантированная скорость.

Ловушка. В некоторых источниках штраф записывают как $\frac{\lambda}{2}\|w\|^2$. Тогда гессиан получает добавку λI, а не $2\lambda I$, задача становится λ-сильно выпуклой, и соответственно меняются все константы выше.

8.2 Квадратичные функции семинара

Для $f(x) = \frac{1}{2} x^\top Q x$ с диагональной матрицей Q: $\mu = \lambda_{\min}(Q)$, $L = \lambda_{\max}(Q)$, градиентный спуск сходится при $0 < \alpha < 2/L$, линейная оценка скорости верна при $\alpha = 1/L$, а оптимальный постоянный шаг равен $2/(L+\mu)$.

Задача	Q	μ	L	κ	$1/L$	$2/L$	$2/(L+\mu)$
A1	diag(1; 10)	1	10	10	0,1	0,2	$\frac{2}{11}$
A2	diag(1; 2)	1	2	2	0,5	1	$\frac{2}{3}$
A3	diag(1; 50)	1	50	50	0,02	0,04	$\frac{2}{51}$

В задаче B1 используется матрица из A1, в B2 и B3 — матрица из A3.