Методы оптимизации

Семинар 4

Ускоренные градиентные методы

Конспект теории

НИУ ВШЭ, факультет компьютерных наук

2026–2027 учебный год

Лектор курса: Андрей Игнатов

Евгений Баулин

Telegram: @tarakan_tuc

Содержание

1 Геометрия и сравнение методов **2**

2 Инерция на квадратичной функции **2**

3 Опережение и рестарт **5**

4 Координатный спуск **6**

5 Сопряжённые градиенты **7**

6 Мини-батчи и шумовой порог **9**

7 Расписания и воспроизводимые эксперименты **11**

8 Стандартизация признаков **12**

9 Проверки реализации и упражнения **13**

Медленный градиентный метод может страдать от вытянутой геометрии, дорогих полных градиентов или шумных оценок. Конспект следует лекции и компьютерному семинару Андрея Игнатова: инерция, координатный спуск, сопряжённые градиенты и стохастические наименьшие квадраты.

Обозначения.
Матрицы Q и A вещественные, симметричные и положительно определённые, если не сказано иное. μ и L — крайние собственные значения, $\kappa = L/\mu$, $g = \nabla f$, $r = b - Ax$. В регрессии используем **половину** средней квадратичной ошибки: $F(w) = \|Xw-y\|^2/(2N)$; у обычной MSE градиент и гессиан вдвое больше.

1 Геометрия и сравнение методов

Определение. Для $f(x) = \frac{1}{2}x^\top Qx - b^\top x$ минимум равен $x^* = Q^{-1}b$. Ошибка $e = x - x^*$ даёт зазор $\frac{1}{2}e^\top Qe$ и градиент Qe. Запишем $Q = U\Lambda U^\top$ с $U^\top U = I$; все скалярные соотношения ниже действуют на $z = U^\top e$.

Теорема. GD с постоянным шагом даёт $z_{k+1,i} = (1 - \alpha\lambda_i)z_{k,i}$. Сходимость из любой точки выполняется ровно при $0 < \alpha < 2/L$. Лучший постоянный шаг для квадратичной функции равен $2/(L + \mu)$, а наихудший множитель ошибки — $(\kappa - 1)/(\kappa + 1)$.

Доказательство. Каждая координата — геометрическая прогрессия. Её модуль стремится к нулю тогда и только тогда, когда $|1 - \alpha\lambda_i| < 1$. Чтобы минимизировать наибольший модуль на $[\mu, L]$, уравняйте крайние значения: $1 - \alpha\mu = -(1 - \alpha L)$.

Почему. При большом κ шаг, не допускающий взрыва в крутом направлении, почти не меняет пологое. Ортогональный поворот сохраняет собственные значения и число обусловленности, но уводит собственные векторы от координатных осей.

Ловушка. Итерация не является общей единицей работы. GD использует полный градиент, координатный шаг может требовать лишь одной частной производной, CG — умножения матрицы и вектора, а SGD — батча градиентов объектов. Запись полной потери также читает все объекты. Указывайте эти счётчики отдельно; время работы — дополнительная величина, зависящая от компьютера.

2 Инерция на квадратичной функции

Определение. Тяжёлый шар хранит перемещение:

$$v_{k+1} = \beta v_k - \alpha g(x_k), \qquad x_{k+1} = x_k + v_{k+1}.$$

Положите $v_0 = 0$, то есть $x_{-1} = x_0$, если задача не задаёт другую предыдущую точку. Исключив v, получим $x_{k+1} = x_k - \alpha g(x_k) + \beta(x_k - x_{k-1})$.

Теорема. Для каждого собственного значения λ у тяжёлого шара возникает многочлен

$$p_\lambda(r) = r^2 - (1 + \beta - \alpha\lambda)r + \beta.$$

При $0 \le \beta < 1$ метод устойчив на всей положительно определённой квадратичной функции ровно при

$$0 < \alpha < \frac{2(1+\beta)}{L}.$$

Устойчивость означает сходимость линейного соотношения при любой начальной паре.

Доказательство. Для вещественного приведённого многочлена $r^2 - ar + \beta$ оба корня лежат внутри единичного круга тогда и только тогда, когда $|\beta| < 1$, $1 - a + \beta > 0$ и $1 + a + \beta > 0$. Подстановка $a = 1 + \beta - \alpha\lambda$ даёт $\alpha\lambda > 0$ и $\alpha\lambda < 2(1+\beta)$. Самое сильное ограничение задаёт наибольшее собственное значение.

Теорема. Параметры Поляка минимизируют наихудший радиус корней по спектральному интервалу положительно определённой квадратичной функции:

$$\alpha_* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta_* = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^2, \quad \rho_* = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.$$

Масштаб сложности равен $O(\sqrt{\kappa}\log(1/\varepsilon))$, в сравнении с $O(\kappa\log(1/\varepsilon))$ для GD.

Доказательство. Положите $s = \sqrt{\beta_*} = \rho_*$. На концах спектра $1 + \beta_* - \alpha_*\mu = 2s$ и $1 + \beta_* - \alpha_* L = -2s$. Для внутренних собственных значений дискриминант неположителен, поэтому комплексно сопряжённые корни имеют модуль s. На концах они кратные. Моды с кратными корнями имеют вид $(c + dk)(\pm s)^k$; простая оценка $\|e_k\| \le s^k\|e_0\|$ отсюда не следует.

Ловушка. Эти оптимальные параметры относятся к квадратичным функциям. Нельзя переносить ту же глобальную гарантию на любую гладкую сильно выпуклую нелинейную функцию. Меньший радиус корней также не требует убывания функции на каждом начальном шаге.

A1. Тяжёлый шар: параметры и первые шаги

У доски

Условие. Для $f(x) = \frac{1}{2}x^\top Q x$, $Q = \operatorname{diag}(1;\ 9)$, положите $x_{-1} = x_0 = (1;\ 1)$ и $x_{k+1} = x_k - \alpha Q x_k + \beta(x_k - x_{k-1})$. Найдите оптимальные параметры Поляка для квадратичной функции и спектральный радиус. Вычислите x_1, x_2 и значения функции. Обязана ли функция убывать на каждом шаге?

Решение.

1. Здесь $\mu = 1$, $L = 9$, $\kappa = 9$. Для положительно определённой квадратичной функции

$$\alpha_* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2} = 0{,}25, \qquad \beta_* = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^2 = 0{,}25.$$

Максимальный модуль корня равен $\rho = \sqrt{\beta_*} = 0{,}5$.

2. Вдоль собственного вектора с собственным значением λ получаем

$$z_{k+1} = (1 + \beta - \alpha\lambda)z_k - \beta z_{k-1}.$$

Характеристический многочлен равен $r^2 - (1 + \beta - \alpha\lambda)r + \beta$. На концах спектра корни кратные: $+\rho$ и $-\rho$.

3. На первом шаге инерции нет, поскольку $x_0 - x_{-1} = 0$. Поэтому $x_1 = (0{,}75;\ -1{,}25)$; следующий шаг включает $\beta(x_1 - x_0)$ и даёт $x_2 = (0{,}5;\ 1)$.

4. $f(x_0) = 5$, $f(x_1) = 7{,}3125$, $f(x_2) = 4{,}625$. На первом шаге функция растёт, хотя все характеристические корни лежат внутри единичного круга. Радиус корней описывает асимптотическое затухание; кратные корни могут добавлять множитель порядка k.

Ответ. $\alpha_* = 0{,}25$, $\beta_* = 0{,}25$, $\rho = 0{,}5$. Устойчивость не означает монотонности.

A2. Граница устойчивости метода с инерцией

Самостоятельно

Условие. Для $f(z) = \frac{1}{2}\lambda z^2$ возьмите $\lambda = 16$ и $\beta = 0{,}5$. Выведите строгий интервал устойчивых положительных шагов. Укажите его верхнюю границу и максимальный модуль корня при $\alpha = 0{,}2$. Устойчив ли этот шаг? Отдельно разберите равенство на границе.

Решение.

1. При $a = 1 + \beta - \alpha\lambda$ критерий для корней сводится к $|\beta| < 1$, $\alpha\lambda > 0$ и $2(1 + \beta) - \alpha\lambda > 0$. При заданной неотрицательной инерции $0 < \alpha < 2(1 + \beta)/\lambda = 0{,}1875$.

2. На границе многочлен раскладывается в $(r + 1)(r + \beta)$, поэтому один корень равен -1. При обычной начальной паре сохраняется колеблющаяся компонента. Для предложенного большего шага максимальный модуль равен $1{,}3217 > 1$, так что для некоторых начальных точек метод расходится.

Ответ. Верхняя граница: 0,1875; радиус для пробного шага: 1,3217. Интервал устойчивости открытый.

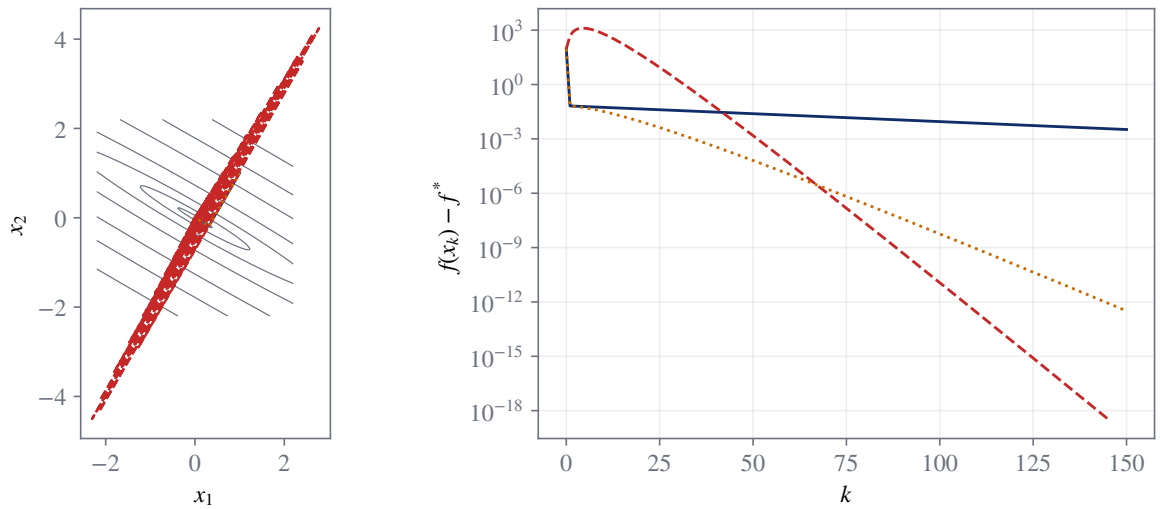


Рисунок. Нетривиальный поворот показывает крутое и пологое направления, не совмещая их с осями.

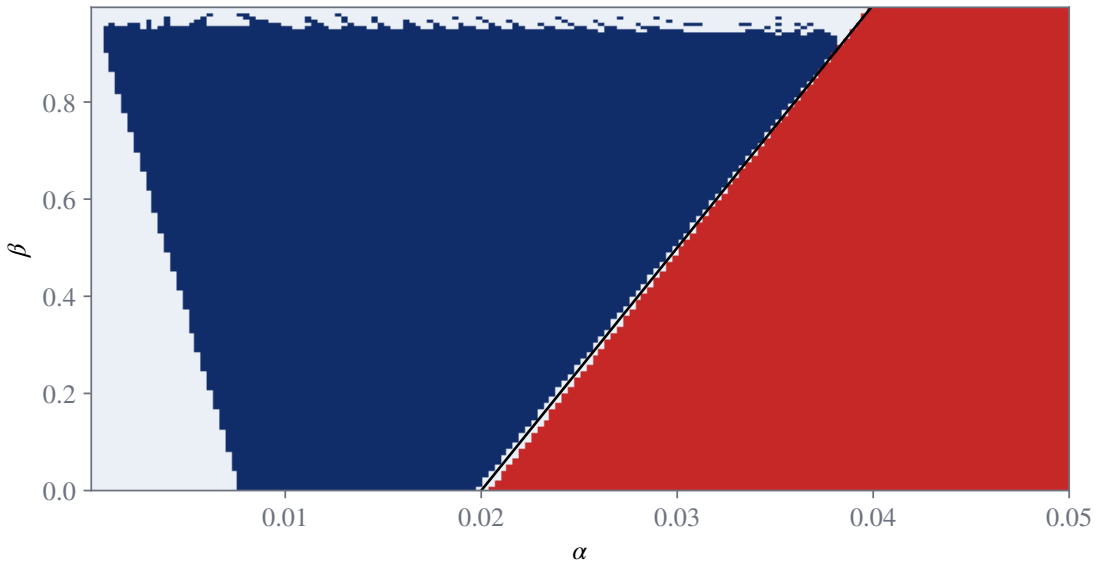


Рисунок. Аналитическая граница строгая; конечный запуск зависит ещё и от порога уменьшения.

3 Опережение и рестарт

Определение. Форма с постоянной инерцией и опережением задаётся как

$$y_k = x_k + \beta(x_k - x_{k-1}), \qquad x_{k+1} = y_k - \alpha g(y_k).$$

На скалярной квадратичной функции

$$z_{k+1} = (1 - \alpha\lambda)\big((1 + \beta)z_k - \beta z_{k-1}\big).$$

Многочлен отличается от тяжёлого шара: $r^2 - (1 + \beta)(1 - \alpha\lambda)r + \beta(1 - \alpha\lambda)$.

Два режима ускорения

Для известной гладкой сильно выпуклой функции стандартный ускоренный выбор равен $\alpha = 1/L$, $\beta = (\sqrt{L} - \sqrt{\mu})/(\sqrt{L} + \sqrt{\mu})$. В просто выпуклом случае ускорение использует меняющийся коэффициент экстраполяции; оценка зазора $O(1/k^2)$ не относится к произвольной постоянной инерции.

Почему. Если экстраполированный шаг направлен неверно, отбросьте инерцию и повторите градиентный шаг из текущей точки. Рестарт по функции проверяет, превышает ли предложенное значение текущее. Обозначайте метод с рестартом отдельно и учитывайте дополнительное вычисление градиента.

А3. Где вычисляется градиент?

Самостоятельно

Условие. Для $f(x) = \frac{1}{2}\lambda x^2$ положите $\lambda = 4$, $x_k = 2$, $x_{k-1} = 3$, $\alpha = 0{,}1$, $\beta = 0{,}5$. Найдите следующую точку тяжёлого шара и следующую точку метода с опережением: $y_k = x_k + \beta(x_k - x_{k-1})$, $x_{k+1} = y_k - \alpha\nabla f(y_k)$. Объясните различие.

Решение.

1. Экстраполированная точка равна $y_k = 1{,}5$. Тяжёлый шар использует $\nabla f(x_k) = 8$ и даёт $x_k + \beta(x_k - x_{k-1}) - \alpha\nabla f(x_k) = 0{,}7$.

2. Обновление с опережением берёт $\nabla f(y_k) = 6$ и даёт $y_k - \alpha\nabla f(y_k) = 0{,}9$. Если в обеих реализациях брать градиент в x_k, методы незаметно станут одинаковыми.

Ответ. Тяжёлый шар: 0,7. Опережение: 0,9.

4 Координатный спуск

Определение. Координатная константа Липшица $L_i > 0$ даёт

$$f(x + te_i) \le f(x) + tg_i + \tfrac{1}{2}L_i t^2.$$

Выбор $t = -g_i/L_i$ приводит к

$$f(x^+) \le f(x) - \frac{g_i^2}{2L_i}.$$

Для квадратичной функции $L_i = Q_{ii}$, и неравенство становится равенством.

Доказательство. Для квадратичной функции срез раскрывается точно: $f(x + te_i) = f(x) + tg_i + Q_{ii}t^2/2$. Дифференцирование по t даёт единственный минимум. Подстановка даёт уменьшение. После изменения x_i следующая производная должна использовать изменённый вектор.

Три правила выбора

Циклический выбор проходит координаты по порядку. Равномерный случайный выбор выбирает одну координату на шаг. Жадный выбор максимизирует $|g_i|/\sqrt{L_i}$, поскольку его квадрат равен удвоенному гарантированному уменьшению. В размерности d один эквивалентный проход — это d координатных обновлений, но проход не обязательно стоит столько же, сколько один полный градиент.

Теорема. Если f является μ-сильно выпуклой и для всех координат $L_i \le L_{\max}$, равномерный выбор даёт

$$\mathbb{E}[f(x^+) - f^* \mid x] \le \left(1 - \frac{\mu}{dL_{\max}}\right)(f(x) - f^*).$$

Это оценка на одно координатное обновление при новой независимой выборке координаты.

Доказательство. Усредните $g_i^2/(2L_i)$ по координатам: среднее уменьшение не меньше $\|g\|^2/(2dL_{\max})$. Сильная выпуклость даёт $\|g\|^2 \ge 2\mu(f - f^*)$; подставьте это в оценку уменьшения.

B1. По одной координате

У доски

Условие. Для $f(x) = \frac{1}{2}x^\top Qx$, $Q = \begin{pmatrix} 5 & -4 \\ -4 & 5 \end{pmatrix}$, начните из $x_0 = (1;\ 1)$. Минимизируйте

сначала по координате 1, затем по координате 2, фиксируя другую. Выведите точный координатный шаг и найдите уменьшение функции после каждого обновления.

Решение.

1. Вдоль координаты i имеем $f(x + te_i) = f(x) + tg_i + \frac{1}{2}Q_{ii}t^2$. Минимум достигается при $t = -g_i/Q_{ii}$, а уменьшение равно $g_i^2/(2Q_{ii})$. Здесь $L_i = Q_{ii}$, хотя собственные значения равны $(1;\ 9)$.
2. $g(x_0) = (1;\ 1)$. После координаты 1: $x = (0{,}8;\ 1)$, $f = 0{,}9$, уменьшение 0,1. Перед следующим шагом пересчитайте градиент в этой точке.
3. После координаты 2: $x = (0{,}8;\ 0{,}64)$, $f = 0{,}576$, уменьшение 0,324. Это два координатных обновления, то есть один полный проход в двумерной задаче.

Ответ. $x_1 = (0{,}8;\ 1)$, $x_2 = (0{,}8;\ 0{,}64)$. Каждое обновление минимизирует текущий одномерный срез.

B2. Выбор координаты по уменьшению функции

Самостоятельно

Условие. Для $Q = \mathrm{diag}(1;\ 9)$ и $x = (2;\ 1)$ вычислите обе компоненты градиента. Какая координата даёт наибольшее точное уменьшение $g_i^2/(2Q_{ii})$? Укажите номер координаты, уменьшение и новое значение функции. Объясните показатель $|g_i|/\sqrt{Q_{ii}}$.

Решение.

1. Градиент равен $(2;\ 9)$. Нормированные показатели равны $(2;\ 3)$, поэтому координата 2 даёт наибольшее точное улучшение.
2. Обновление этой координаты уменьшает f на 4,5 и оставляет $f = 2$. Максимизация $|g_i|/\sqrt{Q_{ii}}$ равносильна максимизации его квадрата, а значит, и точного координатного уменьшения.

Ответ. Координата 2; уменьшение 4,5; новое значение 2.

5 Сопряжённые градиенты

Определение. При $A \succ 0$ минимизация $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ равносильна решению $Ax = b$. Направления p_i, p_j являются A-сопряжёнными, если $p_i^\top Ap_j = 0$. Невязка $r = b - Ax$ равна отрицательному градиенту.

Определение. Начните с $r_0 = b - Ax_0$, $p_0 = r_0$. На каждом шаге вычислите

$$q_k = Ap_k, \quad \alpha_k = \frac{r_k^\top r_k}{p_k^\top q_k},$$

$$x_{k+1} = x_k + \alpha_k p_k, \quad r_{k+1} = r_k - \alpha_k q_k,$$

$$\beta_k = \frac{r_{k+1}^\top r_{k+1}}{r_k^\top r_k}, \quad p_{k+1} = r_{k+1} + \beta_k p_k.$$

Если новая невязка нулевая, проверьте завершение до вычисления следующего коэффициента.

Теорема. В точной арифметике разные невязки ортогональны, а направления поиска являются A-сопряжёнными. CG минимизирует квадратичную функцию на $x_0 + \mathcal{K}_k(A, r_0)$, где $\mathcal{K}_k = \operatorname{span}\{r_0, Ar_0, \ldots, A^{k-1}r_0\}$. В размерности d он завершается не более чем за d шагов.

Почему. Минимизация вдоль нового сопряжённого направления не отменяет минимизации вдоль предыдущих: $p_i^\top A(x + tp_j) = p_i^\top Ax$ при $i \neq j$. Когда направления поиска порождают всё пространство, градиент ортогонален всему пространству и должен быть нулевым.

Теорема. Для энергетической нормы $\|e\|_A = \sqrt{e^\top Ae}$

$$\|e_k\|_A \leq 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k \|e_0\|_A.$$

Так как $f(x_k) - f^* = \|e_k\|_A^2/2$, в отношении зазоров множитель возводится в квадрат. Группировка собственных значений может ускорить наблюдаемую сходимость по сравнению с наихудшей оценкой по интервалу.

Ловушка. Используйте $\|r\|/\|b\|$ при $b \neq 0$. При $b = 0$ задайте явный абсолютный порог. На небольших плотных примерах проверьте симметрию и положительную определённость; предусмотрите проверки неположительной кривизны, неконечных значений и лимита итераций. Истинная конечная невязка равна $b - Ax$, и её проверка стоит ещё одного произведения матрицы на вектор.

B3. Два шага сопряжённых градиентов

Самостоятельно

Условие. Решите $Ax = b$ методом CG при $A = \begin{pmatrix} 4 & 1 \\ 1 & 3 \end{pmatrix}$, $b = (1;\ 2)$, $x_0 = (0;\ 0)$. Начните с $r_0 = b - Ax_0$, $p_0 = r_0$. Вычислите α_0, β_0 и x_2. Проверьте $r_0^\top r_1 = 0$ и $p_0^\top Ap_1 = 0$. Сравните с прямым решением.

Решение.

1. Первая минимизация вдоль направления даёт $\alpha_0 = 0{,}25$, $x_1 = (0{,}25;\ 0{,}5)$, $r_1 = (-0{,}5;\ 0{,}25)$. Скалярное произведение с r_0 равно 0.
2. $\beta_0 = 0{,}0625$, $p_1 = r_1 + \beta_0 p_0 = (-0{,}4375;\ 0{,}375)$. Направления удовлетворяют $p_0^\top Ap_1 = 0$. Следующий шаг равен $\alpha_1 = 0{,}3636$.
3. $x_2 = x^* = (0{,}0909;\ 0{,}6364)$ и $r_2 = 0$ в точной арифметике. Для положительно определённой матрицы CG завершается не более чем за размерность шагов, но округление может потребовать дополнительных шагов. Вычисленное произведение Ap_k нужно использовать и в знаменателе, и при обновлении невязки.

Ответ. $\alpha_0 = 0{,}25$, $\beta_0 = 0{,}0625$, $x_2 = (0{,}0909;\ 0{,}6364)$.

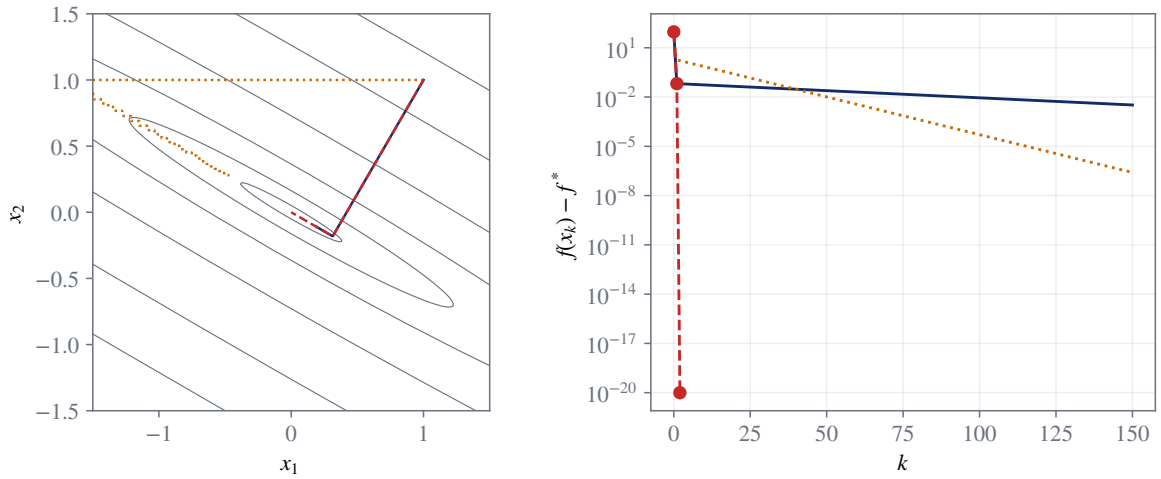


Рисунок. GD, циклический координатный спуск и CG на одной положительно определённой квадратичной функции с разными единицами работы.

6 Мини-батчи и шумовой порог

Определение. Для $F(w) = N^{-1}\sum_i \ell_i(w)$ новый равномерный индекс даёт $\mathbb{E}[\nabla \ell_i(w) \mid w] = \nabla F(w)$. Градиент батча — среднее градиентов его объектов. Если B выборок независимы и каждая имеет дисперсию σ^2, дисперсия батча равна σ^2/B.

Доказательство. Среднее выборки линейно, поэтому его ожидание равно полному среднему. Раскройте квадрат центрированного среднего: независимые смешанные члены имеют нулевое ожидание, остаются B диагональных членов, делённых на B^2. Без возвращения ковариационные члены отрицательны и дают поправку конечной совокупности $(N - B)/(N - 1)$.

Правило выборки

Перемешивание без возвращения в каждой эпохе удобно для реализации. Однако итерат зависит от предыдущих батчей, поэтому условная несмещённость каждого последующего батча не возникает автоматически. Указывайте, предполагает ли теоретический вывод новые независимые батчи или случайное перемешивание.

Теорема. Для L-гладкой функции и несмещённого градиента с условной дисперсией шума не выше σ^2/B лемма о спуске даёт

$$\mathbb{E}[F(w^+) \mid w] \le F(w) - \alpha(1 - L\alpha/2)\|\nabla F(w)\|^2 + \frac{L\alpha^2\sigma^2}{2B}.$$

Положительный шумовой член объясняет, почему постоянный шаг может оставлять порог.

Доказательство. Подставьте $w^+ = w - \alpha g$ в верхнюю модель гладкости. Используйте $\mathbb{E}[g \mid w] = \nabla F(w)$ и $\mathbb{E}[\|g\|^2 \mid w] \le \|\nabla F(w)\|^2 + \sigma^2/B$. Соберите градиентные и дисперсионные члены.

C1. Батч оценивает градиент

У доски

Условие. Пусть $\ell_i(w) = \frac{1}{2}(w - a_i)^2$, $a = (0;\ 2;\ 4;\ 6)$, а $F(w)$ — средняя функция потерь. В точке $w_0 = 0$ сравните полный шаг GD с шагом по батчу с целями $(0;\ 2)$, используя $\alpha = 0{,}25$. Найдите дисперсию одного равномерно выбранного градиента. Как она изменяется при усреднении двух выборок с возвращением и без?

Решение.

1. В начальной точке полный градиент равен -3, а градиент выбранного батча — -1. Поэтому $w_{\text{full}} = 0{,}75$ и $w_B = 0{,}25$. Батч даёт оценку, а не точный полный градиент.
2. Минимум достигается на среднем целевом значении $w^* = 3$. Вычтите полный градиент из каждого градиента объекта и возведите в квадрат; среднее равно $\sigma^2 = 5$. Усреднение двух независимых выборок даёт 2,5.
3. Для равномерного подмножества размера B без возвращения $\operatorname{Var}(g_B) = \sigma^2(N-B)/(B(N-1))$, поэтому здесь дисперсия равна 1,6667. Внутри перемешанной эпохи последующие батчи зависят от предыдущих выборок; условную независимость нельзя предполагать автоматически.

Ответ. $g_B = -1$, $w_B = 0{,}25$, $\sigma^2 = 5$.

C2. Шумовой порог при постоянном шаге

Самостоятельно

Условие. Для $F(w) = \frac{1}{2}\mu w^2$ градиент батча равен $\mu w + \xi_k$, где шумы независимы, имеют нулевое среднее и дисперсию σ^2/B. Пусть $\mu = 2$, $\sigma^2 = 9$, $B = 3$, $\alpha = 0{,}1$. Выведите рекуррентное соотношение для $\mathbb{E}w_k^2$ и его стационарное значение. Укажите стационарную дисперсию и средний зазор функции.

Решение.

1. $w_{k+1} = (1 - \alpha\mu)w_k - \alpha\xi_k$. Независимость и нулевое среднее дают

$$\mathbb{E}w_{k+1}^2 = (1 - \alpha\mu)^2\mathbb{E}w_k^2 + \alpha^2\sigma^2/B.$$

   Здесь среднее сжимается с множителем 0,8.

2. При $0 < \alpha\mu < 2$ решите уравнение неподвижной точки:

$$V_\infty = \frac{\alpha\sigma^2}{B\mu(2 - \alpha\mu)} = 0{,}0833.$$

   Предельное среднее равно нулю, поэтому этот второй момент — дисперсия; $\mathbb{E}[F(w) - F^*] = \mu V_\infty/2 = 0{,}0833$.

3. Меньший шаг или больший батч понижает порог. Среднеквадратичный радиус равен 0,2887, а не самой дисперсии. Убывающий шаг при подходящих предположениях может убрать постоянный порог.

Ответ. $V_\infty = 0{,}0833$, средний зазор 0,0833.

7 Расписания и воспроизводимые эксперименты

Определение. Определяйте расписание по **числу обновлений** k, начиная с нуля: постоянное $\alpha_k = \alpha_0$, шаг, обратно пропорциональный корню, $\alpha_k = \alpha_0/\sqrt{1+k}$, и обратное расписание $\alpha_k = \alpha_0/(1+k)$. Счётчик эпох задаёт другое расписание; не смешивайте соглашения.

Что гарантирует расписание

При обычных предположениях стохастической аппроксимации достаточные условия на шаг имеют вид $\sum_k \alpha_k = \infty$ и $\sum_k \alpha_k^2 < \infty$. Обратные шаги выполняют оба условия; обратный квадратный корень не даёт суммируемости квадратов. Это не запрещает его в выпуклых экспериментах с конечным бюджетом, но не позволяет ссылаться на ту же теорему без дополнительных аргументов.

Ловушка. Обратное расписание может слишком быстро уменьшить шаг ещё до прохождения вытянутой долины. Сравнивайте одинаковые начальный шаг, счётчик обновлений, данные, seed и бюджет работы. Расписание, выигравшее на коротком запуске, может проиграть на длинном.

Протокол эпохи

В каждой эпохе создавайте перестановку, берите срезы размера B и сохраняйте последний срез, даже если он короче. Используйте фактическую длину при усреднении градиента. Записывайте полную функцию после окончания эпохи. Повторите запуск на 5 случайных seed и покажите медиану и межквартильный интервал.

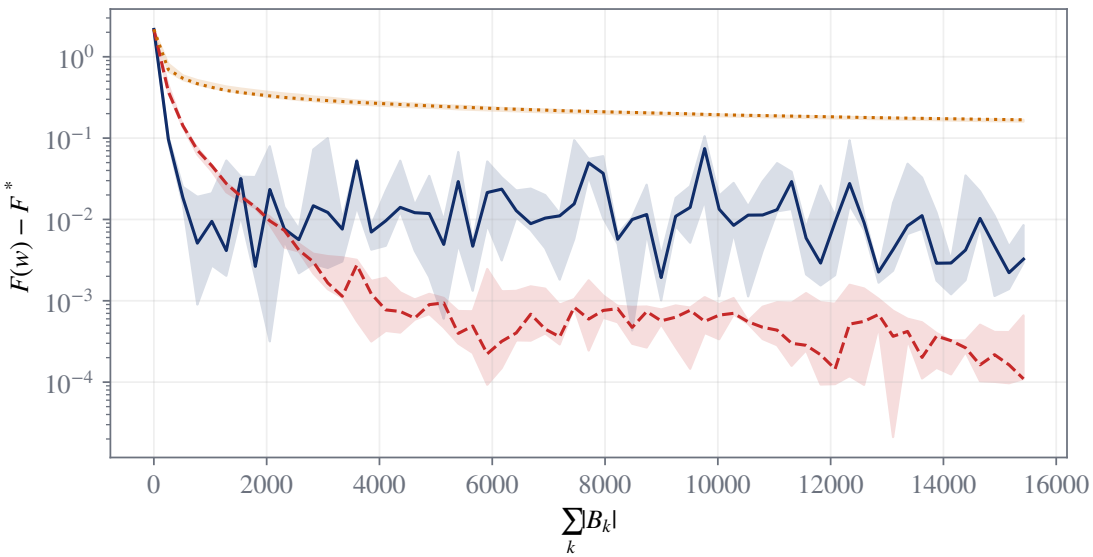


Рисунок. Используйте одинаковый бюджет градиентов объектов для всех расписаний; полосы показывают разброс по seed.

8 Стандартизация признаков

Определение. Для центрированной матрицы X пусть $S = \operatorname{diag}(s_i)$ содержит положительные стандартные отклонения обучающих признаков, а $Z = XS^{-1}$. Гессиан задачи наименьших квадратов равен $H_Z = S^{-1}HS^{-1}$ при $H = X^\top X/N$. Для равенства предсказаний $Zu = Xw$ нужно $w = S^{-1}u$.

Почему. Столбцы с разными единицами вытягивают квадратичную функцию. Масштабирование может убрать эту часть числа обусловленности. Оно не устраняет почти линейную зависимость столбцов, поэтому стандартизированный гессиан может остаться плохо обусловленным. Для постоянных столбцов нужно отдельное соглашение вместо деления на нуль.

Вернуть исходные единицы

При средних m стандартизированное предсказание $c + (x - m)^\top S^{-1}u$ превращается в $b + x^\top w$, где $w = S^{-1}u$ и $b = c - m^\top w$. Оценивайте m, S только по обучающим данным. Поиск наибольшего пригодного шага SGD по сетке — эмпирическая проверка конечного запуска, отличающаяся от границы полного градиента $2/\lambda_{\max}(H)$.

С3. Масштаб признаков и возврат единиц

Самостоятельно

Условие. Для центрированной задачи наименьших квадратов $F(w) = \|Xw - y\|^2/(2N)$ пусть $H = X^\top X/N = \begin{pmatrix} 1 & 0 \\ 0 & 100 \end{pmatrix}$. Стандартизуйте с помощью $Z = XS^{-1}$, $S = \operatorname{diag}(1;\ 10)$. Найдите числа обусловленности до и после масштабирования и границы устойчивости полного GD. Если в стандартизированных единицах получено $u = (2;\ 30)$, чему равны коэффициенты в исходных единицах?

Решение.

1. $H_Z = S^{-1}HS^{-1} = I$. Поэтому $\kappa(H) = 100$, $\kappa(H_Z) = 1$. Верхние границы шага полного GD равны соответственно $2/L = 0{,}02$ и 2; обе границы исключаются.
2. Верните коэффициенты: $w = S^{-1}u = (2;\ 3)$. Для нецентрированных признаков со средним m стандартизированная константа c превращается в $c - m^\top w$. Совпадения коэффициентов в двух системах координат ожидать не нужно.
3. В этом диагональном примере масштабирование исправляет разные единицы. Сильные корреляции могут остаться после стандартизации, а граница по полному гессиану не гарантирует устойчивость каждого отдельного случайного батча.

Ответ. κ: $100 \to 1$; $w = (2;\ 3)$.

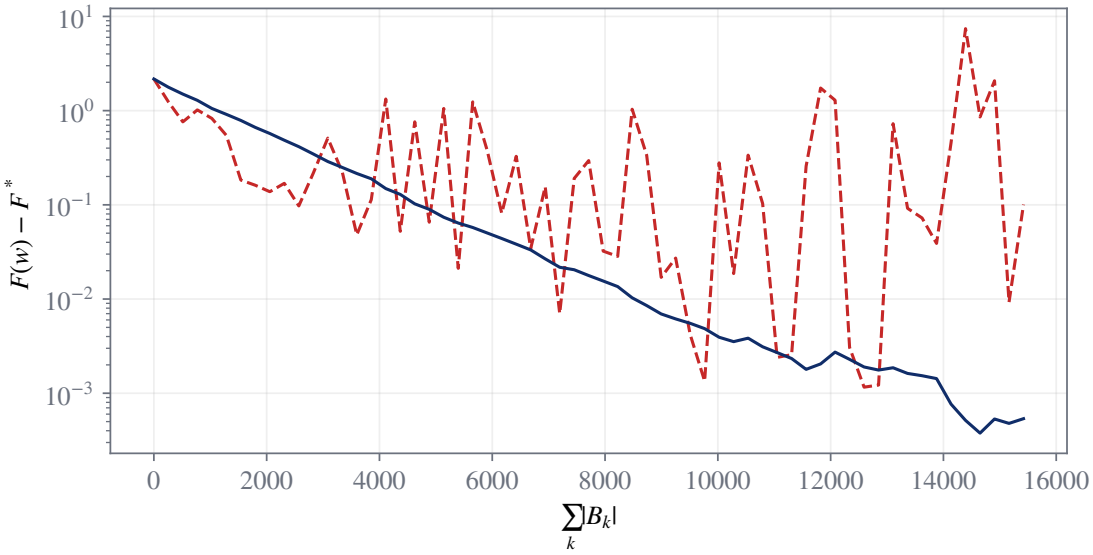


Рисунок. Потери в исходных и стандартизированных единицах при одинаковых настройках SGD.

9 Проверки реализации и упражнения

- Возвращайте независимую копию каждой сохранённой точки; добавление одного изменяемого массива стирает траекторию.
- Останавливайтесь по текущему градиенту или невязке, проверяйте конечность значений и указывайте лимит итераций.
- Указывайте отдельно работу инициализации, оптимизации и диагностики. Жадный просмотр координат вычисляет больше, чем одну выбранную производную.
- Сравните реализации NumPy с точными маленькими примерами и прямой линейной алгеброй, затем запускайте большие эксперименты.

Проверьте себя. Почему аналитически устойчивая пара может не пройти проверку скорости за конечное число шагов?

Ответ. Модуль корня возле единицы и начальный переходный режим могут удерживать функцию выше заданного порога конечного запуска.

Проверьте себя. Почему одну итерацию CG нельзя напрямую сравнить с одним координатным обновлением?

Ответ. CG вычисляет произведение матрицы на вектор, тогда как координатный шаг может использовать одну частную производную. Реальная стоимость зависит от разреженности и реализации выбора координаты.