Методы оптимизации

Семинар 5

Методы второго порядка и квазиньютоновские методы

Конспект теории

НИУ ВШЭ, факультет компьютерных наук

2026–2027 учебный год

Лектор курса: Андрей Игнатов

Евгений Баулин

Telegram: @tarakan_tuc

Содержание

1 Квадратичная модель и шаг Ньютона **2**

2 Локальная квадратичная сходимость **3**

3 Когда полный шаг не работает **4**

4 Сдвиг гессиана **6**

5 Методы Гаусса–Ньютона и Левенберга–Марквардта **7**

6 Стоимость кривизны **8**

7 Секущие пары и BFGS **9**

8 Условие кривизны **11**

9 Ограниченная память и ограничения-отрезки **11**

10 Проверки реализации и упражнения **12**

Градиентный спуск использует только наклон и расплачивается за это числом обусловленности. Конспект следует лекции и компьютерному семинару Андрея Игнатова о методах второго порядка: шаг Ньютона и его локальная теория, защита, без которой он не работает вдали от решения, методы Гаусса–Ньютона и Левенберга–Марквардта, BFGS и L-BFGS, стоимость кривизны.

Обозначения.
$f : \mathbb{R}^n \to \mathbb{R}$ дважды непрерывно дифференцируема, $g = \nabla f(x)$, $H = \nabla^2 f(x)$, $e = x - x^*$. B приближает гессиан, G — обратный к нему; $s_k = x_{k+1} - x_k$, $y_k = g_{k+1} - g_k$. $A \succ 0$ означает положительную определённость. Константа Армихо $c \in (0, 1)$, обычно малая.

1 Квадратичная модель и шаг Ньютона

Определение. Квадратичная модель f в точке x — это

$$m_x(p) = f(x) + g^\top p + \tfrac{1}{2} p^\top H p,$$

она совпадает с $f(x+p)$ с точностью до $o(\|p\|^2)$. Если H обратима, **направление Ньютона** p_N решает $Hp_N = -g$, а полный шаг Ньютона равен $x^+ = x + p_N$.

$\nabla_p m_x(p) = g + Hp$, так что p_N — стационарная точка модели. При $H \succ 0$ это единственный минимум модели; при знаконеопределённой H — её седло, а при $H \prec 0$ — максимум.

Почему. Градиентный спуск минимизирует модель, в которой H заменён на $\alpha^{-1} I$: круглую чашу. Ньютон использует чашу настоящей формы. В собственном базисе $H \succ 0$ шаг Ньютона делит каждую компоненту градиента на свою кривизну: крутым направлениям достаются короткие шаги, пологим — длинные.

Теорема: Один шаг на квадратичной функции. Для $f(x) = \frac{1}{2} x^\top Q x - b^\top x + c$ с $Q \succ 0$ один полный шаг Ньютона из любой точки x попадает в $x^* = Q^{-1} b$.

Доказательство. $g = Qx - b$ и $H = Q$. Уравнение Ньютона $Qp = -(Qx - b)$ даёт $p = -x + Q^{-1} b = x^* - x$, поэтому $x + p = x^*$.

Пример. Для $Q = \mathrm{diag}(1;\ 100)$ GD с шагом $\alpha = 1/L = 0{,}01$ уменьшает ошибку вдоль пологой оси в 0,99 раза за шаг, и чтобы уменьшить её в 1000000 раз, нужно 1375 шагов. Шаг Ньютона делит две компоненты градиента на их кривизны и заканчивает за один шаг.

Ловушка. Решайте $Hp = -g$ через разложение Холецкого или LU, `numpy.linalg.solve`, но никогда как `inv(H) @ g`. Явная обратная матрица дороже и менее точна, а неудавшееся разложение Холецкого — самая дешёвая проверка того, что $H \succ 0$.

A2. Один шаг на квадратичной функции

Самостоятельно

Условие. Пусть $f(x) = \frac{1}{2} x^\top Q x - b^\top x$, $Q = \begin{pmatrix} 4 & 1 \\ 1 & 2 \end{pmatrix}$, $b = (1;\ -1)$. Из $x_0 = (2;\ 0)$ найдите шаг Ньютона и x_1 и покажите, что x_1 не зависит от x_0. Найдите число обусловленности κ

матрицы Q.

Решение.

1. $g_0 = Qx_0 - b = (7;\ 3)$. Из $Qp = -g_0$ получаем $p_0 = (-1{,}5714;\ -0{,}7143)$ и $x_1 = x_0 + p_0 = (0{,}4286;\ -0{,}7143)$.
2. Для любого x уравнение Ньютона имеет вид $Qp = -(Qx - b)$, поэтому $p = Q^{-1}b - x = x^* - x$ и $x + p = x^*$. Действительно, $Qx_1 - b = 0$.
3. Собственные значения Q равны $(1{,}5858;\ 4{,}4142)$, значит, $\kappa = 2{,}7836$. Градиентный спуск с лучшим постоянным шагом сжимал бы ошибку в $(\kappa - 1)/(\kappa + 1) = 0{,}4714$ раза за шаг.

Ответ. $x_1 = (0{,}4286;\ -0{,}7143) = Q^{-1}b$ из любой точки; $\kappa = 2{,}7836$.

2 Локальная квадратичная сходимость

Теорема: Квадратичная сходимость. Пусть $\nabla f(x^*) = 0$, $\nabla^2 f(x^*) \succ 0$ и гессиан M-липшицев возле x^*. Тогда существуют окрестность x^* и $m > 0$, такие что полные шаги Ньютона из неё не выходят и

$$\|e^+\| \le \frac{M}{2m}\|e\|^2.$$

Доказательство. По формуле Ньютона–Лейбница $g(x) = \int_0^1 H(x^* + te)\, e\, dt$. Так как $e^+ = e - H(x)^{-1}g(x)$,

$$e^+ = H(x)^{-1}\int_0^1 \big[H(x) - H(x^* + te)\big]e\, dt.$$

Возле x^* гессиан остаётся положительно определённым, $\|H(x)^{-1}\| \le 1/m$, и $\|H(x) - H(x^* + te)\| \le M(1-t)\|e\|$. Интеграл от $1 - t$ даёт множитель $\frac{1}{2}$.

Как только $\frac{M}{2m}\|e\| < 1$, каждый шаг примерно вдвое увеличивает количество правильных первых знаков x_k. Важны обе константы: почти вырожденный гессиан в решении (малое m) или быстро меняющийся гессиан (большое M) сужает область, где это происходит.

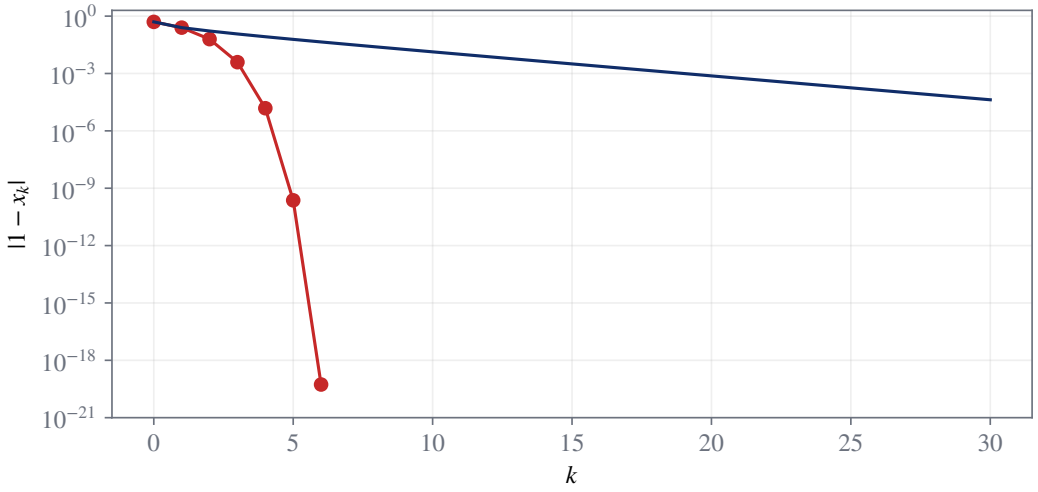


Рисунок. Ошибка метода Ньютона на $x - \ln x$ по итерациям в сравнении с градиентным спуском.

A3. Знаки удваиваются

Самостоятельно

Условие. Примените метод Ньютона к $f(x) = x - \ln x$, $x > 0$, из $x_0 = 0{,}5$. Выведите рекуррентное соотношение для $e_k = 1 - x_k$ и найдите x_3. Сколько шагов нужно, чтобы $e_k \le 10^{-12}$? При каких $x_0 > 0$ метод сходится?

Решение.

1. $x^+ = x - (1 - 1/x)x^2 = 2x - x^2$. При $e = 1 - x$: $e^+ = 1 - 2x + x^2 = (1 - x)^2 = e^2$, точно и с $C = 1$.
2. Из $x_0 = 0{,}5$ итерации равны $(0{,}5;\ 0{,}75;\ 0{,}9375;\ 0{,}9961)$, ошибки — $(0{,}5;\ 0{,}25;\ 0{,}0625;\ 0{,}0039)$; $x_3 = 0{,}9961$.
3. $e_k = e_0^{2^k} = 2^{-2^k}$. Впервые она становится меньше 10^{-12} при $k = 6$: каждый шаг удваивает число верных двоичных знаков.
4. Итерация сходится ровно при $|e_0| < 1$, то есть при $0 < x_0 < 2$. Из $x_0 = 2$ она попадает в 0, за пределы области определения; из большей точки, например из $x_0 = 2{,}5$, прыгает в $-1{,}25$.

Ответ. $e^+ = e^2$, $x_3 = 0{,}9961$, шагов: 6; сходимость при $0 < x_0 < 2$.

Ловушка. Для $f(x) = x^4$ в минимуме $f''(0) = 0$, и метод Ньютона даёт $x^+ = 0{,}6667\,x$: линейная сходимость, 35 шагов на уменьшение в 1000000 раз. Теорема выше не зря требует $\nabla^2 f(x^*) \succ 0$.

3 Когда полный шаг не работает

Вдоль p_N имеем $g^\top p_N = -g^\top H^{-1} g$. Это отрицательно при $H \succ 0$ и может быть положительно при знаконеопределённой H. Даже при $H \succ 0$ единичный шаг может выйти из области, где модель описывает f.

- **Направление вверх.** Знаконеопределённая H может дать $g^\top p_N > 0$; линейный поиск вдоль p_N не поможет.
- **Не та стационарная точка.** Метод Ньютона решает $\nabla f = 0$ и притягивается к сёдлам и максимумам так же охотно, как к минимумам.
- **Слишком длинный шаг.** Модель верна в x и неверна там, где лежит её минимум.
- **Вырожденная или плохо обусловленная H.** Решение линейной системы усиливает ошибки округления, и шаг может оказаться огромным.

B2. Притяжение к максимуму

Самостоятельно

Условие. Примените полный метод Ньютона к $f(x) = \frac{1}{4}x^4 - \frac{1}{2}x^2$ из $x_0 = 0{,}4$. Запишите итерацию как $x^+ = \varphi(x)$ и найдите x_1, x_2. Куда сходится метод и что это за точка? Найдите наибольшее a, при котором любая начальная точка с $0 < |x_0| < a$ притягивается к ней.

Решение.

1. $\varphi(x) = x - \frac{x^3-x}{3x^2-1} = \frac{2x^3}{3x^2-1}$. Из $x_0 = 0{,}4$: $x_1 = -0{,}2462$, $x_2 = 0{,}0365$.
2. Итерации идут в 0, где $f'(0) = 0$ и $f''(0) = -1$: это локальный максимум. Метод Ньютона ищет $f' = 0$ и не отличает максимум от минимума; возле 0 $\varphi(x) \approx -2x^3$, так что сходимость даже кубическая.
3. $\varphi(x) = -x$ даёт $2x^2 = 1 - 3x^2$, $x^2 = 1/5$. При $0 < |x| < a$, где $a = 1/\sqrt{5} = 0{,}4472$, выполнено $|\varphi(x)| < |x|$, и итерации стягиваются к максимуму; при $|x| = a$ они зацикливаются.

Ответ. $x_1 = -0{,}2462$, $x_2 = 0{,}0365$; сходимость к максимуму $x = 0$ при $0 < |x_0| < 0{,}4472$.

Определение. **Демпфированный метод Ньютона** перебирает $\alpha_k = 1, \beta, \beta^2, \ldots,$ пока не выполнится

$$f(x_k + \alpha_k p_k) \le f(x_k) + c\,\alpha_k \nabla f(x_k)^\top p_k,$$

и полагает $x_{k+1} = x_k + \alpha_k p_k$. Ему нужно, чтобы p_k было направлением спуска.

Утверждение. Если итерации демпфированного метода Ньютона сходятся к x^* с $\nabla^2 f(x^*) \succ 0$ и $c < \frac{1}{2}$, то для всех больших k принимается $\alpha_k = 1$, и сходимость квадратичная.

Доказательство. Возле x^* $f(x + p_N) - f(x) = -\frac{1}{2} g^\top H^{-1} g + o(\|g\|^2)$, а условие Армихо требует не больше $-c\, g^\top H^{-1} g$. Поскольку $c < \frac{1}{2}$, первое в итоге оказывается меньше второго.

A1. Ньютон на функции Розенброка: слишком длинный шаг

У доски

Условие. Для $f(x, y) = a(y - x^2)^2 + (1 - x)^2$ при $a = 100$ начните из $x_0 = (0;\ 0)$. Сделайте два полных шага Ньютона и найдите f после каждого. Затем из x_0 запустите демпфированный метод: делите α пополам, начиная с 1, пока не выполнится условие Армихо с $c = 0{,}0001$. Какое α будет принято и чему там равна f?

Решение.

1. В x_0: $\nabla f = (-2;\ 0)$ и $\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 200 \end{pmatrix}$. Решение $\nabla^2 f\, p = -\nabla f$ даёт $p_0 = (1;\ 0)$, поэтому $x_1 = (1;\ 0)$.
2. Но $f(x_1) = 100$, тогда как $f(x_0) = 1$. Квадратичная модель в x_0 верна до второго порядка, однако её минимум лежит далеко за пределами области, где она описывает f: при $x = 1$ дно долины $y = x^2$ находится на высоте один, а шаг остался на $y = 0$.
3. Из x_1: $\nabla f = (400;\ -200)$, $\nabla^2 f = \begin{pmatrix} 1202 & -400 \\ -400 & 200 \end{pmatrix}$, шаг Ньютона $p_1 = (0;\ 1)$. Значит, $x_2 = (1;\ 1)$ — минимум, $f(x_2) = 0$. Полный метод туда приходит, но через точку, которая в сто раз хуже начальной.
4. Демпфированный метод сохраняет направление p_0 и проверяет $f(x_0 + \alpha p_0) \le f(x_0) + c\alpha \nabla f^\top p_0$, где $\nabla f^\top p_0 = -2$. Для $\alpha = (1;\ 0{,}5;\ 0{,}25)$ значения равны $f = (100;\ 6{,}5;\ 0{,}9531)$: первые два не проходят, принимается $\alpha = 0{,}25$ в точке $x = (0{,}25;\ 0)$.

Ответ. $f(x_1) = 100$, $x_2 = (1;\ 1)$; с демпфированием $\alpha = 0{,}25$, пробные значения $f = (100;\ 6{,}5;\ 0{,}9531)$, последнее принято.

4 Сдвиг гессиана

Определение. **Регуляризованный шаг Ньютона** решает $(H + \lambda I)p = -g$, где $\lambda \geq 0$ выбрано так, что $H + \lambda I \succ 0$, то есть $\lambda > -\lambda_{\min}(H)$.

Утверждение. Если $H + \lambda I \succ 0$ и $g \neq 0$, то $g^\top p = -g^\top (H + \lambda I)^{-1} g < 0$. При $\lambda \to 0$ шаг стремится к шагу Ньютона, если $H \succ 0$; при $\lambda \to \infty$ $p \approx -\lambda^{-1} g$ — короткий градиентный шаг.

На практике λ начинают с нуля или с малого значения и умножают на константу до тех пор, пока $H + \lambda I$ не допустит разложения Холецкого; после удачного полного шага λ снова уменьшают. В собственном базисе шаг равен $p_i = -g_i/(\lambda_i + \lambda)$: по направлению отрицательной кривизны с $\lambda_i + \lambda > 0$ теперь идут вниз.

B1. Направление Ньютона ведёт вверх

У доски

Условие. Пусть $f(x, y) = \frac{1}{2}x^2 - y^2 + \frac{1}{4}y^4$ в точке $(0;\ 0{,}5)$. Найдите g, H, направление Ньютона p_N и $g^\top p_N$. Является ли p_N направлением спуска? Найдите наименьший сдвиг, при котором $H + \lambda I$ положительно определена, решите $(H + \lambda I)p = -g$ при $\lambda = 2$ и проверьте полный шаг по Армихо с $c = 0{,}0001$.

Решение.

1. $g = (0;\ -0{,}875)$, $H = \begin{pmatrix} 1 & 0 \\ 0 & -1{,}25 \end{pmatrix}$: одно собственное значение отрицательно, так что H знаконеопределён. Метод Ньютона даёт $p_N = -H^{-1}g = (0;\ -0{,}7)$ и $g^\top p_N = 0{,}6125 > 0$.
2. У $\phi(\alpha) = f(x + \alpha p_N)$ производная $\phi'(0) = g^\top p_N > 0$: любой малый шаг увеличивает f, а полный шаг переводит её из $-0{,}2344$ в $-0{,}0396$. Дробление уменьшало бы α бесконечно. Менять нужно само направление.
3. $H + \lambda I \succ 0$ ровно при $\lambda > 1{,}25$. При $\lambda = 2$: $p = (0;\ 1{,}1667)$ и $g^\top p = -1{,}0208 < 0$. Теперь шаг идёт вдоль отрицательной кривизны, прочь от седла.
4. Армихо при $\alpha = 1$: $f(x + p) = -0{,}8488 \leq f(x) + c\, g^\top p = -0{,}2345$, значит, полный регуляризованный шаг принимается. Минимумы находятся в $y = \pm 1{,}4142$, где $H \succ 0$ и сдвиг можно убрать.

Ответ. $g^\top p_N = 0{,}6125$: это не направление спуска. $\lambda > 1{,}25$; при $\lambda = 2$ шаг равен $(0;\ 1{,}1667)$, и f уменьшается до $-0{,}8488$.

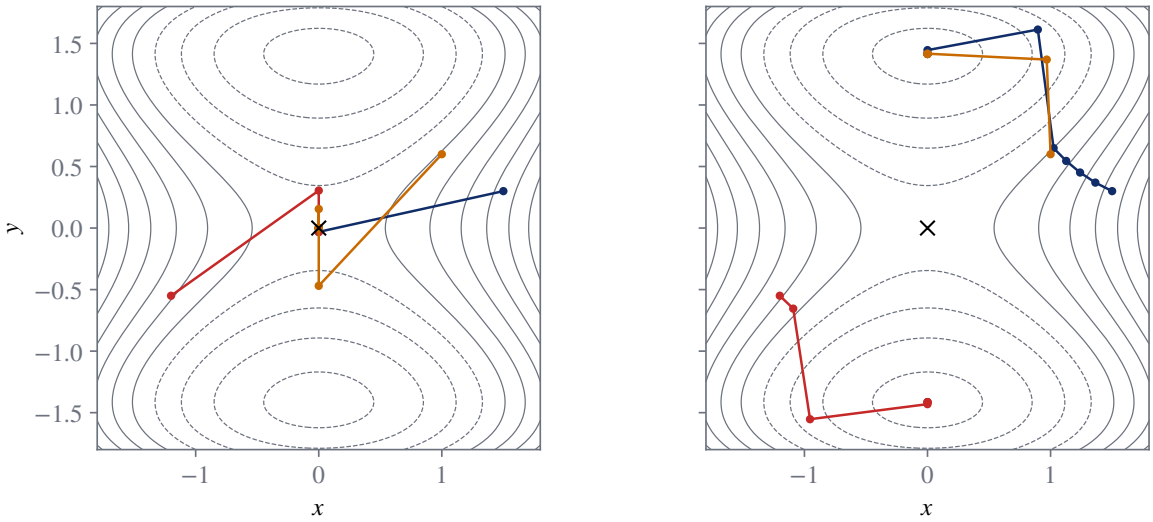


Рисунок. Полный метод Ньютона сходится в седло; регуляризованный демпфированный метод уходит от него вдоль отрицательной кривизны.

Доверительные области

Методы доверительной области выбирают сначала длину шага, а потом сдвиг: p минимизирует модель при $\|p\| \le \Delta$, а решение имеет вид $(H + \lambda I)p = -g$ с $\lambda \ge 0$, определяемым Δ. Отрицательную кривизну они обрабатывают без отдельной проверки.

5 Методы Гаусса–Ньютона и Левенберга–Марквардта

Для $f(x) = \frac{1}{2}\|r(x)\|^2$ с невязками $r : \mathbb{R}^n \to \mathbb{R}^N$ и якобианом J

$$\nabla f = J^\top r, \qquad \nabla^2 f = J^\top J + \sum_i r_i \nabla^2 r_i.$$

Определение. **Метод Гаусса–Ньютона** отбрасывает второе слагаемое и решает $J^\top J p = -J^\top r$; это шаг Ньютона для линеаризованной невязки $r + Jp$. **Метод Левенберга–Марквардта** решает $(J^\top J + \lambda I)p = -J^\top r$.

Почему. $J^\top J \succeq 0$ требует только первых производных, а отброшенное слагаемое мало, когда невязки возле решения малы. Сдвиг λ справляется с неполным рангом J и сдвигает шаг от Гаусса–Ньютона к короткому градиентному шагу.

B3. Гаусс–Ньютон, Ньютон и Левенберг–Марквардт

Самостоятельно

Условие. Пусть $f(\theta) = \frac{1}{2}\|r(\theta)\|^2$, $r(\theta) = (\theta^2 - 2,\ \theta - 1)$. Из $\theta_0 = 1$ сделайте один шаг Гаусса–Ньютона, один шаг Ньютона с точной второй производной и один шаг Левенберга–Марквардта с $\lambda = 1$. Укажите θ_1 для каждого и сравните с точкой минимума.

Решение.

1. В θ_0: $r = (-1;\ 0)$, $J = (2;\ 1)$, $J^\top J = 5$, $J^\top r = -2$. Гаусс–Ньютон: $\theta_1 = \theta_0 - J^\top r / J^\top J = 1{,}4$.

2. Точная вторая производная добавляет $r_1 r_1'' = -2$, так что $f'' = 3$, и метод Ньютона даёт $\theta_1 = 1{,}6667$. Левенберг–Марквардт делит на $J^\top J + \lambda$: $\theta_1 = 1{,}3333$.

3. $f'(\theta) = 2\theta^3 - 3\theta - 1 = (\theta+1)(2\theta^2 - 2\theta - 1)$, точка минимума $\theta^* = (1+\sqrt{3})/2 = 1{,}366$. Ближе всех оказывается Гаусс–Ньютон: в θ_0 слагаемое с невязкой уменьшило точную кривизну, и шаг Ньютона вышел слишком длинным.

Ответ. Гаусс–Ньютон 1,4, Ньютон 1,6667, Левенберг–Марквардт 1,3333; $\theta^* = 1{,}366$.

6 Стоимость кривизны

Операция	Стоимость	Память
Построить гессиан	$O(n^2)$ производных; $O(Nn^2)$ для GLM	$O(n^2)$
Разложение Холецкого	$\approx n^3/3$	$O(n^2)$
Решение с разложением	$O(n^2)$	$O(n^2)$
Произведение гессиана на вектор	несколько градиентов	$O(n)$ дополнительно
Направление L-BFGS	$\approx 4mn$	$2mn$

Пример. Логистическая функция потерь со штрафом ℓ_2, $f(w) = N^{-1}\sum_i \big[\log(1+e^{z_i}) - y_i z_i\big] + \frac{\gamma}{2}\|w\|^2$, $z = Xw$:

$$\nabla f = N^{-1}X^\top(\sigma(z) - y) + \gamma w, \quad Hv = N^{-1}X^\top\big(d \odot Xv\big) + \gamma v,$$

где $d_i = \sigma(z_i)(1-\sigma(z_i))$. Произведение стоит двух проходов по X и не строит H.

Newton-CG приближённо решает $Hp = -g$ с помощью CG, которому нужны только произведения Hv. Ранняя остановка CG или остановка при отрицательной кривизне $v^\top Hv \le 0$ всё равно даёт направление спуска.

С3. Сколько стоит гессиан

Самостоятельно

Условие. Логистическая регрессия с $N = 100000$ объектами и $n = 20000$ признаками. Построение $H = N^{-1}X^\top DX$ стоит около Nn^2 умножений со сложением, одно произведение $Hv = N^{-1}X^\top(d \odot Xv)$ — около $2Nn$. Во сколько раз решение системы методом Newton-CG с $k = 16$ произведениями дешевле построения H? Сколько гигабайт занимает плотная H при 8 байтах на элемент и сколько мегабайт занимают $m = 5$ пар L-BFGS?

Решение.

1. $Nn^2/(2kNn) = n/(2k) = 625$: число объектов сокращается, а выигрыш растёт вместе с числом признаков.

2. Плотная H содержит n^2 элементов: 3,2 ГБ ещё до какого-либо разложения. L-BFGS хранит $2m$ векторов длины n: 1,6 МБ.

3. Разложение Холецкого добавило бы около $n^3/3$ операций. При n порядка десятков тысяч метод Ньютона возможен только без матрицы, через Hv и сопряжённые градиенты.

Ответ. Отношение 625; плотная H — 3,2 ГБ; L-BFGS — 1,6 МБ.

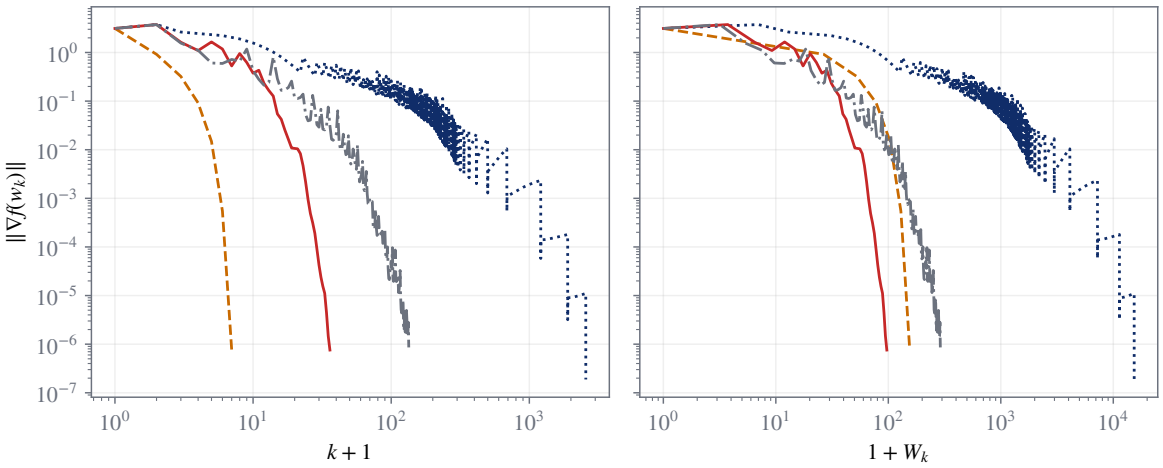


Рисунок. Норма градиента по итерациям и по проходам по данным для градиентного спуска, демпфированного Ньютона, BFGS и L-BFGS.

7 Секущие пары и BFGS

По формуле Ньютона–Лейбница

$$y_k = \left[\int_0^1 \nabla^2 f(x_k + t s_k)\, dt\right] s_k :$$

y_k — действие усреднённого гессиана на s_k. Квазиньютоновский метод хранит матрицу, которая его воспроизводит.

Определение. **Секущие условия** — это $B_{k+1}s_k = y_k$ и $G_{k+1}y_k = s_k$. **Обновление BFGS** в форме гессиана и в обратной форме:

$$B_{k+1} = B_k - \frac{B_k s_k s_k^\top B_k}{s_k^\top B_k s_k} + \frac{y_k y_k^\top}{y_k^\top s_k}, \qquad G_{k+1} = (I - \rho_k s_k y_k^\top) G_k (I - \rho_k y_k s_k^\top) + \rho_k s_k s_k^\top,$$

где $\rho_k = 1/(y_k^\top s_k)$. Направление $p_k = -G_k g_k$, с линейным поиском.

Почему именно эта формула

Одно векторное уравнение не определяет матрицу. BFGS — симметричное обновление, ближайшее к G_k в некоторой взвешенной норме среди удовлетворяющих секущему условию; оно меняет G на матрицу ранга не выше двух. DFP — та же конструкция, в которой B и G поменялись ролями.

Теорема. $G_{k+1}y_k = s_k$. Если $G_k \succ 0$ и $y_k^\top s_k > 0$, то $G_{k+1} \succ 0$.

Доказательство. $(I - \rho y s^\top)y = y - \rho y(s^\top y) = 0$, поэтому первое слагаемое обращается в ноль на y, а $\rho s s^\top y = s$. Для $z \neq 0$ положим $V = I - \rho s y^\top$: $z^\top G_{k+1} z = (V^\top z)^\top G_k (V^\top z) + \rho (s^\top z)^2 \geq 0$. Если бы это было нулём, то $s^\top z = 0$, откуда $V^\top z = z - \rho y (s^\top z) = z$ и $z^\top G_k z = 0$, то есть $z = 0$.

C1. BFGS на квадратичной функции вручную

У доски

Условие. Пусть $f(x) = \frac{1}{2}x^\top Qx$, $Q = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$, $x_0 = (-2;\ 2)$, $G_0 = I$, линейный поиск точный. Сделайте первый шаг, составьте s, y и обратное обновление BFGS G_1. Проверьте секущее условие и положительную определённость. Сделайте второй шаг: чему равны α_1 и x_2?

Решение.

1. $g_0 = Qx_0 = (-2;\ 0)$, $p_0 = -G_0 g_0 = (2;\ 0)$, $\alpha_0 = 0{,}5$. Отсюда $s = (1;\ 0)$, $x_1 = (-1;\ 2)$, $g_1 = (0;\ 1)$ и $y = g_1 - g_0 = (2;\ 1)$; на квадратичной функции $y = Qs$ точно.
2. $y^\top s = 2 > 0$, $\rho = 0{,}5$. При $V = I - \rho sy^\top$
$$G_1 = VG_0V^\top + \rho ss^\top = \begin{pmatrix} 0{,}75 & -0{,}5 \\ -0{,}5 & 1 \end{pmatrix}.$$
3. $G_1 y = (1;\ 0) = s$. Матрица G_1 симметрична, её собственные значения $(0{,}3596;\ 1{,}3904)$ положительны. Обратная к ней $B_1 = \begin{pmatrix} 2 & 1 \\ 1 & 1{,}5 \end{pmatrix}$ совпадает с Q вдоль s, но пока не в других направлениях.
4. $p_1 = -G_1 g_1 = (0{,}5;\ -1)$, $g_1^\top p_1 < 0$, точный шаг $\alpha_1 = 2$: $x_2 = (0;\ 0) = x^*$. При точном линейном поиске BFGS минимизирует n-мерную положительно определённую квадратичную функцию не более чем за n шагов.

Ответ. $G_1 = \begin{pmatrix} 0{,}75 & -0{,}5 \\ -0{,}5 & 1 \end{pmatrix}$, $G_1 y = s$; $\alpha_1 = 2$, $x_2 = (0;\ 0)$.

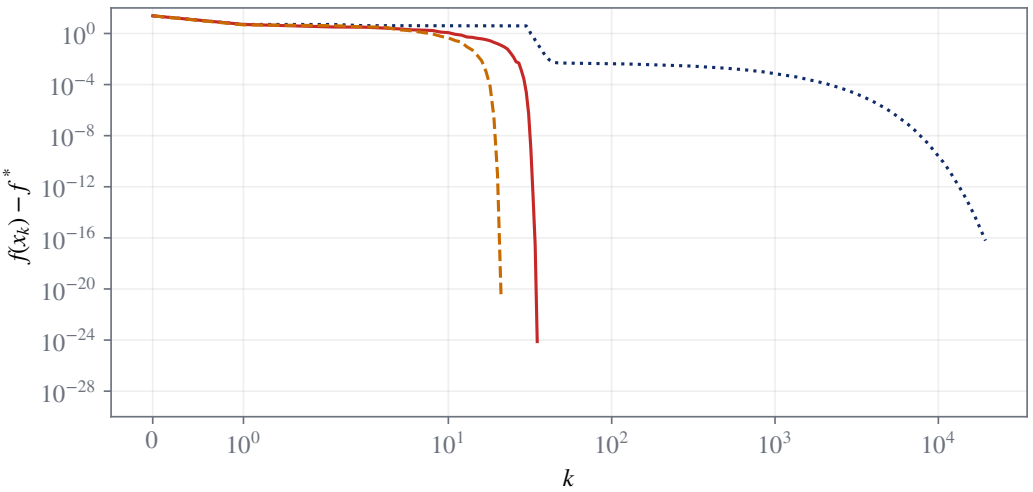


Рисунок. Градиентный спуск, BFGS и метод Ньютона на функции Розенброка: зазор функции по итерациям.

Возле невырожденного минимума BFGS с линейным поиском, который в итоге принимает $\alpha = 1$, сходится сверхлинейно: $\|e_{k+1}\|/\|e_k\| \to 0$. Квадратичной скорости Ньютона он не достигает, зато ему нужны только градиенты и $O(n^2)$ работы на шаг.

8 Условие кривизны

$y_k^\top s_k = s_k^\top \left[\int_0^1 \nabla^2 f(x_k + t s_k) dt\right] s_k$ — средняя кривизна вдоль шага. Для μ-сильно выпуклой f она не меньше $\mu\|s_k\|^2 > 0$; для невыпуклой f может иметь любой знак.

Определение. **Условия Вульфа** для шага α вдоль направления спуска p — это условие Армихо и условие кривизны $\nabla f(x + \alpha p)^\top p \geq c_2 \nabla f(x)^\top p$, где $0 < c < c_2 < 1$.

Утверждение. Если α удовлетворяет условию кривизны Вульфа вдоль направления спуска p, то $y^\top s > 0$ для $s = \alpha p$.

Доказательство. $y^\top s = \alpha\big(\nabla f(x + \alpha p) - \nabla f(x)\big)^\top p \geq \alpha(c_2 - 1)\nabla f(x)^\top p > 0$, поскольку $c_2 < 1$ и $\nabla f(x)^\top p < 0$.

C2. Условие кривизны

Самостоятельно

Условие. Для $f(x) = \frac{1}{4}x^4 - \frac{1}{2}x^2$ возьмите точки $(0;\ 0{,}5;\ 1{,}5)$. Найдите $y^\top s$ для шага из первой точки во вторую; можно ли BFGS использовать эту пару? Для шага из второй точки в третью найдите секущую кривизну $B = y/s$ и квазиньютоновский шаг $x^+ = x - f'(x)/B$ из третьей точки.

Решение.

1. Из первой точки во вторую: $s = 0{,}5$, $y = -0{,}375$ и $y^\top s = -0{,}1875 < 0$. Обновление сделало бы G отрицательной; BFGS должен пропустить эту пару.
2. Из второй точки в третью: $s = 1$, $y = 2{,}25$, $B = y/s = 2{,}25$. По теореме о среднем это среднее значение f'' на шаге, и оно положительно.
3. Из третьей точки $x^+ = x - f'(x)/B = 0{,}6667$. Минимум находится в 1; в одномерном случае BFGS — это метод секущих, который сходится сверхлинейно возле невырожденного минимума.

Ответ. $y^\top s = -0{,}1875$: пару нужно пропустить. $B = 2{,}25$, $x^+ = 0{,}6667$.

Ловушка. Одно дробление по Армихо не гарантирует $y^\top s > 0$. Реализации пропускают обновление при $y^\top s \leq \varepsilon\|y\|\|s\|$ или демпфируют y в сторону Bs (демпфирование Пауэлла). Без этой проверки одно обновление с $y^\top s < 0$ может сделать G знаконеопределённой, а следующее направление — направлением подъёма.

9 Ограниченная память и ограничения-отрезки

Плотный BFGS хранит матрицу $n \times n$. **L-BFGS** хранит последние m пар (s_i, y_i), обычно m от пяти до двадцати, и умножает G_k на g_k, не строя её.

- Положите $q = g_k$. Для пар от новой к старой: $a_i = \rho_i s_i^\top q$, $q \leftarrow q - a_i y_i$.
- Масштабируйте: $r = \gamma_k q$, где $\gamma_k = s_{k-1}^\top y_{k-1} / y_{k-1}^\top y_{k-1}$ — оценка обратной кривизны.
- Для пар от старой к новой: $b_i = \rho_i y_i^\top r$, $r \leftarrow r + s_i(a_i - b_i)$.

- Верните $p_k = -r$: около $4mn$ операций и $2mn$ хранимых чисел.

Результат равен $-Gg$ для матрицы, полученной из $\gamma_k I$ последовательными обновлениями BFGS по хранимым m парам. Старая кривизна забывается, и на задачах, где она была бы полезна, это стоит итераций.

L-BFGS-B

Для ограничений $l \le x \le u$ **L-BFGS-B** движется по пути проекции градиента до обобщённой точки Коши, фиксирует переменные на их границах, минимизирует модель с ограниченной памятью по свободным переменным и делает линейный поиск, не выходящий из бруса. Стационарность измеряется проекцией градиента.

Ловушка. Обрезка решения задачи без ограничений по брусу в общем случае не даёт условный минимум: если две переменные связаны, фиксация одной на границе сдвигает оптимум другой.

Метод	Нужно	На шаг	Возле решения
Градиентный спуск	g	$O(n)$	линейная, скорость задаёт κ
Ньютон	g, H	$O(n^3)$	квадратичная
Newton-CG	g, Hv	итерации CG	сверхлинейная при уменьшающемся допуске
BFGS	g	$O(n^2)$	сверхлинейная
L-BFGS	g	$O(mn)$	в общем случае линейная

10 Проверки реализации и упражнения

- Решайте систему, а не обращайте матрицу; определяйте $H \not\succ 0$ по неудавшемуся разложению Холецкого и сдвигайте.
- Проверяйте $g^\top p < 0$ до линейного поиска и $y^\top s > 0$ до обновления BFGS.
- Проверяйте производные: центральные разности для g, разность градиентов для Hv, для нескольких величин шага.
- Записывайте вызовы функции, градиента и гессиана рядом с итерациями и сравнивайте методы при одном правиле остановки.
- В конце проверяйте гессиан или наименьшую найденную кривизну: малый градиент может означать седло.

Проверьте себя. Почему дробление шага не может исправить направление Ньютона с $g^\top p > 0$?

Ответ. Потому что $f(x + \alpha p) = f(x) + \alpha g^\top p + o(\alpha)$ растёт при любом малом α; условие Армихо не выполняется ни для одного из них.

Проверьте себя. Какую информацию несёт одна секущая пара (s, y)?

Ответ. Действие среднего гессиана на отрезке на один вектор s и ничего о других направлениях.

Проверьте себя. Когда произведение гессиана на вектор полезнее самого гессиана?

Ответ. Когда n велико: Hv стоит несколько градиентов и $O(n)$ памяти, а методу сопряжённых градиентов нужны только такие произведения.