Методы оптимизации

Семинар 6

Методы второго порядка, часть вторая: Гаусс–Ньютон, Левенберг–Марквардт, доверительная область, L-BFGS

Конспект теории

НИУ ВШЭ, факультет компьютерных наук

2026-2027 учебный год

Лектор курса: Андрей Игнатов

Евгений Баулин

Telegram: @tarakan_tuc

Содержание

1 Метод Гаусса–Ньютона **2**

2 Метод Левенберга–Марквардта **3**

3 Доверительная область **4**

4 BFGS с ограниченной памятью **5**

Методы второго порядка, продолжение. На семинаре 5 были шаг Ньютона и его защита. Конспект следует лекции и компьютерному семинару Андрея Игнатова о методах Гаусса–Ньютона и Левенберга–Марквардта для наименьших квадратов, о доверительной области как другой защите и об L-BFGS как квазиньютоновском методе с ограниченной памятью.

Обозначения.
$r : \mathbb{R}^n \to \mathbb{R}^m$ — вектор невязок с якобианом J. B — текущая оценка гессиана, G — обратной к нему; $s_k = x_{k+1} - x_k$, $y_k = g_{k+1} - g_k$. Радиус доверия — Δ; квадратичная модель — $m(p) = f + g^\top p + \frac{1}{2} p^\top B p$, а $\rho =$ (фактическая)/(предсказанная).

1 Метод Гаусса–Ньютона

Для $f(x) = \frac{1}{2}\|r(x)\|^2$ с $r : \mathbb{R}^n \to \mathbb{R}^m$ и якобианом J имеем $\nabla f = J^\top r$ и $\nabla^2 f = J^\top J + \sum_i r_i \nabla^2 r_i$. Метод Гаусса–Ньютона оставляет только $J^\top J$ и решает $J^\top J p = -J^\top r$.

Почему. Шаг Гаусса–Ньютона — это шаг Ньютона для линеаризованной невязки $r + Jp$. Отброшенное слагаемое — то, которое требовало бы вторых производных r; оно мало, когда невязки в решении малы.

Теорема: Сходимость метода Гаусса–Ньютона. Если $J(x^*)$ имеет полный столбцовый ранг и $r(x^*) = 0$, существует окрестность x^*, в которой Гаусс–Ньютон сходится к x^* квадратично. Если же $\|r(x^*)\|$ отделено от нуля, сходимость в лучшем случае линейная.

Ловушка. $J^\top J$ положительно полуопределена, но не определена: если J не полного ранга, нормальные уравнения становятся вырожденными. Левенберг–Марквардт решает это сдвигом; QR-разложение J — более точная альтернатива, никогда не строящая $J^\top J$.

A1. Гаусс–Ньютон на подгонке экспоненты

У доски

Условие. Подгоните $f_\theta(t) = a\, e^{bt}$ к четырём точкам $(t_i, y_i) = \begin{pmatrix} 0 & 2 \\ 1 & 3{,}3 \\ 2 & 5{,}4 \\ 3 & 9 \end{pmatrix}$ с $\theta = (a, b)$. Из $\theta_0 = (1;\ 1)$ сделайте два шага Гаусса–Ньютона. Укажите θ_1, θ_2 и $\frac{1}{2}\|r(\theta_2)\|^2$.

Решение.

1. В точке θ_0 модельные значения $a_0 e^{b_0 t_i} = (1;\ 2{,}7183;\ 7{,}3891;\ 20{,}0855)$, значит, $r_0 = (-1;\ -0{,}5817;\ 1{,}9891;\ 11{,}0855)$. У якобиана строки $(e^{b_0 t_i},\, a_0 t_i e^{b_0 t_i})$: $J_0 = \begin{pmatrix} 1 & 0 \\ 2{,}7183 & 2{,}7183 \\ 7{,}3891 & 14{,}7781 \\ 20{,}0855 & 60{,}2566 \end{pmatrix}$.

2. Нормальные уравнения $J_0^\top J_0\, p = -J_0^\top r_0$ дают $J_0^\top J_0 = \begin{pmatrix} 466{,}416 & 1326{,}8717 \\ 1326{,}8717 & 3856{,}6408 \end{pmatrix}$ и $J_0^\top r_0 = (234{,}7749;\ 695{,}7901)$. Решая по правилу Крамера, получаем $p_0 = (0{,}4654;\ -0{,}3405)$, значит, $\theta_1 = \theta_0 + p_0 = (1{,}4654;\ 0{,}6595)$.

3. Повторяем в θ_1: модель $(1{,}4654;\ 2{,}8337;\ 5{,}4798;\ 10{,}5967)$, невязки $(-0{,}5346;\ -0{,}4663;\ 0{,}0798;\ 1{,}5967)$, $J_1 = \begin{pmatrix} 1 & 0 \\ 1{,}9338 & 2{,}8337 \\ 3{,}7395 & 10{,}9595 \\ 7{,}2314 & 31{,}79 \end{pmatrix}$. Нормальные уравнения дают $p_1 = (0{,}4557;\ -0{,}1548)$ и $\theta_2 = (1{,}9211;\ 0{,}5047)$. Сумма квадратов падает с 64,0919 до 1,5295 и далее до 0,0542: уже после второго шага мы возле минимума.

4. Точное второе слагаемое гессиана равно $\sum_i r_i \nabla^2 r_i$: при малых невязках оно мало, и Гаусс–Ньютон ведёт себя как Ньютон. Точки лежат на экспоненциальной кривой, невязки быстро уменьшаются, а сходимость почти квадратичная.

Ответ. $\theta_1 = (1{,}4654;\ 0{,}6595)$, $\theta_2 = (1{,}9211;\ 0{,}5047)$, $\frac{1}{2}\|r(\theta_2)\|^2 = 0{,}0542$.

2 Метод Левенберга–Марквардта

> **Определение.** **Метод Левенберга–Марквардта** решает $(J^\top J + \lambda I)p = -J^\top r$ с $\lambda \geq 0$, которое адаптируется по отношению $\rho = \frac{f(x)-f(x+p)}{m(0)-m(p)}$: при хорошем ρ λ уменьшается, при плохом — растёт.

Малое λ — это Гаусс–Ньютон; большое — короткий градиентный шаг $-J^\top r/\lambda$. Метод интерполирует между ними без необходимости выбирать стратегию линейного поиска.

A2. Левенберг–Марквардт спасает дикое начало

Самостоятельно

Условие. В задаче подгонки из A1 начните из далёкой точки $\theta_0 = (10;\ 1{,}5)$ и сделайте три шага Левенберга–Марквардта с $\lambda_0 = 1$. Правило: $\rho = (f(\theta) - f(\theta + p))/(m(0) - m(p))$; если $\rho \geq 0{,}25$, шаг принимается и $\lambda \leftarrow \lambda/10$; иначе шаг отвергается и $\lambda \leftarrow \lambda \cdot 10$. Укажите θ после первого и после третьего принятого шага, а также число отказов.

Решение.

1. Из θ_0 полный шаг Гаусса–Ньютона уходит слишком далеко; LM с $\lambda_0 = 1$ его укорачивает. Первые пробные шаги имеют $\rho < 0{,}25$ и отвергаются; λ каждый раз увеличивается в десять раз, пока сдвига не станет достаточно.

2. После первого принятого шага $\theta = (0{,}8765;\ 1{,}474)$. Три принятых шага приводят θ к $(1{,}0785;\ 0{,}8463)$; суммарное число отказов — 0.

3. Каждое принятие делит λ на десять, каждое отвержение — умножает на десять. Метод начинается как градиентный, по мере роста доверия к модели ведёт себя всё более как Гаусс–Ньютон и заканчивается очень близко к его пределу.

Ответ. После одного принятого шага $a = 0{,}8765$; после трёх, $b = 0{,}8463$; отказов — 0.

3 Доверительная область

> **Определение. Шаг доверительной области** минимизирует квадратичную модель при $\|p\| \le \Delta$:
>
> $$p = \arg\min_{\|p\| \le \Delta} f + g^\top p + \tfrac{1}{2} p^\top B p.$$
>
> По ККТ минимум удовлетворяет $(B + \lambda I)p = -g$ при некотором $\lambda \ge 0$ с условием $\lambda(\|p\| - \Delta) = 0$.

Dogleg приближает решение ломаной $0 \to p_C \to p_N$: берут самую дальнюю точку этой ломаной, лежащую в шаре. Это точно, когда $B \succ 0$ и путь dogleg совпадает с кривой решений доверительной области.

- Если $\rho > 3/4$ и $\|p\| = \Delta$, то Δ удваивается.
- Если $\rho > 1/4$, Δ сохраняется.
- Если $\rho < 1/4$, Δ делится на четыре.
- Шаг отвергается при слишком малом ρ; иначе принимается.

B1. Dogleg на вытянутой квадратичной функции

У доски

Условие. Для $f(x, y) = \frac{1}{2}(x^2 + 10\,y^2)$ в $x_0 = (2;\ 1)$ при $B_0 = \nabla^2 f$ и $\Delta = 2$ найдите точку Коши p_C и точку Ньютона p_N. Точка Ньютона лежит за шаром, поэтому dogleg идёт по ломаной из 0 через p_C в p_N до пересечения со сферой. Дайте вторую компоненту p_C, первую компоненту шага dogleg и значение f после шага.

Решение.

1. $g = Bx_0 = (2;\ 10)$, $B = \mathrm{diag}(1;\ 10)$. Шаг Ньютона $p_N = -B^{-1}g = (-2;\ -1)$ имеет длину $\|p_N\| = 2{,}2361 > \Delta$. Безусловный минимум уже лежит за шаром, значит, dogleg остановится на границе.
2. Квадратичная $m(-\alpha g) = f - \alpha g^\top g + \frac{1}{2}\alpha^2 g^\top B g$ минимизируется при $\alpha^* = g^\top g / (g^\top B g) = 0{,}1036$; её длина $\alpha^* \|g\| = 1{,}0564 < \Delta$, поэтому $p_C = -\alpha^* g = (-0{,}2072;\ -1{,}0359)$. Обе координаты сжаты: крутая сильнее, чем пологая.
3. На отрезке от p_C до p_N решим $\|p(\tau)\|^2 = \Delta^2$ для положительного корня: $\tau = 0{,}8488$. Шаг dogleg равен $p = (-1{,}7289;\ -1{,}0054)$, его длина $\|p\| = 2 = \Delta$, на границе.
4. $f(x_0) = 7$, $f(x_0 + p) = 0{,}0369$, модельная убыль $m(0) - m(p) = 6{,}9631$, значит, $\rho = 1 > 3/4$. Шаг достиг границы, поэтому Δ увеличивается; радиус следующей пробы — 4.

Ответ. $p_C = (-0{,}2072;\ -1{,}0359)$, шаг dogleg $p = (-1{,}7289;\ -1{,}0054)$, $f = 0{,}0369$.

B2. Доверительная область сжимается, когда модель лжёт

Самостоятельно

Условие. Для $f(x) = -x + \frac{1}{4}x^4$ в $x_0 = 0{,}5$ при $B_0 = f''(x_0)$ начните с $\Delta_0 = 2$ и запустите метод доверительной области до первого принятого шага. Правило: при $\rho < 0{,}25$ шаг отвергается и $\Delta \leftarrow \Delta/2$; иначе принимается. Укажите Δ принятого шага, следующую точку и число отказов.

Решение.

1. В точке $x_0 = 0{,}5$: $g = -0{,}875$, $B = 0{,}75$. Безусловный минимум модели равен $-g/B = 1{,}1667$: он лежит далеко за первым шаром радиуса 2.
2. Первая проба имеет длину 2 и идёт в сторону $-\operatorname{sign}(g)$. Квартичное слагаемое растёт настолько быстро, что либо $f(x_0 + p) > f(x_0)$, либо $\rho < 0{,}25$; Δ делится на 2, и проба повторяется.
3. Принятое $\Delta = 0{,}5$ приходит после 2 отказов. Шаг равен 0,5, $x_1 = 1$; f падает с $-0{,}4844$ до $-0{,}75$.

Ответ. $\Delta = 0{,}5$, $x_1 = 1$; отказов — 2.

4 BFGS с ограниченной памятью

Плотный BFGS хранит матрицу $n \times n$. **L-BFGS** хранит последние m пар (s_i, y_i) и умножает G_k на g_k, не строя её: с масштабированием $\gamma_k = s_{k-1}^\top y_{k-1} / (y_{k-1}^\top y_{k-1})$ и двухпроходной рекурсией одно направление стоит около $4mn$ умножений со сложением.

- Положите $q = g_k$. Для пар от новой к старой: $a_i = s_i^\top q / (y_i^\top s_i)$, $q \leftarrow q - a_i y_i$.
- Масштабируйте: $r = \gamma_k q$.
- Для пар от старой к новой: $b_i = y_i^\top r / (y_i^\top s_i)$, $r \leftarrow r + s_i (a_i - b_i)$.
- Верните $p_k = -r$: около $4mn$ операций и $2mn$ хранимых чисел.

Утверждение. Результат равен $-Gg$ для матрицы G, полученной из $\gamma_k I$ последовательными m обновлениями BFGS по хранимым парам. При $m \geq n$ L-BFGS и плотный BFGS совпадают с точностью машинного эпсилон.

C1. BFGS вручную

У доски

Условие. Пусть $f(x) = \frac{1}{2} x^\top Q x$, $Q = \operatorname{diag}\begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}$, $x_0 = (2;\ 2)$, $G_0 = I$, линейный поиск точный. Сделайте два шага: после первого составьте s, y и обновите G по BFGS в обратной форме, проверьте секущее условие, затем сделайте второй шаг. Укажите диагональ G_1, α_1 и x_2.

Решение.

1. $g_0 = Qx_0 = (2;\ 8)$, $p_0 = -g_0$, $\alpha_0 = g_0^\top g_0 / (g_0^\top Q g_0) = 0{,}2615$. Отсюда $s = \alpha_0 p_0 = (-0{,}5231;\ -2{,}0923)$, $x_1 = (1{,}4769;\ -0{,}0923)$, $g_1 = Qx_1 = (1{,}4769;\ -0{,}3692)$ и $y = g_1 - g_0 = (-0{,}5231;\ -8{,}3692)$. На квадратичной функции $y = Qs$ точно.
2. $y^\top s = 17{,}7846 > 0$, $\rho = 1/(y^\top s) = 0{,}0562$. При $V = I - \rho s y^\top$
$$G_1 = V G_0 V^\top + \rho s s^\top = \begin{pmatrix} 1{,}0454 & -0{,}0028 \\ -0{,}0028 & 0{,}2502 \end{pmatrix}.$$
3. Проверки: $G_1 y = (-0{,}5231;\ -2{,}0923) = s$, $G_1^\top = G_1$, собственные значения $(0{,}2502;\ 1{,}0455)$, оба положительны. Обратная $B_1 = \begin{pmatrix} 0{,}9566 & 0{,}0109 \\ 0{,}0109 & 3{,}9973 \end{pmatrix}$ отличается от Q в направлении, ортогональном s: одна секущая пара не фиксирует всю матрицу.

4. $p_1 = -G_1 g_1 = (-1{,}5451;\ 0{,}0966)$, $g_1^\top p_1 = -2{,}3176 < 0$, точный шаг $\alpha_1 = 0{,}9559$: $x_2 = (0;\ 0) = x^* = 0$. При точном линейном поиске BFGS минимизирует n-мерную положительно определённую квадратичную функцию не более чем за n шагов.

Ответ. $G_1 = \begin{pmatrix} 1{,}0454 & -0{,}0028 \\ -0{,}0028 & 0{,}2502 \end{pmatrix}$, $\alpha_1 = 0{,}9559$, $x_2 = (0;\ 0)$.

C2. L-BFGS: двухпроходная рекурсия вручную

Самостоятельно

Условие. В задаче из C1 храните последние $m = 2$ пар. Сделайте два шага L-BFGS из $x_0 = (2;\ 2)$ с точным линейным поиском, применяя двухпроходную рекурсию с масштабированием $\gamma_k = s_{k-1}^\top y_{k-1} / y_{k-1}^\top y_{k-1}$. Укажите γ_1, первую компоненту направления $p_1 = -H_1 g_1$, вычисленного рекурсией, и x_2.

Решение.

1. Нулевой шаг — $-g_0$ с точным α: он совпадает с C1. После него $\gamma_1 = s_0^\top y_0 / (y_0^\top y_0) = 0{,}2529$.

2. Двухпроходный проход с парами $[(s_0, y_0)]$ и ядром $\gamma_1 I$ даёт $p_1 = (-0{,}3908;\ 0{,}0244)$. Точный шаг $\alpha_1 = 3{,}7794$, значит, $x_2 = (0;\ 0)$. На 2-мерной квадратичной функции L-BFGS с $m = n$ совпадает с плотным BFGS до знака.

3. Двухпроходная рекурсия не строит G: она вычисляет Gg за $O(mn)$ операций. При $m \ll n$ она хранит усечённую по последним направлениям версию обратного гессиана.

Ответ. $\gamma_1 = 0{,}2529$, первая компонента $p_1 = -0{,}3908$, первая компонента $x_2 = 0$.

> **Ловушка.** Выбирайте m по задаче: слишком малое перезапускает метод каждые m шагов и теряет итерации; слишком большое тратит работу без выигрыша. Обычный диапазон — от пяти до двадцати, а двухпроходной рекурсии полезно, чтобы $s^\top y$ новейшей пары оставалось положительным.